TRƯỜNG ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE



NHÓM 8

MÔN HỌC: KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

ĐỀ BÀI: Phân tích và đánh giá Medical Cost Personal Datasets

Lớp: Kinh tế đầu tư CLC 66B

Giảng viên: TS. Trần Đức Minh

Thành viên:

1. Đỗ Hương Giang - 11245637
2. Hoàng Hà Linh - 11243965
3. Vũ Thu Phương - 11240560
4. Đỗ Phương Thảo - 11245693
5. Ngô Thùy Dương - 11246847

MỤC LỤC

I. Giai đoạn 1: Thu thập và đánh giá dữ liệu ban đầu 4
1. Xác định bài toán nghiên cứu 4
2. Nguồn dữ liệu 4
2.1 Mô tả dữ liệu 4
2.2. Kiểm tra hiện trạng dữ liệu 5
2.3. Xác định kích thước dữ liệu 6
2.4. Xác định kiểu dữ liệu mỗi biến và giá trị thiếu của dữ liệu 6
2.5. Kiểm tra dữ liệu trùng 8
2.6. Thống kê mô tả biến số 9
2.7. Tính nhất quán của dữ liệu 10
II. Giai đoạn 2 11
1. Khởi tạo dữ liệu phục vụ quá trình làm sạch 11
2. Kiểm tra sai định dạng và miền giá trị của dữ liệu 12
3. Kiểm tra giá trị thiếu và đánh giá phân phối của biến chi phí bảo hiểm 14
4. Phát hiện và xử lý dữ liệu trùng lặp 15
5. Phát hiện ngoại lệ bằng biểu đồ hộp (Boxplot) 16
6. Phát hiện và đánh giá ngoại lệ bằng phương pháp IQR 17
7. Phát hiện và đánh giá ngoại lệ bằng phương pháp IQR 18
8. Phân tích ngoại lệ của chi phí bảo hiểm theo tình trạng hút thuốc 20
9. Mã hóa các biến phân loại (Encoding) 22
10. Chuẩn hóa dữ liệu (Scaling) 24
11. Kiểm tra kết quả sau tiền xử lý dữ liệu 25
III. Giai đoạn 3: Phân tích và trực quan hóa 26
3.1. Người hút thuốc có chi phí bảo hiểm cao hơn không? 26
3.1.1. Thống kê mô tả chi phí bảo hiểm theo tình trạng hút thuốc 27
3.1.2. Trực quan hóa sự khác biệt chi phí bảo hiểm bằng biểu đồ hộp (Boxplot) 29
3.1.3. So sánh chi phí trung bình và trung vị bằng biểu đồ cột (Bar Chart) 31
3.1.4. Kiểm định giả thuyết về sự khác biệt chi phí bảo hiểm giữa hai nhóm: hút thuốc và không 33
3.1.5. Phân tích các quan sát có chi phí cao theo tình trạng hút thuốc 35
3.1.6. Kết luận 38
3.2. Chi phí bảo hiểm thay đổi thế nào theo độ tuổi? 39
3.2.1: Biểu đồ phân tán giữa tuổi và chi phí bảo hiểm 40
3.2.2: Kiểm định giả thuyết về mối tương quan giữa tuổi và chi phí 41
3.2.3: Chi phí bảo hiểm theo nhóm tuổi 42
3.2.4: Phân bố các quan sát có chi phí cao theo nhóm tuổi 44

3.2.5: Xu hướng chi phí theo tuổi khi phân tách theo tình trạng hút thuốc 46
3.2.6. Kết luận Bảng 2 48
3.3. Chỉ số BMI có mối liên hệ với chi phí bảo hiểm y tế cá nhân không? 49
3.3.1. Trực quan hóa mối quan hệ giữa BMI và chi phí y tế bằng biểu đồ phân tán 49
3.3.2. Đo lường và kiểm định mối tương quan giữa BMI và chi phí y tế 51
3.3.3. Phân tích mối quan hệ giữa BMI và chi phí y tế theo tình trạng hút thuốc 53
3.3.4. So sánh chi phí y tế theo ngưỡng BMI và tình trạng hút thuốc 57
3.3.5. Kết luận 59
3.4.1. Thống kê mô tả chi phí y tế theo từng khu vực 61
3.4.2. Trực quan hóa sự khác biệt chi phí y tế giữa bốn khu vực 63
3.4.3. Kiểm định giả thuyết về sự khác biệt chi phí y tế giữa các khu vực 65
3.4.4. Phân tích sự khác biệt chi phí giữa các khu vực theo tình trạng hút thuốc 69
3.4.5. Kết luận Bảng 4 75
3.5. Mối quan hệ giữa các biến định lượng và chi phí y tế cá nhân 76
3.5.1. Tính ma trận tương quan Pearson 77
3.5.1. Trực quan hóa ma trận bằng Heatmap 78
3.5.4. Kiểm định giả thuyết về mối tương quan 81
3.5.5. Kết luận 82
IV. Giai đoạn 4: Đánh giá tác động và khuyến nghị 83
1. Tóm tắt các phát hiện kinh doanh hay chuyên môn nổi bật nhất. 83
2. Đề xuất giải pháp mang tính ứng dụng thực tế. 85
2.1. Xây dựng chương trình bảo hiểm gắn với hỗ trợ cai thuốc lá và phòng ngừa rủi ro sức khỏe 85
2.2. Phát triển gói bảo hiểm và chương trình chăm sóc sức khỏe theo từng giai đoạn tuổi 86
2.3. Xây dựng chương trình quản lý BMI kết hợp với tình trạng hút thuốc, thay vì chỉ dựa vào chỉ số BMI riêng lẻ 87
2.4. Ứng dụng phân tích dữ liệu để cá nhân hóa đánh giá rủi ro và dự báo chi phí bảo hiểm 88
2.5. Phát triển mô hình chăm sóc sức khỏe cộng đồng dựa trên nhu cầu thực tế, thay vì phân bổ nguồn lực đồng đều theo khu vực 89
2.6. Thiết kế các gói bảo hiểm gia đình linh hoạt theo nhu cầu chăm sóc thực tế 90
3. Chỉ ra các giới hạn của tập dữ liệu và hướng mở rộng trong tương lai. 90
3.1. Giới hạn của tập dữ liệu 90
3.2. Hướng mở rộng trong tương lai 92
3.3. Định hướng phát triển nghiên cứu 93

I. Giai đoạn 1: Thu thập và đánh giá dữ liệu ban đầu

1. Xác định bài toán nghiên cứu

Trong bối cảnh lĩnh vực y tế ngày càng phát triển, việc tìm hiểu sự khác biệt về chi phí y tế giữa các cá nhân có ý nghĩa quan trọng đối với hoạt động phân tích rủi ro, đánh giá đặc điểm khách hàng và hỗ trợ quá trình ra quyết định của doanh nghiệp bảo hiểm. Chi phí y tế có thể liên quan đến nhiều yếu tố khác nhau, bao gồm đặc điểm nhân khẩu học, tình trạng sức khỏe và hành vi của cá nhân. Từ đó có thể rút ra được những yếu tố tác động đến sự thay đổi trong chi phí bảo hiểm.

Trên cơ sở bộ dữ liệu Medical Cost Personal Dataset (Insurance), nhóm nghiên cứu xác định bài toán trọng tâm là phân tích các yếu tố liên quan đến chi phí y tế cá nhân tại Hoa Kỳ. Trong đó, chi phí y tế (charges) được lựa chọn làm biến phụ thuộc, trong khi các yếu tố như độ tuổi (age), giới tính (sex), chỉ số BMI (bmi), số người phụ thuộc (children), tình trạng hút thuốc (smoker) và khu vực sinh sống (region) được sử dụng làm các biến độc lập.

Thông qua việc áp dụng các phương pháp thống kê mô tả, phân tích so sánh, phân tích tương quan và trực quan hóa dữ liệu, nghiên cứu hướng đến việc nhận diện đặc điểm phân phối chi phí y tế, làm rõ sự khác biệt giữa các nhóm cá nhân và xác định những yếu tố có mối liên hệ đáng chú ý với chi phí y tế. Đặc biệt, nghiên cứu tập trung xem xét sự khác biệt về chi phí giữa người hút thuốc và không hút thuốc, cũng như mối liên hệ giữa độ tuổi, chỉ số BMI và chi phí y tế.

2. Nguồn dữ liệu

Nhóm nghiên cứu sử dụng bộ dữ liệu Medical Cost Personal Dataset được công bố trên nền tảng Kaggle. Đây là nguồn dữ liệu thứ cấp cung cấp thông tin về đặc điểm nhân khẩu học, chỉ số BMI, tình trạng hút thuốc và chi phí y tế của các cá nhân tại Hoa Kỳ.

2.1 Mô tả dữ liệu

Tập dữ liệu Medical Cost Personal Dataset (Insurance) chứa các thông tin đa chiều về đặc điểm nhân khẩu học, tình trạng sức khỏe và chi phí y tế của các cá nhân tại Hoa Kỳ. Với 1.338 quan sát và 7 thuộc tính. Cụ thể, các biến trong tập dữ liệu được phân loại thành các nhóm như sau:

- **Nhóm đặc điểm nhân khẩu học:** age (độ tuổi), sex (giới tính), children (số con/người phụ thuộc được bảo hiểm). Nhóm biến này phản ánh những đặc điểm cơ bản của cá nhân, giúp phân loại các đối tượng theo độ tuổi, giới tính và quy mô người phụ thuộc.

- **Nhóm đặc điểm sức khỏe và hành vi cá nhân:** bmi (chỉ số khối cơ thể), smoker (tình trạng hút thuốc). Đây là nhóm biến quan trọng để phân tích mối liên hệ giữa đặc điểm sức khỏe, hành vi cá nhân và chi phí y tế. Trong đó, BMI cung cấp thông tin về chỉ số khối cơ thể, còn tình trạng hút thuốc cho phép phân chia đối tượng thành hai nhóm hút thuốc và không hút thuốc.
- **Nhóm đặc điểm địa lý:** region (khu vực sinh sống). Biến này phân loại các cá nhân theo bốn khu vực tại Hoa Kỳ, bao gồm Northeast, Northwest, Southeast và Southwest. Thông qua việc so sánh chi phí y tế giữa các khu vực, nghiên cứu có thể nhận diện sự khác biệt về mức chi phí theo vị trí địa lý, từ đó xem xét vai trò của yếu tố khu vực trong sự phân hóa chi phí y tế cá nhân.
- **Nhóm biến chi phí y tế:** charges (chi phí y tế cá nhân, tính bằng USD). Đây là biến kết quả trọng tâm của nghiên cứu, phản ánh khoản chi phí y tế được ghi nhận đối với mỗi cá nhân trong tập dữ liệu. Việc phân tích biến này giúp xác định đặc điểm phân phối, mức chi phí trung bình, mức độ biến động và sự chênh lệch chi phí giữa các nhóm đối tượng.

2.2. Kiểm tra hiện trạng dữ liệu

Để đọc dữ liệu, nhóm đã liên kết Google Colab với Google Drive. Để tiến hành đọc và khai phá dữ liệu ban đầu, nhóm sử dụng các thư viện của Python bao gồm Pandas, Numpy, Matplotlib và Seaborn. Sử dụng thư viện Pandas để đọc tập dữ liệu insurance.csv và lưu vào DataFrame có tên df. Từ đó phục vụ cho các bước kiểm tra, xử lý và phân tích tiếp theo.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Đọc dữ liệu từ file CSV đã tải lên Colab
df = pd.read_csv('/insurance.csv')

# Hiển thị 5 dòng đầu tiên
display(df.head())
```

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520

Trong đó:

- import pandas as pd: Khai báo thư viện Pandas, phục vụ việc đọc, quản lý và xử lý dữ liệu dạng bảng.
- import numpy as np: Khai báo thư viện NumPy, hỗ trợ các phép tính toán số học và xử lý dữ liệu số.
- import matplotlib.pyplot as plt: Khai báo thư viện Matplotlib, phục vụ việc xây dựng và tùy chỉnh các biểu đồ.
- import seaborn as sns: Khai báo thư viện Seaborn, hỗ trợ trực quan hóa dữ liệu thống kê.

Lệnh display đã hiển thị 5 quan sát đầu tiên của tập dữ liệu nhằm có cái nhìn tổng quan về cấu trúc bảng, tên các biến và cách dữ liệu được biểu diễn. Kết quả hiển thị ban đầu cho thấy tập dữ liệu được tổ chức dưới dạng bảng, trong đó mỗi dòng tương ứng với một quan sát và mỗi cột đại diện cho một thuộc tính.

2.3. Xác định kích thước dữ liệu

Để xác định kích thước tập dữ liệu, nhóm đã sử dụng df.shape của DataFrame:

```
# Kiểm tra số dòng, số cột và tên các biến
print("Số hàng dữ liệu:", df.shape[0])
print("Số  của dữ liệu:", df.shape[1])
print("Tên các cột:", df.columns.tolist())
```

```
Số hàng dữ liệu: 1338
Số  của dữ liệu: 7
Tên các cột: ['age', 'sex', 'bmi', 'children', 'smoker', 'region', 'charges']
```

Kết quả cho thấy bộ dữ liệu gồm 1338 hàng và 7 cột. Trong đó, mỗi hàng ghi lại thuộc tính khác nhau của hành vi người dùng. Để cụ thể hóa hơn các thuộc tính của dữ liệu, nhóm sử dụng lệnh print(df.columns.tolist()). Lệnh này chuyển danh sách cột ra dạng list, từ đó thuận tiện hơn cho việc quan sát.

2.4. Xác định kiểu dữ liệu mỗi biến và giá trị thiếu của dữ liệu

Việc này giúp dễ dàng hơn trong việc xem các thông tin của bộ dữ liệu, bao gồm số dòng, tên cột, từng cột và số lượng giá trị thiếu trong mỗi cột. Bên cạnh đó, còn cho biết kiểu dữ liệu của từng cột và dung lượng bộ nhớ mà data đang sử dụng.

```python
# Kiểm tra kiểu dữ liệu mỗi biến thuộc kiểu dữ liệu gì
df.info()
print("\nSố giá trị thiếu từng cột:")
print(df.isnull().sum())
print("Tổng số giá trị thiếu là:", df.isnull().sum().sum())
```

Bộ dữ liệu Insurance gốc có 7 thuộc tính, được phân chia thành ba kiểu dữ liệu chính:

- **Kiểu số nguyên (int64):** Gồm 2 biến age và children, lần lượt phản ánh độ tuổi và số người phụ thuộc.
- **Kiểu số thực (float64):** Gồm 2 biến bmi và charges, phản ánh chỉ số khối cơ thể và chi phí y tế cá nhân.
- **Kiểu chuỗi (object):** Gồm 3 biến sex, smoker và region, thể hiện các đặc điểm phân loại như giới tính, tình trạng hút thuốc và khu vực sinh sống.

Bên cạnh đó, nhóm sử dụng các câu lệnh sau để kiểm tra tình trạng khuyết thiếu dữ liệu:

- print("\nSố giá trị thiếu từng cột:"): Hiển thị tiêu đề cho phần thống kê số lượng giá trị khuyết thiếu theo từng thuộc tính.
- df.isnull().sum(): Kiểm tra và đếm tổng số giá trị khuyết thiếu trong từng cột dữ liệu. Trong đó, isnull() xác định các ô có giá trị thiếu, còn sum() tính tổng số ô bị thiếu của từng thuộc tính.
- df.isnull().sum().sum(): Tính tổng số giá trị khuyết thiếu trong toàn bộ tập dữ liệu bằng cách cộng số giá trị thiếu của tất cả các cột.

Kết quả kiểm tra giá trị khuyết thiếu cho thấy cả 7 thuộc tính đều có số lượng giá trị thiếu bằng 0. Do đó, tổng số giá trị khuyết thiếu trong toàn bộ tập dữ liệu cũng bằng 0.

Để đánh giá sâu mức độ đầy đủ của tập dữ liệu, nhóm tiến hành kiểm tra số lượng và tỷ lệ phần trăm giá trị khuyết thiếu của từng thuộc tính thông qua các câu lệnh Python.

Cụ thể:

- missing_count = df.isnull().sum(): Xác định số lượng giá trị khuyết thiếu trong từng cột và lưu kết quả vào biến missing_count.

- missing_percent = df.isnull().mean() * 100: Tính tỷ lệ phần trăm giá trị khuyết thiếu trong từng cột trên tổng số quan sát. Trong đó, mean() tính tỷ lệ các giá trị được xác định là thiếu, sau đó nhân với 100 để chuyển sang đơn vị phần trăm.
- pd.DataFrame(): Tạo bảng tổng hợp gồm hai cột Missing Count (số lượng giá trị thiếu) và Missing Percentage (%) (tỷ lệ phần trăm giá trị thiếu).
- display(missing_summary): Hiển thị bảng thống kê kết quả dưới dạng trực quan, giúp thuận tiện cho việc quan sát và đánh giá.

```
# Tính tỷ lệ phần trăm dữ liệu thiếu
missing_count = df.isnull().sum()
missing_percent = df.isnull().mean() * 100

missing_summary = pd.DataFrame({
    'Missing Count': missing_count,
    'Missing Percentage (%)': missing_percent
})

display(missing_summary)
```

Kết quả thực thi cho thấy cả 7 thuộc tính của tập dữ liệu, bao gồm age, sex, bmi, children, smoker, region và charges, đều có số lượng giá trị khuyết thiếu bằng 0, tương ứng với tỷ lệ khuyết thiếu 0%.

2.5. Kiểm tra dữ liệu trùng

Để kiểm tra sự tồn tại của các bản ghi trùng lặp trong tập dữ liệu, nhóm sử dụng các câu lệnh df.duplicated().sum() và df[df.duplicated(keep=False)].

Cụ thể:

- df.duplicated(): Kiểm tra các dòng dữ liệu có toàn bộ giá trị thuộc tính giống với một dòng đã xuất hiện trước đó hay không. Kết quả trả về là True đối với các dòng được xác định là trùng lặp và False đối với các dòng còn lại.
- df.duplicated().sum(): Đếm tổng số dòng dữ liệu trùng lặp trong tập dữ liệu.
- df.duplicated(keep=False): Đánh dấu tất cả các dòng thuộc nhóm bản ghi trùng lặp, bao gồm cả dòng xuất hiện đầu tiên.
- df[df.duplicated(keep=False)]: Trích xuất và hiển thị toàn bộ các dòng có giá trị giống nhau, giúp nhóm xác định cụ thể những bản ghi bị trùng.

```
# Kiểm tra các dòng trùng lặp
print("Số dòng trùng:", df.duplicated().sum())
# Hiển thị dòng bị trùng:
df[df.duplicated(keep=False)]
```

```
Số dòng trùng: 1
```

	age	sex	bmi	children	smoker	region	charges
195	19	male	30.59	0	no	northwest	1639.5631
581	19	male	30.59	0	no	northwest	1639.5631

Kết quả cho thấy hai dòng dữ liệu có chỉ số 195 và 581 được hiển thị với các thuộc tính hoàn toàn giống nhau.

2.6. Thống kê mô tả biến số

Lệnh df.describe() được sử dụng để thực hiện thống kê mô tả đối với các thuộc tính dạng số trong DataFrame. Mặc định, lệnh này áp dụng cho các biến có kiểu dữ liệu số như int64 và float64.

Kết quả thống kê bao gồm các chỉ tiêu: số lượng quan sát hợp lệ (count), giá trị trung bình (mean), độ lệch chuẩn (std), giá trị nhỏ nhất (min), các tứ phân vị (25%, 50%, 75%) và giá trị lớn nhất (max).

```
# Thống kê mô tả các biến số
display(df.describe())
```

	age	bmi	children	charges
count	1338.000000	1338.000000	1338.000000	1338.000000
mean	39.207025	30.663397	1.094918	13270.422265
std	14.049960	6.098187	1.205493	12110.011237
min	18.000000	15.960000	0.000000	1121.873900
25%	27.000000	26.296250	0.000000	4740.287150
50%	39.000000	30.400000	1.000000	9382.033000
75%	51.000000	34.693750	2.000000	16639.912515
max	64.000000	53.130000	5.000000	63770.428010

Đối với bộ dữ liệu Insurance gốc, có 4 thuộc tính được thống kê gồm age, bmi, children và charges. Tất cả các biến đều có count = 1338, cho thấy không có giá trị khuyết thiếu trong các thuộc tính dạng số.

- **Biến age:** Dao động từ 18 đến 64 tuổi, với độ tuổi trung bình khoảng 39,21.
- **Biến bmi:** Có giá trị nhỏ nhất khoảng 15,96 và lớn nhất khoảng 53,13, trung bình khoảng 30,66.
- **Biến children:** Dao động từ 0 đến 5, với giá trị trung bình khoảng 1,09.
- **Biến charges:** Có giá trị nhỏ nhất khoảng 1.121,87 USD và lớn nhất khoảng 63.770,43 USD, trung bình khoảng 13.270,42 USD. Độ lệch chuẩn khoảng 12.110,01 USD cho thấy chi phí y tế có mức độ phân tán lớn giữa các cá nhân.

2.7. Tính nhất quán của dữ liệu

```
# Kiểm tra tính nhất quán của dữ liệu
for col in ['sex', 'smoker', 'region']:
    print(f"\n{col}:")
    print(df[col].value_counts(dropna=False))
```

Nhóm sử dụng phương thức value_counts() để kiểm tra các giá trị xuất hiện cùng với những thuộc tính phân loại, bao gồm sex, smoker và region.

Trong đó:

- Vòng lặp for cho phép lần lượt kiểm tra từng thuộc tính trong danh sách.
- df[col] truy xuất dữ liệu của thuộc tính đang được kiểm tra.
- value_counts() đếm số lần xuất hiện của từng giá trị.
- dropna=False cho phép hiển thị cả các giá trị khuyết thiếu nếu có.

Kết quả: Đối với bộ Insurance gốc, các thuộc tính phân loại có những nhóm giá trị như sau:

- **Biến sex:** Gồm hai giá trị male và female, tương ứng với giới tính nam và nữ.
- **Biến smoker:** Gồm hai giá trị yes và no, thể hiện tình trạng hút thuốc và không hút thuốc.
- **Biến region:** Gồm bốn giá trị northeast, northwest, southeast và southwest, tương ứng với bốn khu vực địa lý tại Hoa Kỳ.

```
sex:
sex
male      676
female    662
Name: count, dtype: int64

smoker:
smoker
no     1064
yes     274
Name: count, dtype: int64

region:
region
southeast    364
southwest    325
northwest    325
northeast    324
Name: count, dtype: int64
```

II. Giai đoạn 2

1. Khởi tạo dữ liệu phục vụ quá trình làm sạch

```
# GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU
# Tạo bản sao để làm sạch, giữ nguyên dữ liệu gốc df của Giai đoạn 1
df_clean = df.copy()
print("Kích thước dữ liệu trước khi làm sạch:", df_clean.shape)
```

```
Kích thước dữ liệu trước khi làm sạch: (1338, 7)
```

Ở giai đoạn 2, nhóm tiến hành tiền xử lý và làm sạch bộ dữ liệu insurance nhằm kiểm tra, đánh giá và xử lý những vấn đề có thể ảnh hưởng đến chất lượng dữ liệu trước khi thực hiện các bước phân tích tiếp theo.

Trước tiên, nhóm sử dụng câu lệnh df_clean = df.copy() để tạo một bản sao từ DataFrame df đã được xây dựng ở giai đoạn 1. Việc tạo bản sao giúp nhóm thực hiện các thao tác làm sạch trên df_clean mà không làm thay đổi trực tiếp dữ liệu gốc. Nhờ

đó, dữ liệu ban đầu vẫn được giữ lại để đối chiếu và đánh giá mức độ thay đổi sau quá trình xử lý.

Tiếp theo, nhóm sử dụng thuộc tính shape để xác định kích thước của bộ dữ liệu trước khi làm sạch. Kết quả cho thấy dữ liệu ban đầu gồm 1.338 quan sát và 7 biến. Đây là mốc đối chiếu để nhóm đánh giá sự thay đổi về số lượng bản ghi và số lượng biến trong các bước xử lý tiếp theo.

Như vậy, thao tác khởi tạo này chưa làm thay đổi nội dung dữ liệu mà chỉ tạo ra một bản sao phục vụ quá trình làm sạch. Việc xác định kích thước ban đầu cũng giúp nhóm theo dõi và kiểm soát những thay đổi phát sinh trong quá trình tiền xử lý.

2. Kiểm tra sai định dạng và miền giá trị của dữ liệu

```
# KIỂM TRA SAI ĐỊNH DẠNG
# Xem kiểu dữ liệu của từng cột
print(df_clean.dtypes)

# Liệt kê các giá trị của 3 biến phân loại để tìm lỗi chính tả, viết hoa, khoảng trắng thừa
for cot in ['sex', 'smoker', 'region']:
    print(cot, ":", df_clean[cot].unique())

# Kiểm tra giá trị vô lý của các biến số
print("Số dòng có tuổi < 18 hoặc > 100:", ((df_clean['age'] < 18) | (df_clean['age'] > 100)).sum())
print("Số dòng có BMI <= 0:", (df_clean['bmi'] <= 0).sum())
print("Số dòng có số con < 0:", (df_clean['children'] < 0).sum())
print("Số dòng có chi phí <= 0:", (df_clean['charges'] <= 0).sum())
```

```
age           int64
sex          object
bmi         float64
children      int64
smoker       object
region       object
charges     float64
dtype: object
sex : ['female' 'male']
smoker : ['yes' 'no']
region : ['southwest' 'southeast' 'northwest' 'northeast']
Số dòng có tuổi < 18 hoặc > 100: 0
Số dòng có BMI <= 0: 0
Số dòng có số con < 0: 0
Số dòng có chi phí <= 0: 0
```

Sau khi khởi tạo bản sao dữ liệu df_clean, nhóm tiến hành kiểm tra kiểu dữ liệu, tính nhất quán của các biến phân loại và tính hợp lý của các biến số. Mục tiêu của bước này là phát hiện những sai lệch có thể ảnh hưởng đến quá trình phân tích, đồng thời xác định liệu dữ liệu có cần điều chỉnh trước khi tiếp tục xử lý hay không.

Kiểm tra kiểu dữ liệu của các biến. Nhóm sử dụng thuộc tính dtypes để xác định kiểu dữ liệu của từng cột. Kết quả cho thấy bộ dữ liệu gồm 7 biến, trong đó age và children có kiểu số nguyên (int64); bmi và charges có kiểu số thực (float64); còn sex, smoker và region có kiểu dữ liệu đối tượng (object).

Cách biểu diễn này phù hợp với ý nghĩa của các biến trong bộ dữ liệu. Cụ thể, tuổi và số con được biểu diễn bằng số nguyên; BMI và chi phí bảo hiểm được biểu diễn bằng số thực; các biến giới tính, tình trạng hút thuốc và khu vực cư trú được biểu diễn bằng nhãn phân loại. Vì vậy, kết quả kiểm tra chưa cho thấy dấu hiệu sai kiểu dữ liệu ở các cột được sử dụng.

Kiểm tra tính nhất quán của các biến phân loại. Đối với ba biến sex, smoker và region, nhóm sử dụng vòng lặp kết hợp với phương thức unique() để liệt kê các giá trị khác nhau đang xuất hiện trong từng cột. Kết quả ghi nhận:

- sex gồm hai giá trị: female và male.
- smoker gồm hai giá trị: yes và no.
- region gồm bốn giá trị: southwest, southeast, northwest và northeast.

Các giá trị quan sát được thống nhất về cách viết chữ thường và phù hợp với các nhóm phân loại của bộ dữ liệu. Kết quả này cho thấy chưa phát hiện dấu hiệu không nhất quán rõ ràng về chữ hoa, chữ thường hoặc các nhãn phân loại trong phần dữ liệu được kiểm tra.

Việc kiểm tra này có ý nghĩa quan trọng vì những nhãn có cùng ý nghĩa nhưng khác cách viết hoặc chứa khoảng trắng thừa có thể bị hệ thống coi là các nhóm riêng biệt. Trong trường hợp đó, kết quả thống kê tần suất và quá trình mã hóa biến phân loại có thể bị ảnh hưởng.

Kiểm tra miền giá trị của các biến số. Nhóm xây dựng các điều kiện kiểm tra dựa trên ý nghĩa thực tế của từng biến, bao gồm: tuổi nhỏ hơn 18 hoặc lớn hơn 100; BMI nhỏ hơn hoặc bằng 0; số con nhỏ hơn 0; và chi phí bảo hiểm nhỏ hơn hoặc bằng 0. Các điều kiện này được thực hiện bằng phép so sánh trên từng cột, kết hợp với phương thức sum() để đếm số dòng thỏa mãn điều kiện.

Kết quả kiểm tra cho thấy không có quan sát nào vi phạm các điều kiện trên. Cụ thể, số dòng có tuổi nhỏ hơn 18 hoặc lớn hơn 100 bằng 0; số dòng có BMI nhỏ hơn hoặc bằng 0 bằng 0; số dòng có số con âm bằng 0; và số dòng có chi phí bảo hiểm nhỏ hơn hoặc bằng 0 bằng 0.

Như vậy, theo các tiêu chí kiểm tra được xây dựng trong code, nhóm chưa phát hiện giá trị bất hợp lý ở bốn biến số. Tuy nhiên, kết quả này chỉ phản ánh những điều kiện đã được kiểm tra, không đồng nghĩa với việc toàn bộ dữ liệu chắc chắn không có sai sót. Đặc biệt, các giá trị lớn hoặc khác biệt so với phần lớn quan sát vẫn cần được xem xét riêng bằng phương pháp phát hiện ngoại lệ ở bước tiếp theo.

Từ kết quả trên, nhóm chưa thực hiện điều chỉnh kiểu dữ liệu hoặc loại bỏ quan sát ở bước kiểm tra này. Việc giữ nguyên dữ liệu khi chưa có bằng chứng về sai sót

giúp hạn chế những thay đổi không cần thiết, đồng thời tạo cơ sở để tiếp tục kiểm tra bản ghi trùng lặp và ngoại lệ.

3. Kiểm tra giá trị thiếu và đánh giá phân phối của biến chi phí bảo hiểm

```
# KIỂM TRA GIÁ TRỊ THIẾU
print("Tổng số giá trị thiếu:", df_clean.isnull().sum().sum())
# Không có giá trị thiếu -> không điền. Nếu có, charges sẽ điền bằng Median thay vì Mean
# vì charges lệch phải mạnh (Mean bị kéo lên bởi một số ít chi phí rất cao)
print("Mean charges  :", round(df_clean['charges'].mean(), 2))
print("Median charges:", round(df_clean['charges'].median(), 2))
print("Hệ số lệch (skew) của charges:", round(df_clean['charges'].skew(), 2))
```

```
Tổng số giá trị thiếu: 0
Mean charges  : 13270.42
Median charges: 9382.03
Hệ số lệch (skew) của charges: 1.52
```

Sau khi kiểm tra kiểu dữ liệu, nhãn phân loại và miền giá trị, nhóm tiếp tục đánh giá mức độ đầy đủ của dữ liệu thông qua việc kiểm tra giá trị thiếu. Đồng thời, nhóm xem xét các chỉ tiêu thống kê của biến charges nhằm xác định đặc điểm phân phối, làm cơ sở lựa chọn phương pháp xử lý phù hợp nếu phát sinh dữ liệu thiếu ở bước sau.

Kiểm tra giá trị thiếu. Nhóm sử dụng biểu thức df_clean.isnull().sum().sum() để tính tổng số ô có giá trị thiếu trên toàn bộ DataFrame. Kết quả cho thấy tổng số giá trị thiếu bằng 0. Điều này chứng tỏ không có ô dữ liệu thiếu được phát hiện trong bộ dữ liệu tại thời điểm kiểm tra. Vì vậy, nhóm không cần thực hiện bổ sung dữ liệu bằng giá trị trung bình, trung vị hay các phương pháp thay thế khác. Việc không tiến hành điền giá trị thiếu giúp giữ nguyên thông tin quan sát ban đầu và tránh tạo ra những giá trị không cần thiết.

Đánh giá phân phối của biến charges. Bên cạnh kiểm tra giá trị thiếu, nhóm tính giá trị trung bình (Mean), trung vị (Median) và hệ số lệch (Skewness) của biến charges. Kết quả thu được như sau:

Chỉ tiêu	Giá trị
Tổng số giá trị thiếu	0
Giá trị trung bình của charges	13.270,42
Giá trị trung vị của charges	9.382,03
Hệ số lệch của charges	1,52

Kết quả cho thấy giá trị trung bình của chi phí bảo hiểm cao hơn đáng kể so với giá trị trung vị. Cụ thể, Mean đạt 13.270,42, trong khi Median đạt 9.382,03. Đồng thời, hệ số lệch của biến charges bằng 1,52, mang giá trị dương và cho thấy phân phối có xu hướng lệch phải.

Điều này hàm ý rằng phần lớn quan sát có thể tập trung ở mức chi phí thấp hơn, trong khi một số quan sát có chi phí cao kéo phần đuôi phân phối về phía bên phải và làm tăng giá trị trung bình. Đặc điểm này cũng giải thích vì sao Mean nhạy cảm hơn với một số giá trị chi phí lớn so với Median.

Từ kết quả trên, nhóm xác định rằng nếu phát sinh giá trị thiếu ở biến charges trong quá trình xử lý dữ liệu, trung vị có thể là phương án cần cân nhắc vì ít chịu ảnh hưởng của các giá trị cực đoan hơn giá trị trung bình. Tuy nhiên, do dữ liệu hiện tại không có giá trị thiếu, nhóm không thực hiện điền Median hoặc Mean. Các chỉ tiêu Mean, Median và Skewness chỉ được sử dụng để mô tả đặc điểm phân phối và định hướng phương pháp xử lý phù hợp khi cần thiết.

Nhìn chung, kết quả kiểm tra cho thấy bộ dữ liệu đáp ứng yêu cầu về tính đầy đủ tại thời điểm đánh giá. Tuy nhiên, việc phân phối charges lệch phải cho thấy nhóm vẫn cần tiếp tục xem xét các giá trị cực đoan bằng phương pháp phát hiện ngoại lệ, thay vì chỉ dựa vào thống kê mô tả để kết luận về chất lượng dữ liệu.

4. Phát hiện và xử lý dữ liệu trùng lặp

```
# XỬ LÝ DỮ LIỆU TRÙNG LẶP
# Dòng 195 và 581 trùng cả 7 cột (kể cả chi phí đến 4 chữ số thập phân) -> nhiều khả năng là lỗi nhập liệu
# Xóa bản lặp, giữ lại 1 bản
df_clean = df_clean.drop_duplicates(keep='first').reset_index(drop=True)

# Kiểm tra lại sau khi xóa
print("Số dòng trùng còn lại:", df_clean.duplicated().sum())
print("Kích thước sau khi xóa trùng:", df_clean.shape)
```

```
Số dòng trùng còn lại: 0
Kích thước sau khi xóa trùng: (1337, 7)
```

Dữ liệu trùng lặp có thể khiến một quan sát được tính nhiều lần trong quá trình thống kê và phân tích, từ đó ảnh hưởng đến tính chính xác của kết quả. Vì vậy, nhóm tiến hành kiểm tra và xử lý các bản ghi trùng hoàn toàn nhằm đảm bảo mỗi bản ghi trong bộ dữ liệu chỉ được lưu giữ một lần theo tiêu chí đã lựa chọn.

Qua quá trình kiểm tra, nhóm phát hiện dòng 195 và dòng 581 có giá trị giống nhau ở toàn bộ 7 cột, bao gồm age, sex, bmi, children, smoker, region và charges. Đáng chú ý, hai dòng có cùng giá trị chi phí bảo hiểm đến bốn chữ số thập phân. Điều này cho thấy hai bản ghi trùng khớp hoàn toàn trên các thuộc tính được thu thập, làm phát sinh khả năng một bản ghi đã bị nhập lặp trong quá trình hình thành dữ liệu.

Để xử lý, nhóm sử dụng phương thức drop_duplicates(keep='first') nhằm giữ lại lần xuất hiện đầu tiên và loại bỏ bản ghi trùng dư thừa. Sau đó, nhóm sử dụng reset_index(drop=True) để đánh lại chỉ số dòng liên tục, giúp dữ liệu có cấu trúc chỉ mục nhất quán sau khi loại bỏ bản ghi.

Kết quả sau xử lý cho thấy kích thước dữ liệu giảm từ 1.338 quan sát xuống còn 1.337 quan sát, trong khi số biến vẫn giữ nguyên là 7. Đồng thời, kết quả kiểm tra bằng df_clean.duplicated().sum() cho thấy số dòng trùng hoàn toàn còn lại bằng 0.

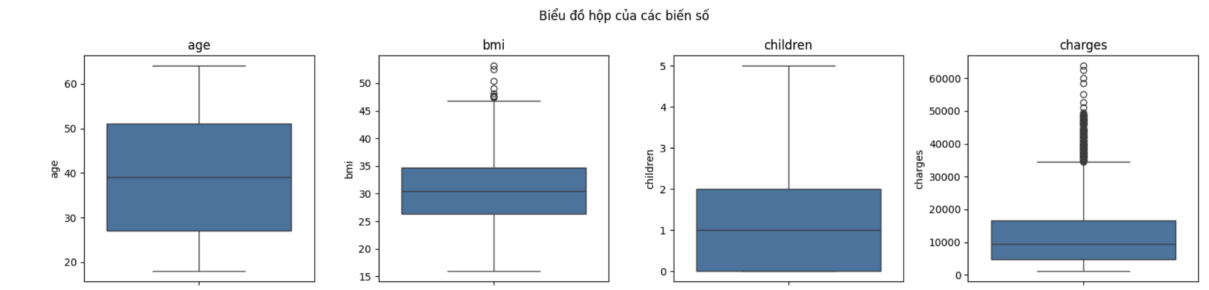
Chỉ tiêu	Trước xử lý	Sau xử lý
Số quan sát	1.338	1.337
Số biến	7	7
Số bản ghi trùng dư thừa còn lại	1	0

Việc loại bỏ một bản ghi trùng giúp hạn chế nguy cơ tính lặp thông tin trong các bước phân tích tiếp theo mà không làm thay đổi cấu trúc biến của bộ dữ liệu. Tuy nhiên, do bộ dữ liệu không có mã định danh cá nhân, nhóm chưa thể khẳng định tuyệt đối rằng hai bản ghi thuộc về cùng một người. Vì vậy, quyết định loại bỏ được thực hiện dựa trên tiêu chí trùng khớp hoàn toàn của cả 7 cột, với mục tiêu tránh lưu giữ hai bản ghi giống hệt nhau trong bộ dữ liệu phân tích.

Nhìn chung, sau bước xử lý, dữ liệu không còn bản ghi trùng hoàn toàn theo tiêu chí kiểm tra của nhóm. Đây là cơ sở để tiếp tục đánh giá ngoại lệ và thực hiện các bước làm sạch còn lại.

5. Phát hiện ngoại lệ bằng biểu đồ hộp (Boxplot)

```
# PHÁT HIỆN NGOẠI LỆ (OUTLIERS)
# Vẽ biểu đồ hộp cho 4 biến số; các chấm nằm ngoài "râu" của hộp là ngoại lệ
cot_so = ['age', 'bmi', 'children', 'charges']
fig, axes = plt.subplots(1, 4, figsize=(16, 4))
for ax, cot in zip(axes, cot_so):
    sns.boxplot(y=df_clean[cot], ax=ax)
    ax.set_title(cot)
plt.suptitle('Biểu đồ hộp của các biến số')
plt.tight_layout()
plt.show()
```



Sau khi xử lý dữ liệu trùng lặp, nhóm tiến hành phát hiện các giá trị ngoại lệ tiềm năng thông qua biểu đồ hộp (Boxplot) đối với bốn biến số gồm age, bmi, children và charges. Nhóm sử dụng thư viện Seaborn để trực quan hóa phân phối của từng biến, qua đó quan sát khoảng phân bố chính, vị trí trung vị và những giá trị nằm ngoài phạm vi của các râu biểu đồ. Theo quy tắc biểu đồ hộp, các điểm nằm ngoài râu được xem là những quan sát cần kiểm tra thêm do có sự khác biệt tương đối lớn so với phần lớn dữ liệu.

Kết quả trực quan cho thấy biến age không xuất hiện các điểm nằm ngoài râu biểu đồ. Phần lớn quan sát nằm trong khoảng từ khoảng 27 đến 51 tuổi, với trung vị xấp xỉ 39 tuổi. Đối với biến children, biểu đồ cũng không thể hiện các điểm ngoại lệ riêng biệt; số con được ghi nhận trong khoảng từ 0 đến 5, trong đó trung vị bằng 1. Những kết quả này cho thấy hai biến chưa xuất hiện dấu hiệu ngoại lệ theo tiêu chí trực quan của biểu đồ hộp.

Ngược lại, biến bmi xuất hiện một số điểm nằm phía trên râu biểu đồ, tập trung ở các giá trị lớn hơn khoảng 47. Điều này cho thấy một số quan sát có chỉ số BMI cao hơn đáng kể so với phần lớn mẫu nghiên cứu. Đối với biến charges, số lượng điểm nằm ngoài râu biểu đồ lớn hơn rõ rệt, chủ yếu ở phía trên ngưỡng khoảng 34.000 và có một số quan sát vượt 60.000. Đặc điểm này phù hợp với kết quả thống kê trước đó, khi biến charges có giá trị trung bình lớn hơn trung vị và hệ số lệch dương bằng 1,52, phản ánh phân phối lệch phải.

Từ kết quả trực quan hóa, nhóm nhận thấy các biến bmi và đặc biệt là charges có những quan sát ngoại lệ tiềm năng cần được xem xét kỹ hơn. Tuy nhiên, biểu đồ hộp chỉ xác định các giá trị khác biệt về mặt thống kê, không đủ căn cứ để kết luận rằng các quan sát này là lỗi nhập liệu. Trong bộ dữ liệu bảo hiểm, BMI cao hoặc chi phí bảo hiểm lớn vẫn có thể phản ánh tình trạng thực tế của người tham gia. Vì vậy, nhóm không tự động xóa các điểm nằm ngoài râu biểu đồ mà sử dụng kết quả này làm căn cứ cho bước đánh giá ngoại lệ tiếp theo, kết hợp với phương pháp IQR và đặc điểm phân phối của dữ liệu.

Nhìn chung, biểu đồ hộp giúp nhóm nhận diện trực quan sự khác biệt về phân phối giữa các biến số, đồng thời cung cấp bằng chứng cho thấy cần chú ý hơn đến bmi và charges trong quá trình làm sạch dữ liệu. Việc giữ lại hay loại bỏ các quan sát này sẽ được cân nhắc dựa trên bản chất dữ liệu và tiêu chí xử lý đã lựa chọn, nhằm hạn chế làm mất thông tin có giá trị trong bộ dữ liệu phân tích.

6. Phát hiện và đánh giá ngoại lệ bằng phương pháp IQR

```python
# Đếm số ngoại lệ bằng quy tắc IQR (Tukey, 1977):
# ngoại lệ là giá trị < Q1 - 1.5*IQR hoặc > Q3 + 1.5*IQR, với IQR = Q3 - Q1
for cot in cot_so:
    Q1 = df_clean[cot].quantile(0.25)
    Q3 = df_clean[cot].quantile(0.75)
    IQR = Q3 - Q1
    can_duoi = Q1 - 1.5 * IQR
    can_tren = Q3 + 1.5 * IQR
    so_ngoai_le = ((df_clean[cot] < can_duoi) | (df_clean[cot] > can_tren)).sum()
    print(f"{cot}: cận dưới = {can_duoi:.2f}, cận trên = {can_tren:.2f}, số ngoại lệ = {so_ngoai_le}")
```

```
age: cận dưới = -9.00, cận trên = 87.00, số ngoại lệ = 0
bmi: cận dưới = 13.67, cận trên = 47.32, số ngoại lệ = 9
children: cận dưới = -3.00, cận trên = 5.00, số ngoại lệ = 0
charges: cận dưới = -13120.72, cận trên = 34524.78, số ngoại lệ = 139
```

Để xác định cụ thể số lượng quan sát ngoại lệ, nhóm tiếp tục áp dụng phương pháp khoảng tứ phân vị (Interquartile Range - IQR) theo quy tắc được Tukey (1977) đề xuất. Với mỗi biến số, nhóm tính tứ phân vị thứ nhất (Q1), tứ phân vị thứ ba (Q3), sau đó xác định khoảng tứ phân vị theo công thức (IQR = Q3 - Q1). Hai ngưỡng phát hiện ngoại lệ được xác định bằng (Q1 - 1,5 \times IQR) và (Q3 + 1,5 \times IQR). Những quan sát có giá trị nằm ngoài hai ngưỡng này được đánh dấu là ngoại lệ tiềm năng.

Kết quả tính toán cho thấy biến age có cận dưới là −9,00 và cận trên là 87,00, không ghi nhận quan sát ngoại lệ theo quy tắc IQR. Đối với biến children, hai ngưỡng tương ứng là −3,00 và 5,00, đồng thời không phát hiện giá trị nằm ngoài khoảng này.

Trong khi đó, biến bmi có cận dưới là 13,67 và cận trên là 47,32, với 9 quan sát nằm ngoài ngưỡng, chủ yếu ở phía trên cận trên. Đối với biến charges, cận dưới là −13.120,72 và cận trên là 34.524,78, với 139 quan sát ngoại lệ tiềm năng, chủ yếu nằm phía trên cận trên. Cận dưới âm là kết quả toán học của công thức IQR, không có ý nghĩa thực tế đối với chi phí bảo hiểm không âm.

Như vậy, trong bốn biến số được kiểm tra, bmi có 9 quan sát ngoại lệ tiềm năng và charges có 139 quan sát ngoại lệ tiềm năng; hai biến age và children không ghi nhận ngoại lệ theo quy tắc IQR. Kết quả này bổ sung bằng chứng định lượng cho biểu đồ hộp và cho thấy cần chú ý hơn đến phân phối của hai biến bmi và charges.

Trên cơ sở đó, nhóm không tự động loại bỏ các quan sát được đánh dấu là ngoại lệ. Các giá trị BMI cao hoặc chi phí bảo hiểm lớn vẫn có thể phản ánh tình trạng thực tế của cá nhân. Do chưa có căn cứ xác nhận đây là lỗi nhập liệu, nhóm giữ nguyên các quan sát nhằm bảo toàn thông tin và hạn chế làm sai lệch đặc điểm của mẫu nghiên cứu. Phương pháp IQR được sử dụng để nhận diện những giá trị cần đánh giá thêm, chứ không phải căn cứ duy nhất để quyết định xóa dữ liệu.

7. Phát hiện và đánh giá ngoại lệ bằng phương pháp IQR

```
# Xem chi tiết các ngoại lệ của BMI
Q1 = df_clean['bmi'].quantile(0.25)
Q3 = df_clean['bmi'].quantile(0.75)
can_tren_bmi = Q3 + 1.5 * (Q3 - Q1)
display(df_clean[df_clean['bmi'] > can_tren_bmi].sort_values('bmi'))
# BMI 47-53 là béo phì độ III theo WHO (BMI >= 40), giá trị có thật, không phải lỗi -> GIỮ LẠI
```

	age	sex	bmi	children	smoker	region	charges
543	54	female	47.41	0	yes	southeast	63770.42801
401	47	male	47.52	1	no	southeast	8083.91980
859	37	female	47.60	2	yes	southwest	46113.51100
1087	52	male	47.74	1	no	southeast	9748.91060
286	46	female	48.07	2	no	northeast	9432.92530
116	58	male	49.06	0	no	southeast	11381.32540
846	23	male	50.38	1	no	southeast	2438.05520
1046	22	male	52.58	1	yes	southeast	44501.39820
1316	18	male	53.13	0	no	southeast	1163.46270

Sau khi sử dụng biểu đồ hộp và quy tắc khoảng tứ phân vị (Interquartile Range - IQR) để phát hiện các giá trị ngoại lệ tiềm năng, nhóm tiếp tục kiểm tra chi tiết những quan sát có chỉ số BMI vượt ngưỡng trên nhằm xác định bản chất của các giá trị này và lựa chọn phương án xử lý phù hợp. Đây là bước cần thiết bởi một giá trị được xác định là ngoại lệ theo tiêu chí thống kê không đồng nghĩa với việc giá trị đó bị sai hoặc không hợp lệ. Đặc biệt, đối với dữ liệu bảo hiểm y tế, chỉ số BMI cao có thể phản ánh tình trạng sức khỏe thực tế của cá nhân và có liên quan đến sự khác biệt về chi phí bảo hiểm.

Trong bước này, nhóm sử dụng phương pháp IQR để xác định cận trên của biến bmi theo công thức (Q3 + 1,5 \times (Q3-Q1)), trong đó Q1 là tứ phân vị thứ nhất và Q3 là tứ phân vị thứ ba. Sau đó, nhóm lọc các quan sát có giá trị bmi lớn hơn cận trên và sắp xếp chúng theo thứ tự tăng dần bằng phương thức sort_values('bmi'). Thao tác này giúp nhóm xem xét trực tiếp các trường hợp được đánh dấu là ngoại lệ, đồng thời đối chiếu chỉ số BMI với những thuộc tính liên quan như tuổi, giới tính, số con, tình trạng hút thuốc, khu vực cư trú và chi phí bảo hiểm. Nhờ đó, việc đánh giá không chỉ dựa trên mức độ cao của một biến đơn lẻ mà còn có thể xem xét tính hợp lý của toàn bộ bản ghi.

Kết quả từ bước tính toán IQR trước đó cho thấy cận trên của biến bmi bằng 47,32. Vì vậy, các quan sát có BMI lớn hơn ngưỡng này được đưa vào bảng kiểm tra chi tiết. Trong phần kết quả hiển thị, các giá trị BMI được ghi nhận gồm 47,41; 47,52; 47,60; 47,74; 48,07; 49,06; 50,38; 52,58 và 53,13. Đây là những giá trị vượt cận trên

theo quy tắc IQR, phù hợp với kết quả thống kê trước đó ghi nhận 9 quan sát ngoại lệ tiềm năng ở biến này.

Đáng chú ý, các bản ghi được hiển thị vẫn có đầy đủ thông tin ở những cột liên quan. Chẳng hạn, quan sát có BMI bằng 47,41 thuộc một cá nhân 54 tuổi, giới tính nữ, không có con, có hút thuốc và sinh sống tại khu vực Southeast; chi phí bảo hiểm được ghi nhận là 63.770,42801. Trong khi đó, quan sát có BMI bằng 47,52 thuộc một cá nhân nam 47 tuổi, có một con, không hút thuốc và có chi phí bảo hiểm 8.083,91980. Một trường hợp khác có BMI bằng 47,60 thuộc cá nhân nữ 37 tuổi, có hai con, hút thuốc và có chi phí bảo hiểm 46.113,51100. Các trường hợp còn lại cũng thể hiện sự khác biệt về tuổi, tình trạng hút thuốc, khu vực cư trú và chi phí bảo hiểm. Điều này cho thấy những quan sát có BMI cao không hoàn toàn giống nhau về các đặc điểm cá nhân và chi phí được ghi nhận.

Từ kết quả kiểm tra, nhóm nhận thấy các giá trị BMI nằm trong khoảng từ 47,41 đến 53,13 trong bảng kết quả hiển thị. Đây là những mức BMI cao và vượt ngưỡng thống kê được xác định bằng IQR. Tuy nhiên, xét về bản chất dữ liệu, các giá trị này vẫn có thể xuất hiện trong thực tế và không tự động chứng minh rằng thông tin đã bị nhập sai. Việc một quan sát nằm ngoài cận trên của biểu đồ hộp chỉ phản ánh rằng giá trị đó khác biệt so với phần lớn mẫu nghiên cứu, chứ không xác nhận đây là lỗi dữ liệu.

Do đó, nhóm lựa chọn giữ lại cả 9 quan sát BMI ngoại lệ tiềm năng, thay vì xóa các dòng này hoặc thay thế chúng bằng giá trị cận trên. Quyết định này dựa trên hai căn cứ chính. Thứ nhất, nhóm chưa có bằng chứng cho thấy các giá trị BMI được ghi nhận là sai định dạng, sai đơn vị hoặc không hợp lệ về mặt logic. Thứ hai, việc loại bỏ các quan sát BMI cao có thể làm mất thông tin về một nhóm cá nhân có đặc điểm sức khỏe khác biệt, từ đó làm giảm tính đa dạng của dữ liệu dùng cho phân tích chi phí bảo hiểm. Việc giữ lại các quan sát này cũng giúp tránh làm thay đổi không cần thiết mối quan hệ giữa BMI và các biến giải thích khác.

Như vậy, sau bước kiểm tra chi tiết, nhóm không thực hiện loại bỏ hay thay thế các giá trị ngoại lệ của biến bmi. Các quan sát này vẫn được giữ trong df_clean và sẽ tiếp tục được sử dụng trong các bước phân tích tiếp theo. Cách xử lý trên bảo đảm rằng quyết định làm sạch dữ liệu được đưa ra dựa trên cả tiêu chí thống kê và ý nghĩa thực tế của biến, thay vì loại bỏ máy móc mọi giá trị vượt ngưỡng IQR.

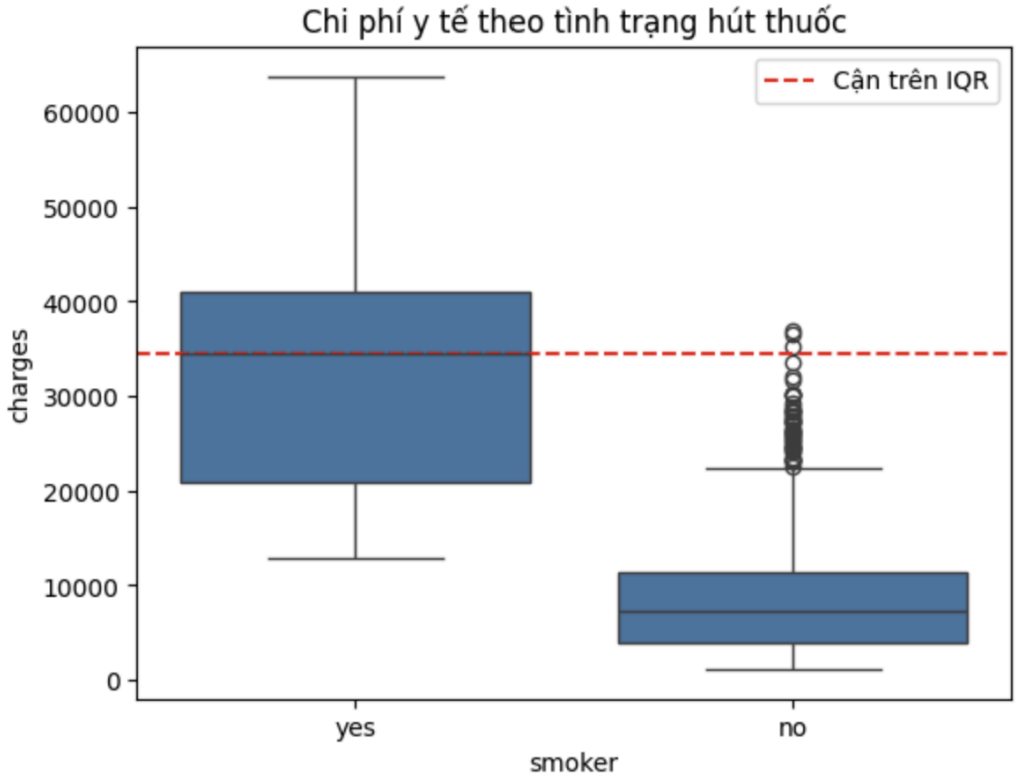
8. Phân tích ngoại lệ của chi phí bảo hiểm theo tình trạng hút thuốc

```python
# Tìm hiểu các ngoại lệ của charges thuộc nhóm khách hàng nào
Q1 = df_clean['charges'].quantile(0.25)
Q3 = df_clean['charges'].quantile(0.75)
can_tren_charges = Q3 + 1.5 * (Q3 - Q1)
ngoai_le_charges = df_clean[df_clean['charges'] > can_tren_charges]

# Đếm số ngoại lệ theo tình trạng hút thuốc
print("Số ngoại lệ charges theo tình trạng hút thuốc:")
print(ngoai_le_charges['smoker'].value_counts())

# Biểu đồ hộp chi phí theo tình trạng hút thuốc, đường đỏ là cận trên IQR
sns.boxplot(data=df_clean, x='smoker', y='charges')
plt.axhline(can_tren_charges, color='red', linestyle='--', label='Cận trên IQR')
plt.title('Chi phí y tế theo tình trạng hút thuốc')
plt.legend()
plt.show()
# Hầu hết ngoại lệ là người hút thuốc -> đây là nhóm khách hàng có thật với chi phí cao,
# không phải lỗi -> GIỮ LẠI (xóa sẽ mất gần một nửa số người hút thuốc)
```

```
Số ngoại lệ charges theo tình trạng hút thuốc:
smoker
yes    136
no       3
Name: count, dtype: int64
```



Sau khi xác định biến charges có 139 quan sát ngoại lệ tiềm năng theo quy tắc IQR, nhóm tiếp tục phân tích đặc điểm của các quan sát này để xác định liệu chi phí cao có phải do lỗi dữ liệu hay phản ánh sự khác biệt thực tế giữa các nhóm khách hàng. Do charges là biến thể hiện chi phí bảo hiểm y tế, việc loại bỏ các giá trị lớn chỉ

dựa trên tiêu chí thống kê có thể làm mất thông tin quan trọng. Vì vậy, nhóm xem xét mối liên hệ giữa các quan sát ngoại lệ và tình trạng hút thuốc của khách hàng.

Trước tiên, nhóm tính cận trên IQR của biến charges theo công thức (Q3 + 1,5 \times (Q3-Q1)). Theo kết quả ở bước trước, cận trên bằng 34.524,78. Các bản ghi có chi phí vượt ngưỡng này được lọc thành tập ngoại lệ tiềm năng. Sau đó, nhóm sử dụng value_counts() để thống kê số lượng quan sát theo hai trạng thái của biến smoker, đồng thời xây dựng biểu đồ hộp thể hiện phân phối chi phí bảo hiểm theo tình trạng hút thuốc và bổ sung đường nét đứt màu đỏ tại cận trên IQR để thuận tiện đối chiếu.

Kết quả thống kê cho thấy trong tổng số 139 quan sát có chi phí bảo hiểm vượt cận trên IQR, có 136 quan sát thuộc nhóm hút thuốc và chỉ 3 quan sát thuộc nhóm không hút thuốc. Tương ứng, nhóm hút thuốc chiếm khoảng 97,84% và nhóm không hút thuốc chiếm 2,16% số quan sát ngoại lệ. Điều này cho thấy phần lớn các giá trị chi phí cao trong bộ dữ liệu tập trung ở nhóm khách hàng có hút thuốc.

Kết quả trên biểu đồ hộp cũng cho thấy phân phối charges của nhóm hút thuốc nằm ở mức cao hơn rõ rệt. Trung vị chi phí của nhóm này vào khoảng 34.500, trong khi nhóm không hút thuốc chỉ khoảng 7.300. Phần lớn chi phí của nhóm hút thuốc tập trung trong khoảng từ 20.000 đến trên 40.000, còn nhóm không hút thuốc chủ yếu nằm trong khoảng 4.000-11.500, dù vẫn có một số quan sát vượt cận trên IQR. Sự khác biệt này cho thấy các giá trị chi phí cao có thể gắn với đặc điểm của nhóm khách hàng thay vì đơn thuần là lỗi nhập liệu. Tuy nhiên, kết quả mới phản ánh mối liên hệ giữa tình trạng hút thuốc và chi phí, chưa đủ để khẳng định hút thuốc là nguyên nhân duy nhất khiến chi phí tăng cao.

Trên cơ sở đó, nhóm quyết định giữ lại 139 quan sát ngoại lệ tiềm năng của biến charges. Việc giữ lại nhằm bảo toàn thông tin khi chưa có bằng chứng cho thấy các giá trị này là sai lệch do nhập liệu. Nếu xóa toàn bộ các quan sát vượt ngưỡng IQR, dữ liệu có thể mất đi một phần đáng kể nhóm khách hàng hút thuốc, làm thay đổi phân phối chi phí và ảnh hưởng đến kết quả phân tích ở các bước tiếp theo.

Nhìn chung, việc kết hợp thống kê theo tình trạng hút thuốc với biểu đồ hộp giúp nhóm đánh giá ngoại lệ dựa trên đặc điểm thực tế của dữ liệu, thay vì tự động loại bỏ các giá trị vượt ngưỡng thống kê. Kết quả là cơ sở để giữ nguyên các quan sát này trong bộ dữ liệu đã làm sạch, đồng thời cung cấp thông tin cho việc phân tích mối liên hệ giữa đặc điểm khách hàng và chi phí bảo hiểm y tế ở giai đoạn tiếp theo.

9. Mã hóa các biến phân loại (Encoding)

```python
# MÃ HÓA BIẾN PHÂN LOẠI (ENCODING)
# Tạo bản riêng df_model để mã hóa; df_clean giữ nguyên chữ để vẽ biểu đồ ở Giai đoạn 3
df_model = df_clean.copy()

# sex và smoker chỉ có 2 giá trị -> mã hóa 0/1
df_model['sex'] = df_model['sex'].map({'female': 0, 'male': 1})
df_model['smoker'] = df_model['smoker'].map({'no': 0, 'yes': 1})

# region có 4 vùng KHÔNG có thứ tự -> dùng One-hot thay vì đánh số 0,1,2,3
# (đánh số sẽ khiến máy hiểu sai là các vùng có thứ tự hơn kém)
# drop_first=True: bỏ cột northeast làm nhóm gốc, tránh lỗi đa cộng tuyến (bẫy biến giả)
df_model = pd.get_dummies(df_model, columns=['region'], drop_first=True, dtype=int)

display(df_model.head())
```

	age	sex	bmi	children	smoker	charges	region_northwest	region_southeast	region_southwest
0	19	0	27.900	0	1	16884.92400	0	0	1
1	18	1	33.770	1	0	1725.55230	0	1	0
2	28	1	33.000	3	0	4449.46200	0	1	0
3	33	1	22.705	0	0	21984.47061	1	0	0
4	32	1	28.880	0	0	3866.85520	1	0	0

Sau khi hoàn thành việc kiểm tra và đánh giá chất lượng dữ liệu, nhóm tiến hành mã hóa các biến phân loại nhằm chuyển dữ liệu dạng chữ thành dữ liệu số, phục vụ quá trình xây dựng mô hình học máy ở giai đoạn tiếp theo. Trong bộ dữ liệu nghiên cứu chi phí bảo hiểm y tế, ba biến phân loại gồm sex, smoker và region, trong đó hai biến đầu có hai giá trị, còn biến region gồm bốn khu vực địa lý. Do đặc điểm của từng biến khác nhau, nhóm lựa chọn phương pháp mã hóa phù hợp cho từng trường hợp.

Trước hết, nhóm tạo bản sao df_model từ bộ dữ liệu đã làm sạch df_clean để thực hiện mã hóa. Cách làm này giúp giữ nguyên dữ liệu gốc ở dạng chữ, phục vụ phân tích mô tả và trực quan hóa ở giai đoạn 3, đồng thời tạo bộ dữ liệu riêng cho quá trình xây dựng mô hình.

Đối với biến sex, nhóm mã hóa female = 0 và male = 1; đối với biến smoker, nhóm mã hóa no = 0 và yes = 1. Do mỗi biến chỉ có hai trạng thái, phương pháp mã hóa nhị phân giúp chuyển đổi dữ liệu sang dạng số mà không cần tạo thêm cột. Các giá trị 0 và 1 chỉ mang ý nghĩa đại diện cho từng nhóm, không thể hiện thứ bậc giữa các nhóm.

Đối với biến region, nhóm sử dụng phương pháp One-Hot Encoding vì bốn khu vực northeast, northwest, southeast và southwest không có thứ tự tự nhiên. Nếu gán các khu vực thành 0, 1, 2 và 3, mô hình có thể hiểu nhầm rằng chúng có quan hệ thứ bậc. Vì vậy, nhóm sử dụng hàm pd.get_dummies() với tham số drop_first=True, loại bỏ cột region_northeast và lấy Northeast làm nhóm tham chiếu. Sau mã hóa, ba cột được tạo gồm region_northwest, region_southeast và region_southwest. Khi cả ba cột

đều bằng 0, khách hàng thuộc khu vực Northeast. Cách làm này đồng thời giúp tránh đa cộng tuyến hoàn hảo giữa các biến giả khi mô hình có hệ số chặn.

Kết quả hiển thị cho thấy các biến phân loại đã được chuyển sang dạng số, trong khi các biến age, bmi, children và charges vẫn được giữ nguyên. Chẳng hạn, dòng dữ liệu đầu tiên có sex = 0, smoker = 1 và region_southwest = 1, tương ứng với khách hàng nữ, có hút thuốc và thuộc khu vực Southwest. Như vậy, quá trình mã hóa giúp dữ liệu phù hợp hơn với yêu cầu đầu vào của các thuật toán học máy, đồng thời việc giữ nguyên df_clean bảo đảm nhóm vẫn có thể sử dụng các nhãn phân loại ban đầu cho những bước phân tích tiếp theo.

10. Chuẩn hóa dữ liệu (Scaling)

```
# CHUẨN HÓA DỮ LIỆU (SCALING)
from sklearn.preprocessing import StandardScaler

# Dùng StandardScaler: (giá trị - trung bình) / độ lệch chuẩn
# Không dùng MinMaxScaler vì nhạy với giá trị cực trị (như BMI 53.13)
# Chỉ chuẩn hóa 3 biến số đầu vào; không chuẩn hóa biến 0/1 và biến mục tiêu charges
cot_chuan_hoa = ['age', 'bmi', 'children']
scaler = StandardScaler()
df_model[cot_chuan_hoa] = scaler.fit_transform(df_model[cot_chuan_hoa])

# Kiểm tra: sau chuẩn hóa, trung bình ≈ 0 và độ lệch chuẩn ≈ 1
display(df_model[cot_chuan_hoa].describe().round(2))
```

	age	bmi	children
count	1337.00	1337.00	1337.00
mean	-0.00	-0.00	0.00
std	1.00	1.00	1.00
min	-1.51	-2.41	-0.91
25%	-0.87	-0.72	-0.91
50%	-0.02	-0.04	-0.08
75%	0.84	0.66	0.75
max	1.76	3.68	3.24

Sau khi mã hóa các biến phân loại, nhóm tiến hành chuẩn hóa dữ liệu nhằm đưa các biến số về cùng thang đo, hạn chế sự khác biệt về độ lớn giữa các biến khi xây dựng mô hình học máy. Trong bộ dữ liệu, nhóm lựa chọn ba biến age, bmi và children để chuẩn hóa, đồng thời giữ nguyên các biến nhị phân sex, smoker, các biến giả của region và biến mục tiêu charges.

Nhóm sử dụng phương pháp Standardization thông qua StandardScaler của thư viện sklearn.preprocessing. Phương pháp này chuyển đổi dữ liệu theo công thức (z=(x-\mu)/\sigma), trong đó (x) là giá trị ban đầu, (\mu) là giá trị trung bình và (\sigma) là độ lệch chuẩn của biến. Sau chuẩn hóa, các biến có giá trị trung bình xấp xỉ 0 và độ lệch chuẩn xấp xỉ 1. Nhóm lựa chọn phương pháp này thay vì Min-Max Scaling do dữ liệu có một số giá trị ngoại lệ tiềm năng, đặc biệt là biến bmi với giá trị lớn nhất 53,13. Tuy nhiên, cần lưu ý StandardScaler không loại bỏ ảnh hưởng của ngoại lệ mà chỉ thay đổi thang đo dữ liệu.

Kết quả thống kê sau chuẩn hóa cho thấy cả ba biến age, bmi và children đều có 1.337 quan sát, giá trị trung bình xấp xỉ 0 và độ lệch chuẩn bằng 1, phù hợp với đặc điểm của phương pháp StandardScaler. Giá trị nhỏ nhất và lớn nhất của từng biến cũng được chuyển sang thang đo mới; chẳng hạn, biến bmi có giá trị từ -2,41 đến 3,68. Các giá trị âm thể hiện quan sát thấp hơn mức trung bình, còn giá trị dương thể hiện quan sát cao hơn mức trung bình.

Như vậy, bước chuẩn hóa giúp đưa ba biến số về cùng thang đo mà không làm thay đổi số lượng quan sát. Nhóm vẫn giữ nguyên charges để sử dụng làm biến mục tiêu và không chuẩn hóa các biến phân loại đã mã hóa. Bộ dữ liệu df_model sau bước này được chuẩn bị cho quá trình xây dựng mô hình ở giai đoạn tiếp theo.

11. Kiểm tra kết quả sau tiền xử lý dữ liệu

```
# KIỂM TRA KẾT QUẢ SAU TIỀN XỬ LÝ
print("df_clean (dùng cho Giai đoạn 3):", df_clean.shape)
print("   - Số giá trị thiếu:", df_clean.isnull().sum().sum())
print("   - Số dòng trùng lặp:", df_clean.duplicated().sum())
print("df_model (đã mã hóa và chuẩn hóa):", df_model.shape)
print("   - Các cột:", df_model.columns.tolist())
```

```
df_clean (dùng cho Giai đoạn 3): (1337, 7)
   - Số giá trị thiếu: 0
   - Số dòng trùng lặp: 0
df_model (đã mã hóa và chuẩn hóa): (1337, 9)
   - Các cột: ['age', 'sex', 'bmi', 'children', 'smoker', 'charges', 'region_northwest', 'region_southeast', 'region_southwest']
```

Sau khi hoàn thành các bước kiểm tra dữ liệu, xử lý trùng lặp, mã hóa biến phân loại và chuẩn hóa dữ liệu, nhóm tiến hành kiểm tra lại kết quả nhằm đánh giá mức độ hoàn thiện của bộ dữ liệu trước khi chuyển sang giai đoạn tiếp theo. Nhóm sử dụng các thuộc tính shape, isnull().sum().sum(), duplicated().sum() và columns.tolist() để kiểm tra kích thước, giá trị thiếu, dòng trùng lặp và danh sách biến của hai bộ dữ liệu df_clean và df_model.

Kết quả cho thấy, bộ dữ liệu df_clean dùng cho giai đoạn 3 có 1.337 quan sát và 7 biến, không còn giá trị thiếu và không còn dòng trùng lặp. So với dữ liệu ban đầu gồm 1.338 quan sát, bộ dữ liệu đã giảm một dòng sau khi loại bỏ bản ghi trùng lặp, trong khi các giá trị ngoại lệ của bmi và charges được giữ lại do chưa có đủ căn cứ xác định là lỗi dữ liệu.

Đối với bộ dữ liệu df_model phục vụ xây dựng mô hình, kết quả ghi nhận 1.337 quan sát và 9 biến. Số cột tăng từ 7 lên 9 do biến region được mã hóa thành ba biến giả, thay cho một biến ban đầu. Các biến sex và smoker đã được mã hóa nhị phân; ba biến age, bmi, children đã được chuẩn hóa, trong khi charges được giữ nguyên làm biến mục tiêu.

Như vậy, quá trình tiền xử lý đã loại bỏ các bản ghi trùng lặp, bảo đảm dữ liệu không còn giá trị thiếu và chuẩn bị hai bộ dữ liệu phục vụ những mục đích khác nhau. df_clean được giữ ở dạng ban đầu để phân tích và trực quan hóa, còn df_model đã được mã hóa và chuẩn hóa để chuẩn bị cho bước xây dựng mô hình dự báo chi phí bảo hiểm y tế.

III. Giai đoạn 3: Phân tích và trực quan hóa

3.1. Người hút thuốc có chi phí bảo hiểm cao hơn không?

Tình trạng hút thuốc là một trong những yếu tố hành vi có thể liên quan đáng kể đến chi phí y tế cá nhân. Về mặt lý thuyết, người hút thuốc có nguy cơ mắc một số bệnh lý về hô hấp, tim mạch và các vấn đề sức khỏe khác cao hơn, từ đó có khả năng phát sinh nhu cầu sử dụng dịch vụ y tế và chi phí điều trị lớn hơn. Trong lĩnh vực bảo hiểm, việc xác định sự khác biệt về chi phí giữa người hút thuốc và không hút thuốc có ý nghĩa quan trọng đối với hoạt động đánh giá rủi ro, phân loại khách hàng và xây dựng chính sách định phí.

Trên cơ sở bộ dữ liệu Medical Cost Personal Dataset đã được làm sạch ở Giai đoạn 2, nhóm nghiên cứu sử dụng hai biến gồm smoker (tình trạng hút thuốc) và charges (chi phí bảo hiểm y tế cá nhân, đơn vị USD) để đánh giá mức độ khác biệt về chi phí giữa hai nhóm khách hàng.

Câu hỏi nghiên cứu: Người hút thuốc có chi phí bảo hiểm y tế cao hơn người không hút thuốc hay không? Mức độ chênh lệch giữa hai nhóm là bao nhiêu và sự khác biệt này có ý nghĩa thống kê hay không?

Nhóm xây dựng cặp giả thuyết nghiên cứu:

Giả thuyết	Nội dung
$\mathbf{H_0}$	Chi phí bảo hiểm của người hút thuốc không cao hơn người

không hút thuốc.

$\mathbf{H}_1$	Chi phí bảo hiểm của người hút thuốc có xu hướng cao hơn người không hút thuốc.

Mức ý nghĩa thống kê được lựa chọn là $\alpha = 0,05$.

Do biến smoker là biến phân loại gồm hai nhóm độc lập, trong khi charges là biến định lượng có phân phối lệch phải và xuất hiện các quan sát chi phí cao, nhóm kết hợp thống kê mô tả, biểu đồ hộp, biểu đồ cột và các kiểm định thống kê phù hợp để đánh giá giả thuyết.

3.1.1. Thống kê mô tả chi phí bảo hiểm theo tình trạng hút thuốc

Trước khi tiến hành trực quan hóa và kiểm định giả thuyết, nhóm thực hiện thống kê mô tả biến charges theo từng trạng thái của biến smoker. Bước này nhằm xác định quy mô mẫu, mức chi phí trung bình, trung vị và độ phân tán của từng nhóm, từ đó nhận diện sơ bộ mức độ chênh lệch chi phí giữa người hút thuốc và không hút thuốc.

Nhóm sử dụng các câu lệnh Python sau:

- df_clean[df_clean['smoker'] == 'no']: Lọc các quan sát thuộc nhóm không hút thuốc.
- df_clean[df_clean['smoker'] == 'yes']: Lọc các quan sát thuộc nhóm hút thuốc.
- groupby('smoker'): Phân chia dữ liệu thành hai nhóm theo tình trạng hút thuốc.
- agg(): Tính đồng thời nhiều chỉ tiêu thống kê cho biến charges.
- count: Đếm số lượng quan sát trong từng nhóm.
- mean: Tính chi phí trung bình, phản ánh mức chi phí bình quân của nhóm.
- median: Tính trung vị, phản ánh mức chi phí điển hình và ít bị ảnh hưởng bởi các giá trị cực đoan.
- std: Tính độ lệch chuẩn, đánh giá mức độ phân tán chi phí.
- min, max: Xác định chi phí nhỏ nhất và lớn nhất.
- quantile(0.25) và quantile(0.75): Xác định Q1 và Q3, làm cơ sở đánh giá khoảng phân phối trung tâm của dữ liệu.
- round(2): Làm tròn kết quả đến hai chữ số thập phân.

```python
# Tách dữ liệu thành hai nhóm
non_smoker = df_clean[df_clean['smoker'] == 'no']['charges']
smoker = df_clean[df_clean['smoker'] == 'yes']['charges']

# Thống kê mô tả theo tình trạng hút thuốc
bang_smoker = df_clean.groupby('smoker')['charges'].agg(
    So_quan_sat='count',
    Trung_binh='mean',
    Trung_vi='median',
    Do_lech_chuan='std',
    Nho_nhat='min',
    Lon_nhat='max')

# Bổ sung các tứ phân vị
bang_smoker['Q1'] = df_clean.groupby('smoker')['charges'].quantile(0.25)
bang_smoker['Q3'] = df_clean.groupby('smoker')['charges'].quantile(0.75)

print("BẢNG 4.1. THỐNG KÊ CHI PHÍ BẢO HIỂM CỦA NGƯỜI HÚT THUỐC VÀ KHÔNG")
display(bang_smoker.round(2))
```

BẢNG 4.1. THỐNG KÊ CHI PHÍ BẢO HIỂM CỦA NGƯỜI HÚT THUỐC VÀ KHÔNG

smoker	So_quan_sat	Trung_binh	Trung_vi	Do_lech_chuan	Nho_nhat	Lon_nhat	Q1	Q3
no	1063	8440.66	7345.73	5992.97	1121.87	36910.61	3988.88	11363.02
yes	274	32050.23	34456.35	11541.55	12829.46	63770.43	20826.24	41019.21

Bảng 3.1.1 Thống kê chi phí bảo hiểm theo tình trạng hút thuốc

Kết quả thống kê cho thấy có sự khác biệt đáng kể về chi phí bảo hiểm giữa hai nhóm khách hàng. Cụ thể, nhóm không hút thuốc có 1.063 quan sát, trong khi nhóm hút thuốc có 274 quan sát. Mặc dù quy mô mẫu của nhóm hút thuốc nhỏ hơn đáng kể, chi phí bảo hiểm của nhóm này lại cao hơn rõ rệt.

Chi phí trung bình của nhóm hút thuốc đạt 32.050,23 USD, cao hơn 23.609,57 USD so với nhóm không hút thuốc (8.440,66 USD). Như vậy, chi phí trung bình của người hút thuốc cao gấp khoảng 3,80 lần người không hút thuốc, tương đương mức chênh lệch tăng khoảng 279,71%.

Đáng chú ý, sự khác biệt còn thể hiện rõ hơn khi xét theo trung vị. Nhóm hút thuốc có trung vị chi phí đạt 34.456,35 USD, trong khi nhóm không hút thuốc chỉ đạt 7.345,73 USD. Mức trung vị của nhóm hút thuốc cao gấp khoảng 4,69 lần nhóm không hút thuốc. Điều này cho thấy mức chi phí cao không chỉ xuất hiện do một số cá nhân có chi phí đặc biệt lớn mà còn phản ánh sự khác biệt đáng kể trong mức chi phí điển hình giữa hai nhóm.

Bên cạnh đó, độ lệch chuẩn của nhóm hút thuốc đạt 11.541,55 USD, gần gấp đôi mức 5.992,97 USD của nhóm không hút thuốc. Điều này cho thấy chi phí trong nhóm hút thuốc có mức độ biến động tuyệt đối lớn hơn, đồng thời phản ánh sự khác biệt đáng kể về quy mô chi phí giữa các cá nhân thuộc nhóm này.

Một điểm đáng chú ý khác là trung bình của nhóm không hút thuốc (8.440,66 USD) cao hơn trung vị (7.345,73 USD), cho thấy phân phối chi phí có xu hướng lệch phải. Ngược lại, ở nhóm hút thuốc, trung bình (32.050,23 USD) thấp hơn trung vị (34.456,35 USD). Đặc điểm này cho thấy không nên mặc định rằng cả hai nhóm đều có cùng hình dạng phân phối. Vì vậy, việc kết hợp trung bình, trung vị và biểu đồ hộp là cần thiết để đánh giá đầy đủ sự khác biệt.

Nhìn chung, thống kê mô tả cung cấp bằng chứng ban đầu cho thấy người hút thuốc có chi phí bảo hiểm cao hơn đáng kể so với người không hút thuốc. Tuy nhiên, các chỉ tiêu mô tả chưa đủ để xác định sự khác biệt này có ý nghĩa thống kê hay không. Do đó, nhóm tiếp tục sử dụng biểu đồ trực quan và kiểm định giả thuyết ở các bước tiếp theo.

3.1.2. Trực quan hóa sự khác biệt chi phí bảo hiểm bằng biểu đồ hộp (Boxplot)

Để đánh giá trực quan sự khác biệt về phân phối chi phí bảo hiểm giữa hai nhóm khách hàng, nhóm sử dụng biểu đồ hộp (Boxplot). Đây là loại biểu đồ phù hợp với mục tiêu so sánh một biến định lượng (charges) giữa hai nhóm phân loại (smoker).

Biểu đồ hộp cho phép quan sát đồng thời trung vị, khoảng tứ phân vị, mức độ phân tán và các quan sát ngoại lệ. Phương pháp này đặc biệt phù hợp với bộ dữ liệu nghiên cứu do chi phí bảo hiểm có phân phối lệch và tồn tại nhiều quan sát có giá trị lớn.

Nhóm sử dụng câu lệnh Python sau:

- plt.figure(figsize=(10, 6)): Thiết lập kích thước biểu đồ, giúp các thành phần được hiển thị rõ ràng.
- sns.boxplot(): Xây dựng biểu đồ hộp để so sánh phân phối chi phí giữa hai nhóm.
- data=df_clean: Sử dụng bộ dữ liệu đã được làm sạch ở Giai đoạn 2.
- x='smoker': Đưa tình trạng hút thuốc lên trục hoành để phân chia thành hai nhóm.
- y='charges': Đưa chi phí bảo hiểm lên trục tung để thể hiện mức độ phân bố chi phí.
- hue='smoker': Phân biệt hai nhóm bằng màu sắc.

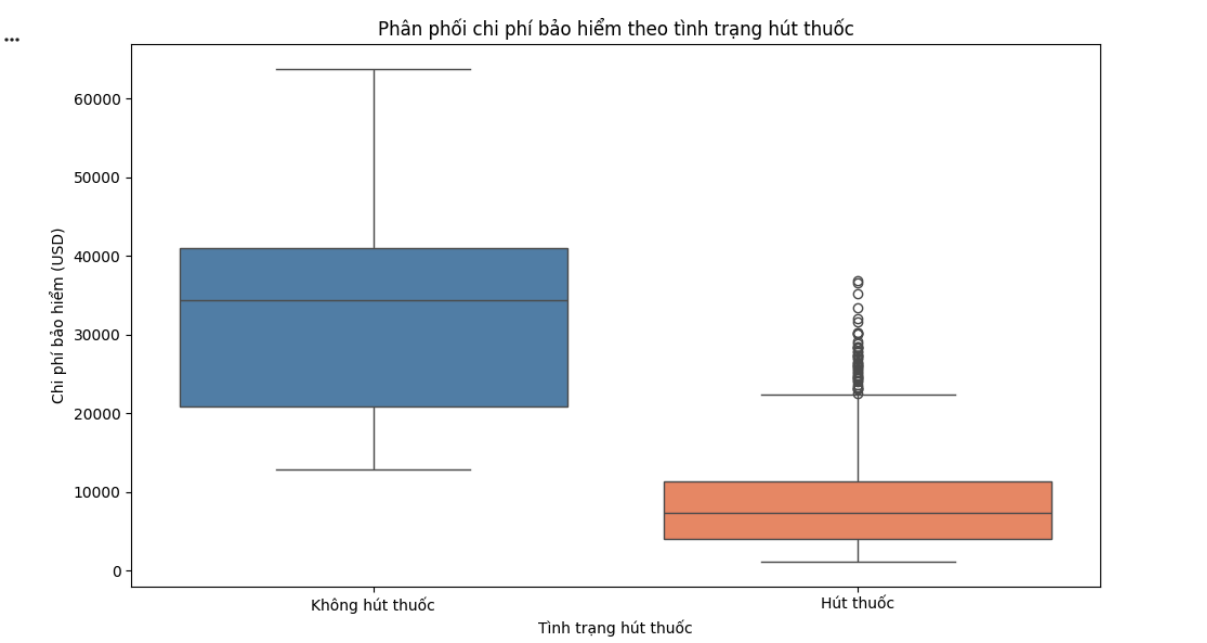
- palette: Thiết lập màu riêng cho từng nhóm nhằm tăng khả năng nhận diện.
- plt.title(), plt.xlabel() và plt.ylabel(): Bổ sung tiêu đề và tên các trục để làm rõ nội dung biểu đồ.
- plt.tight_layout(): Tự động điều chỉnh khoảng cách giữa các thành phần.
- plt.show(): Hiển thị biểu đồ sau khi hoàn thành.

```
plt.figure(figsize=(10, 6))

sns.boxplot(
    data=df_clean,
    x='smoker',
    y='charges',
    hue='smoker',
    palette=['steelblue', 'coral'],
    legend=False
)

plt.title('Phân phối chi phí bảo hiểm theo tình trạng hút thuốc')
plt.xlabel('Tình trạng hút thuốc')
plt.ylabel('Chi phí bảo hiểm (USD)')
plt.xticks([0, 1], ['Không hút thuốc', 'Hút thuốc'])

plt.tight_layout()
plt.show()
```



Hình 3.1.1. Phân phối chi phí bảo hiểm theo tình trạng hút thuốc

Kết quả trên biểu đồ hộp cho thấy phân phối charges của nhóm hút thuốc nằm ở mức cao hơn rõ rệt so với nhóm không hút thuốc. Trung vị của nhóm hút thuốc đạt 34.456,35 USD, trong khi nhóm không hút thuốc chỉ đạt 7.345,73 USD. Khoảng cách

lớn giữa hai đường trung vị cho thấy sự khác biệt về mức chi phí điển hình giữa hai nhóm khách hàng.

Xét về khoảng tứ phân vị, 50% quan sát trung tâm của nhóm hút thuốc nằm trong khoảng từ 20.826,24 đến 41.019,21 USD. Trong khi đó, nhóm không hút thuốc có khoảng tứ phân vị chỉ từ 3.988,88 đến 11.363,02 USD. Như vậy, ngay cả mức chi phí thuộc nhóm 25% thấp nhất của người hút thuốc cũng cao hơn đáng kể so với phần lớn mức chi phí trung tâm của nhóm không hút thuốc.

Đáng chú ý, khoảng tứ phân vị của hai nhóm gần như không chồng lấn. Điều này cho thấy sự khác biệt về chi phí không chỉ xuất phát từ một số quan sát cực đoan mà còn thể hiện tương đối rõ trong phần lớn dữ liệu của hai nhóm.

Bên cạnh đó, nhóm hút thuốc có khoảng phân bố chi phí cao hơn, với giá trị lớn nhất đạt 63.770,43 USD, so với 36.910,61 USD ở nhóm không hút thuốc. Điều này phản ánh sự xuất hiện của những khoản chi phí đặc biệt lớn trong nhóm hút thuốc.

Tuy nhiên, biểu đồ hộp chỉ phản ánh sự khác biệt về mặt phân phối trong mẫu nghiên cứu, chưa đủ cơ sở để khẳng định tình trạng hút thuốc là nguyên nhân trực tiếp làm tăng chi phí bảo hiểm. Vì vậy, nhóm tiếp tục sử dụng các kiểm định thống kê nhằm xác định mức độ tin cậy của sự khác biệt quan sát được.

3.1.3. So sánh chi phí trung bình và trung vị bằng biểu đồ cột (Bar Chart)

Sau khi quan sát sự khác biệt về phân phối chi phí thông qua biểu đồ hộp, nhóm tiếp tục sử dụng biểu đồ cột (Bar Chart) để lượng hóa mức chênh lệch giữa hai nhóm khách hàng. Biểu đồ được xây dựng dựa trên hai chỉ tiêu là chi phí trung bình (Mean) và chi phí trung vị (Median).

Việc sử dụng đồng thời hai chỉ tiêu giúp nhóm đánh giá sự khác biệt về chi phí từ hai góc độ. Trong đó, Mean phản ánh mức chi phí bình quân của toàn bộ nhóm khách hàng, còn Median phản ánh mức chi phí điển hình và ít chịu ảnh hưởng của các quan sát cực đoan.

Nhóm sử dụng câu lệnh Python sau:

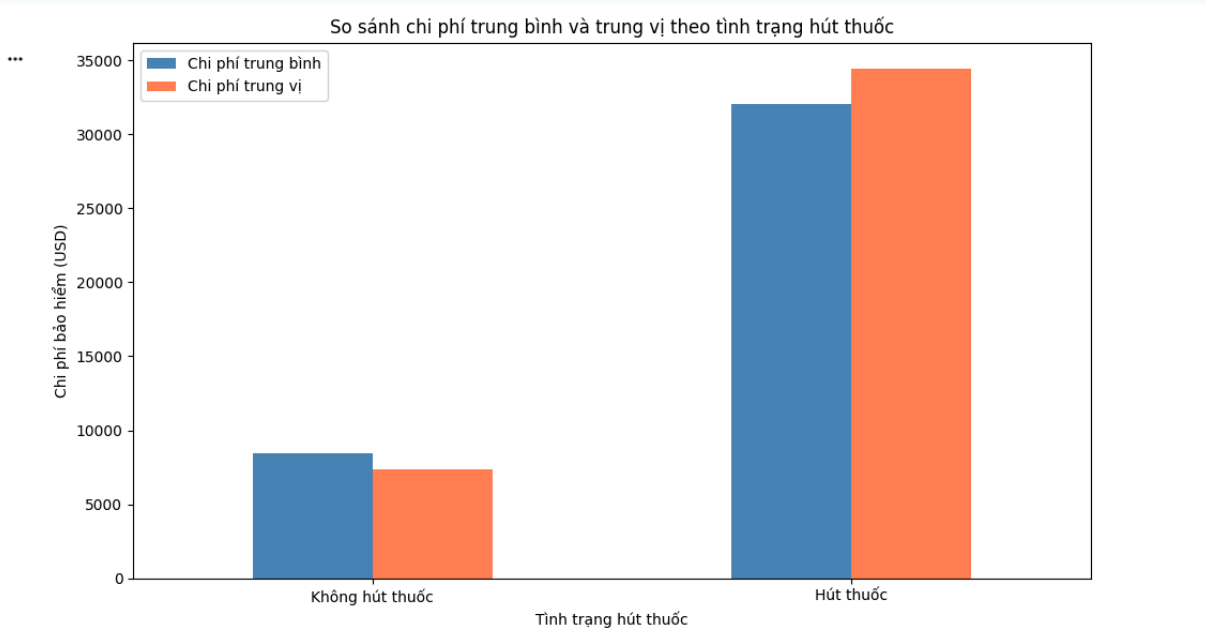
- groupby('smoker'): Chia dữ liệu thành hai nhóm theo tình trạng hút thuốc.
- agg(Mean='mean', Median='median'): Tính đồng thời chi phí trung bình và trung vị của từng nhóm.
- plot(kind='bar'): Xây dựng biểu đồ cột để so sánh trực tiếp các chỉ tiêu giữa hai nhóm.
- figsize=(10, 6): Thiết lập kích thước biểu đồ.
- color: Quy định màu sắc khác nhau cho hai chỉ tiêu.

- plt.legend(): Bổ sung chú thích giúp phân biệt Mean và Median.
- plt.xticks(): Đặt tên cho hai nhóm khách hàng trên trục hoành.
- plt.tight_layout() và plt.show(): Điều chỉnh bố cục và hiển thị biểu đồ.

```
# Tính trung bình và trung vị theo nhóm
bang_ve = df_clean.groupby('smoker')['charges'].agg(
    Mean='mean',
    Median='median'
)

# Vẽ biểu đồ cột
bang_ve.plot(
    kind='bar',
    figsize=(10, 6),
    color=['steelblue', 'coral']
)

plt.title('So sánh chi phí trung bình và trung vị theo tình trạng hút thuốc')
plt.xlabel('Tình trạng hút thuốc')
plt.ylabel('Chi phí bảo hiểm (USD)')
plt.xticks([0, 1], ['Không hút thuốc', 'Hút thuốc'], rotation=0)
plt.legend(['Chi phí trung bình', 'Chi phí trung vị'])
plt.tight_layout()
plt.show()
```



Hình 3.1.2. So sánh chi phí trung bình và trung vị theo tình trạng hút thuốc

Kết quả biểu đồ cho thấy cả chi phí trung bình và trung vị của nhóm hút thuốc đều cao hơn đáng kể so với nhóm không hút thuốc. Cụ thể, chi phí trung bình của nhóm hút thuốc đạt 32.050,23 USD, trong khi nhóm không hút thuốc chỉ đạt 8.440,66 USD. Chênh lệch tuyệt đối là 23.609,57 USD, tương đương khoảng 3,80 lần.

Đối với chỉ tiêu trung vị, mức chi phí của nhóm hút thuốc đạt 34.456,35 USD, cao gấp khoảng 4,69 lần so với mức 7.345,73 USD của nhóm không hút thuốc. Đáng chú ý, tỷ lệ chênh lệch theo trung vị lớn hơn tỷ lệ chênh lệch theo trung bình. Điều này cho thấy mức chi phí điển hình giữa hai nhóm có sự phân hóa rất rõ rệt.

Một điểm đáng quan tâm là ở nhóm hút thuốc, trung bình thấp hơn trung vị khoảng 2.406,12 USD. Ngược lại, ở nhóm không hút thuốc, trung bình cao hơn trung vị khoảng 1.094,93 USD. Sự khác biệt này cho thấy hình dạng phân phối chi phí của hai nhóm không giống nhau. Vì vậy, việc chỉ sử dụng chi phí trung bình có thể chưa phản ánh đầy đủ đặc điểm chi phí điển hình của từng nhóm.

Nhìn chung, biểu đồ cột củng cố kết quả từ biểu đồ hộp và bảng thống kê mô tả. Người hút thuốc có mức chi phí bảo hiểm cao hơn đáng kể trên cả phương diện bình quân và trung vị. Tuy nhiên, để xác định sự khác biệt này có đủ bằng chứng thống kê trong tổng thể hay không, nhóm tiếp tục thực hiện kiểm định giả thuyết.

3.1.4. Kiểm định giả thuyết về sự khác biệt chi phí bảo hiểm giữa hai nhóm: hút thuốc và không

Các kết quả thống kê mô tả và biểu đồ trực quan cho thấy chi phí bảo hiểm của người hút thuốc cao hơn rõ rệt so với người không hút thuốc. Tuy nhiên, sự khác biệt quan sát được trong mẫu có thể chịu ảnh hưởng của biến động ngẫu nhiên. Vì vậy, nhóm tiến hành kiểm định thống kê nhằm xác định liệu có đủ bằng chứng để kết luận chi phí bảo hiểm của nhóm hút thuốc cao hơn trong tổng thể hay không.

Trước tiên, nhóm kiểm tra đặc điểm phân phối và sự đồng nhất phương sai giữa hai nhóm. Sau đó, Mann–Whitney U được lựa chọn làm kiểm định chính để so sánh thứ hạng chi phí, kết hợp Welch's t-test để đánh giá sự khác biệt về giá trị trung bình.

Nhóm sử dụng các câu lệnh Python sau:

- stats.skew(): Tính hệ số độ lệch (Skewness), giúp đánh giá mức độ bất đối xứng trong phân phối chi phí của từng nhóm.
- stats.levene(): Kiểm định giả thuyết hai nhóm có phương sai bằng nhau hay không.
- center='median': Sử dụng trung vị làm tâm trong kiểm định Levene, giúp giảm độ nhạy với các giá trị cực đoan.
- stats.mannwhitneyu(): Thực hiện kiểm định Mann–Whitney U để so sánh thứ hạng phân phối chi phí giữa hai nhóm độc lập.
- alternative='greater': Kiểm định một phía, trong đó giả thuyết đối là chi phí của nhóm hút thuốc có xu hướng cao hơn nhóm không hút thuốc.

- rank_biserial: Tính hệ số tương quan thứ hạng, bổ sung thông tin về mức độ khác biệt giữa hai nhóm.
- stats.ttest_ind(): Thực hiện kiểm định t hai mẫu độc lập để đánh giá sự khác biệt về trung bình.
- equal_var=False: Sử dụng Welch's t-test, không yêu cầu phương sai của hai nhóm bằng nhau.
- alpha = 0.05: Thiết lập mức ý nghĩa thống kê 5%.

```python
from scipy import stats
import numpy as np

alpha = 0.05

# 1. Kiểm định Mann-Whitney U
u_stat, mw_p = stats.mannwhitneyu(
    smoker, non_smoker, alternative='greater'
)

rank_biserial = 2*u_stat/(len(smoker)*len(non_smoker))-1

# 2. Kiểm định Welch's t-test
t_stat, t_p = stats.ttest_ind(
    smoker, non_smoker,
    equal_var=False, alternative='greater'
)

# Khoảng tin cậy 95%
a = smoker.var(ddof=1)/len(smoker)
b = non_smoker.var(ddof=1)/len(non_smoker)

df_w = (a+b)**2/(a**2/(len(smoker)-1)+b**2/(len(non_smoker)-1))
se = np.sqrt(a+b)
t_crit = stats.t.ppf(0.975, df_w)

diff = smoker.mean()-non_smoker.mean()

# 3. In kết quả kiểm định
print("KẾT QUẢ KIỂM ĐỊNH")
print("-"*50)
print(f"Mann-Whitney U: {u_stat:,.2f}")
print(f"P-value: {mw_p:.6e}")
print(f"Rank-biserial: {rank_biserial:.4f}")
print(f"Welch's t-test: {t_stat:.4f}")
print(f"P-value: {t_p:.6e}")
print(f"Khoảng tin cậy 95%: [{diff-t_crit*se:,.2f}; {diff+t_crit*se:,.2f}] USD")
```

```
KẾT QUẢ KIỂM ĐỊNH
--------------------------------------------------
Mann-Whitney U: 283,859.00
P-value: 2.873506e-130
Rank-biserial: 0.9492
Welch's t-test: 32.7423
P-value: 3.130860e-103
Khoảng tin cậy 95%: [22,190.79; 25,028.35] USD

KẾT LUẬN:
Bác bỏ H0.
```

Kết quả kiểm tra Skewness cho thấy phân phối chi phí của nhóm không hút thuốc có hệ số lệch 1,538, phản ánh phân phối lệch phải tương đối rõ. Trong khi đó, nhóm hút thuốc có hệ số lệch 0,128, cho thấy phân phối gần đối xứng hơn. Như vậy, hai nhóm có hình dạng phân phối khác nhau và không phù hợp để mặc định sử dụng các phương pháp so sánh dựa trên giả định phân phối chuẩn giống nhau.

Bên cạnh đó, kiểm định Levene cho giá trị thống kê 332,4714 với p-value nhỏ hơn 0,001. Do p-value thấp hơn mức ý nghĩa 0,05, nhóm bác bỏ giả thuyết phương sai hai nhóm bằng nhau. Điều này cho thấy mức độ biến động chi phí giữa người hút thuốc và không hút thuốc không đồng nhất. Vì vậy, khi so sánh chi phí trung bình, nhóm lựa chọn Welch's t-test thay vì kiểm định t hai mẫu độc lập truyền thống với giả định phương sai bằng nhau.

Đối với kiểm định Mann–Whitney U, kết quả thu được giá trị U = 283.859,00 và p-value = $2{,}873506 \times 10^{-130}$. Giá trị p-value nhỏ hơn rất nhiều so với mức ý nghĩa 0,05. Do đó, nhóm bác bỏ giả thuyết H_0 và kết luận có đủ bằng chứng thống kê cho thấy chi phí bảo hiểm của người hút thuốc có xu hướng cao hơn người không hút thuốc.

Đáng chú ý, hệ số Rank-biserial correlation đạt 0,9492, thể hiện mức độ khác biệt về thứ hạng rất lớn giữa hai nhóm. Kết quả này cho thấy sự khác biệt không chỉ có ý nghĩa về mặt thống kê mà còn có quy mô đáng kể trong mẫu nghiên cứu.

Bên cạnh đó, kết quả Welch's t-test ghi nhận thống kê t = 32,7423 và p-value = $3{,}130860 \times 10^{-103}$, tiếp tục cung cấp bằng chứng rất mạnh về sự khác biệt theo hướng chi phí trung bình của nhóm hút thuốc cao hơn. Khoảng tin cậy 95% của chênh lệch trung bình giữa hai nhóm nằm trong khoảng từ 22.190,79 đến 25.028,35 USD. Toàn bộ khoảng tin cậy đều lớn hơn 0, cho thấy mức chênh lệch chi phí trung bình được ước lượng là dương và có ý nghĩa thống kê.

Như vậy, cả Mann–Whitney U và Welch's t-test đều ủng hộ giả thuyết nghiên cứu. Đặc biệt, việc kết hợp hai phương pháp giúp nhóm đánh giá sự khác biệt trên cả phương diện phân phối thứ hạng và giá trị trung bình, hạn chế sự phụ thuộc vào một phương pháp kiểm định duy nhất.

3.1.5. Phân tích các quan sát có chi phí cao theo tình trạng hút thuốc

Kết quả phân tích ở các mục trước cho thấy nhóm hút thuốc có mức chi phí bảo hiểm cao hơn đáng kể. Tuy nhiên, một vấn đề cần được xem xét là liệu những quan sát có chi phí đặc biệt cao có tập trung chủ yếu trong nhóm khách hàng hút thuốc hay không.

Ở Giai đoạn 2, nhóm đã xác định 139 quan sát ngoại lệ tiềm năng của biến charges theo quy tắc IQR, với cận trên là 34.524,78 USD. Do chi phí bảo hiểm là biến phản ánh giá trị thực tế phát sinh, những quan sát có giá trị lớn không nhất thiết là lỗi nhập liệu. Vì vậy, nhóm tiếp tục phân tích các quan sát này theo tình trạng hút thuốc để đánh giá đặc điểm của nhóm khách hàng có chi phí cao.

Nhóm sử dụng câu lệnh Python sau:

- quantile(0.25): Tính tứ phân vị thứ nhất Q1 của biến charges.
- quantile(0.75): Tính tứ phân vị thứ ba Q3.
- iqr = q3 - q1: Xác định khoảng tứ phân vị IQR.
- upper_bound = q3 + 1.5 * iqr: Tính cận trên để xác định các quan sát có chi phí cao theo quy tắc IQR.
- chi_phi_cao: Tạo biến điều kiện, nhận giá trị True đối với những quan sát có chi phí vượt ngưỡng.
- groupby('smoker'): Phân chia quan sát theo tình trạng hút thuốc.
- sum(): Đếm số quan sát thỏa mãn điều kiện chi phí cao trong từng nhóm.
- Ty_le (%): Tính tỷ lệ quan sát có chi phí cao trên tổng số quan sát của từng nhóm.

```python
# 4. PHÂN TÍCH CHI PHÍ CAO THEO IQR

q1 = df_clean['charges'].quantile(0.25)
q3 = df_clean['charges'].quantile(0.75)
iqr = q3 - q1
upper_bound = q3 + 1.5 * iqr

# Xác định các quan sát có chi phí cao theo ngưỡng IQR
chi_phi_cao = df_clean['charges'] > upper_bound

# Thống kê số lượng và tỷ lệ chi phí cao theo tình trạng hút thuốc
outlier_summary = df_clean.groupby('smoker').agg(
    Tong_quan_sat=('charges', 'count'))
outlier_summary['Chi_phi_cao'] = chi_phi_cao.groupby(df_clean['smoker']).sum()
outlier_summary['Ty_le (%)'] = (
    outlier_summary['Chi_phi_cao'] / outlier_summary['Tong_quan_sat'] * 100)

print(f"Q1: {q1:,.2f} USD")
print(f"Q3: {q3:,.2f} USD")
print(f"IQR: {iqr:,.2f} USD")
print(f"Ngưỡng chi phí cao: {upper_bound:,.2f} USD")

print("\nBẢNG PHÂN TÍCH CHI PHÍ CAO")
display(outlier_summary.round(2))

# Tỷ trọng người hút thuốc trong tổng số quan sát có chi phí cao
total_high = int(chi_phi_cao.sum())
high_yes = int(((df_clean['smoker'] == 'yes') & chi_phi_cao).sum())

print(f"\nTổng số quan sát chi phí cao: {total_high}")
if total_high > 0:
    print(f"Số người hút thuốc: {high_yes}")
    print(f"Tỷ lệ người hút thuốc trong nhóm chi phí cao: {high_yes / total_high * 100:.2f}%")
```

```
Q1: 4,746.34 USD
Q3: 16,657.72 USD
IQR: 11,911.37 USD
Ngưỡng chi phí cao: 34,524.78 USD

BẢNG PHÂN TÍCH CHI PHÍ CAO
```

smoker	Tong_quan_sat	Chi_phi_cao	Ty_le (%)
no	1063	3	0.28
yes	274	136	49.64

```
Tổng số quan sát chi phí cao: 139
Số người hút thuốc: 136
Tỷ lệ người hút thuốc trong nhóm chi phí cao: 97.84%
```

Bảng 3.1.2. Phân bố các quan sát có chi phí cao theo tình trạng hút thuốc

Kết quả cho thấy trong tổng số 139 quan sát có chi phí vượt ngưỡng IQR, có đến 136 quan sát thuộc nhóm hút thuốc, chiếm 97,84%. Trong khi đó, nhóm không hút thuốc chỉ ghi nhận 3 quan sát, tương ứng 2,16% tổng số trường hợp có chi phí cao.

Đáng chú ý, khi xét trong từng nhóm, có 49,64% khách hàng hút thuốc có chi phí vượt ngưỡng 34.524,78 USD. Ngược lại, tỷ lệ tương ứng ở nhóm không hút thuốc chỉ đạt 0,28%. Chênh lệch này cho thấy các khoản chi phí đặc biệt cao tập trung rất mạnh ở nhóm khách hàng hút thuốc.

Đây là một phát hiện quan trọng vì nó bổ sung bằng chứng cho kết quả thống kê mô tả và kiểm định ở những phần trước. Không chỉ có mức trung bình và trung vị cao hơn, nhóm hút thuốc còn chiếm gần như toàn bộ các quan sát vượt ngưỡng chi phí cao. Điều này cho thấy tình trạng hút thuốc là một đặc điểm phân nhóm có liên hệ rất rõ với sự phân hóa chi phí trong bộ dữ liệu.

Một điểm cần lưu ý là ngưỡng IQR chỉ xác định những quan sát khác biệt đáng kể so với phân phối chung, chứ không khẳng định các giá trị đó là sai lệch. Việc phần lớn các quan sát chi phí cao thuộc nhóm hút thuốc, đồng thời các bản ghi vẫn có đầy đủ đặc điểm cá nhân, cho thấy chưa có căn cứ để loại bỏ chúng một cách máy móc.

Trên cơ sở đó, nhóm tiếp tục giữ lại các quan sát chi phí cao trong bộ dữ liệu phân tích. Việc loại bỏ toàn bộ những trường hợp này có thể làm mất đi thông tin quan trọng về nhóm khách hàng hút thuốc, đồng thời làm thay đổi đáng kể phân phối chi phí và ảnh hưởng đến kết quả của những phân tích tiếp theo.

Tuy nhiên, cần nhấn mạnh rằng kết quả này mới phản ánh mối liên hệ giữa tình trạng hút thuốc và sự xuất hiện của chi phí cao. Để đánh giá vai trò độc lập của hút

thuốc, cần tiếp tục xem xét các yếu tố khác như tuổi, BMI và những đặc điểm sức khỏe của khách hàng.

3.1.6. Kết luận

Kết quả phân tích cho thấy giả thuyết ban đầu được ủng hộ: người hút thuốc có chi phí bảo hiểm y tế cao hơn đáng kể so với người không hút thuốc. Sự khác biệt này được thể hiện nhất quán qua thống kê mô tả, trực quan hóa và các kiểm định giả thuyết.

Trước hết, chi phí trung bình của nhóm hút thuốc đạt 32.050,23 USD, cao gấp khoảng 3,80 lần so với nhóm không hút thuốc (8.440,66 USD). Nếu xét theo trung vị, mức chênh lệch còn lớn hơn khi chi phí điển hình của nhóm hút thuốc đạt 34.456,35 USD, cao gấp khoảng 4,69 lần nhóm không hút thuốc (7.345,73 USD). Điều này cho thấy sự khác biệt không chỉ xuất phát từ một số cá nhân có chi phí đặc biệt cao mà còn thể hiện rõ trong phần lớn khách hàng thuộc hai nhóm.

Kết quả kiểm định Mann–Whitney U ghi nhận p-value = $2{,}873506 \times 10^{-130}$, nhỏ hơn mức ý nghĩa 0,05. Đồng thời, hệ số Rank-biserial correlation đạt 0,9492, phản ánh mức độ khác biệt về thứ hạng rất lớn giữa hai nhóm. Kiểm định Welch's t-test cũng cho kết quả có ý nghĩa thống kê với p-value = $3{,}130860 \times 10^{-103}$. Như vậy, các kết quả kiểm định đều cung cấp bằng chứng mạnh ủng hộ nhận định rằng nhóm hút thuốc có chi phí bảo hiểm cao hơn.

Một phát hiện quan trọng khác là trong tổng số 139 quan sát có chi phí vượt ngưỡng IQR 34.524,78 USD, có đến 136 quan sát thuộc nhóm hút thuốc, chiếm 97,84%. Trong khi đó, nhóm không hút thuốc chỉ có 3 quan sát. Điều này cho thấy các trường hợp có chi phí đặc biệt cao tập trung chủ yếu ở nhóm khách hàng hút thuốc, qua đó củng cố thêm nhận định về sự phân hóa chi phí theo đặc điểm hành vi cá nhân.

Về ý nghĩa ứng dụng, kết quả nghiên cứu gợi ý rằng tình trạng hút thuốc là một đặc điểm quan trọng cần được doanh nghiệp bảo hiểm quan tâm trong quá trình đánh giá rủi ro và phân tích chi phí y tế. Việc nhận diện nhóm khách hàng hút thuốc có mức chi phí cao có thể hỗ trợ doanh nghiệp xây dựng các mô hình dự báo chi phí, phân loại nhóm rủi ro và thiết kế những chương trình quản lý sức khỏe phù hợp hơn.

Mặc dù vậy, nghiên cứu vẫn tồn tại một số giới hạn cần được xem xét. Thứ nhất, dữ liệu mang tính quan sát và cắt ngang, do đó chưa đủ cơ sở để khẳng định tình trạng hút thuốc trực tiếp gây ra mức tăng chi phí tương ứng. Thứ hai, chi phí bảo hiểm còn có thể chịu ảnh hưởng của nhiều yếu tố khác như tuổi, BMI, bệnh lý nền và đặc điểm sức khỏe cá nhân. Thứ ba, các kiểm định được thực hiện trên từng nhóm riêng biệt, chưa kiểm soát đồng thời ảnh hưởng của tất cả các biến độc lập.

Do đó, những phát hiện từ phân tích này nên được xem là bằng chứng về mối liên hệ thống kê giữa tình trạng hút thuốc và chi phí bảo hiểm, thay vì bằng chứng khẳng định quan hệ nhân quả. Việc mở rộng nghiên cứu bằng mô hình hồi quy đa biến có thể giúp đánh giá rõ hơn vai trò của tình trạng hút thuốc khi đồng thời kiểm soát các đặc điểm cá nhân khác.

3.2. Chi phí bảo hiểm thay đổi thế nào theo độ tuổi?

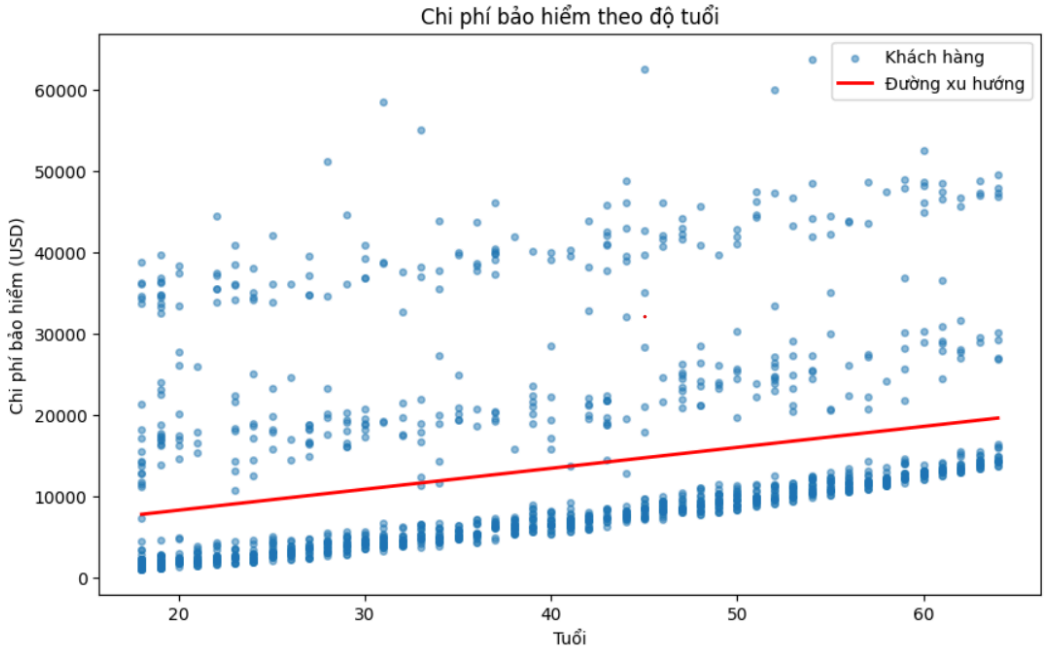
Tuổi tác thường được coi là một trong những yếu tố rủi ro cơ bản trong bảo hiểm y tế, vì nguy cơ mắc bệnh và nhu cầu sử dụng dịch vụ y tế có xu hướng tăng theo tuổi. Từ đó, giả thuyết ban đầu được đặt ra là chi phí bảo hiểm y tế tăng dần theo độ tuổi của khách hàng. Hai biến được sử dụng là age (tuổi) và charges (chi phí bảo hiểm, đơn vị USD), lấy từ bộ dữ liệu df_clean đã được làm sạch ở Giai đoạn 2. Cả hai đều là biến định lượng liên tục, nên biểu đồ phân tán (scatter plot) là lựa chọn phù hợp. Loại biểu đồ này cho phép quan sát đồng thời ba khía cạnh: xu hướng biến động chung, mức độ phân tán của dữ liệu và vị trí các quan sát có chi phí cao.

3.2.1: Biểu đồ phân tán giữa tuổi và chi phí bảo hiểm

```
# GIAI ĐOẠN 3 – BẢNG 2: CHI PHÍ BẢO HIỂM THEO ĐỘ TUỔI
# Scatter plot tuổi – chi phí (dùng df_clean đã làm sạch ở Giai đoạn 2)
plt.figure(figsize=(10, 6))
plt.scatter(df_clean['age'], df_clean['charges'],
            alpha=0.5, s=15, label='Khách hàng')

# Đường xu hướng tuyến tính: chi phí = độ dốc x tuổi + hệ số chặn
do_doc, he_so_chan = np.polyfit(df_clean['age'], df_clean['charges'], 1)
truc_tuoi = np.arange(18, 65)
plt.plot(truc_tuoi, do_doc * truc_tuoi + he_so_chan,
         color='red', linewidth=2, label='Đường xu hướng')

plt.title('Chi phí bảo hiểm theo độ tuổi')
plt.xlabel('Tuổi'); plt.ylabel('Chi phí bảo hiểm (USD)'); plt.legend()
plt.show()
print(f"Chi phí = {do_doc:,.2f} x tuổi + {he_so_chan:,.2f}")
```




```
Chi phí = 257.23 x tuổi + 3,190.02
```

Biểu đồ được xây dựng bằng hàm plt.scatter(). Mỗi điểm trên biểu đồ đại diện cho một khách hàng, trục hoành thể hiện tuổi, trục tung thể hiện chi phí bảo hiểm. Tham số alpha=0.5 làm các điểm trong suốt một phần, nhờ đó có thể nhận biết những vùng tập trung nhiều quan sát. Đường xu hướng tuyến tính được ước lượng bằng hàm np.polyfit() theo phương pháp bình phương nhỏ nhất, với hệ số bậc 1 (độ dốc) phản ánh mức thay đổi trung bình của chi phí khi tuổi tăng thêm một năm. Phương trình đường xu hướng thu được là: chi phí = 257,23 × tuổi + 3.190,02. Như vậy, xét trên toàn bộ mẫu, mỗi năm tuổi tăng thêm gắn với mức chi phí bảo hiểm cao hơn trung bình khoảng 257,23 USD. Đường xu hướng có độ dốc dương, phù hợp với giả thuyết ban đầu. Tuy nhiên, đường xu hướng này mô tả dữ liệu chưa tốt. Các quan sát không

phân tán ngẫu nhiên quanh đường thẳng mà tách thành ba dải gần như song song, và cả ba dải đều có xu hướng đi lên theo tuổi:

- Dải thấp: khoảng 1.000-16.000 USD.
- Dải giữa: khoảng 13.000-30.000 USD.
- Dải cao: khoảng 33.000-63.000 USD.

Đường xu hướng chung lại đi qua khoảng trống giữa dải thấp và dải giữa, là vùng có rất ít quan sát thực tế. Ngoài ra, mức chênh lệch chi phí giữa những khách hàng cùng độ tuổi rất lớn: ở tuổi 18, chi phí dao động từ khoảng 1.100 USD đến gần 40.000 USD. Biểu đồ vì vậy gợi ý rằng tuổi có liên hệ với chi phí, nhưng tuổi không phải là yếu tố duy nhất, cũng không phải yếu tố chủ yếu quyết định sự khác biệt về chi phí giữa các khách hàng.

3.2.2: Kiểm định giả thuyết về mối tương quan giữa tuổi và chi phí

```
# Kiểm định giả thuyết, mức ý nghĩa 5%
# H0: tuổi và chi phí không tương quan; H1: có tương quan
from scipy import stats
# Pearson: tương quan tuyến tính; Spearman: tương quan đơn điệu
r_p, p_p = stats.pearsonr(df_clean['age'], df_clean['charges'])
r_s, p_s = stats.spearmanr(df_clean['age'], df_clean['charges'])
print(f"Pearson : r = {r_p:.3f}, p-value = {p_p:.2e}")
print(f"Spearman: rho = {r_s:.3f}, p-value = {p_s:.2e}")
print("=> Bác bỏ H0" if max(p_p, p_s) < 0.05 else "=> Chưa bác bỏ H0")
```

```
Pearson : r = 0.298, p-value = 6.98e-29
Spearman: rho = 0.534, p-value = 3.19e-99
=> Bác bỏ H0
```

Để kiểm chứng nhận định từ biểu đồ bằng thống kê, cặp giả thuyết sau được đặt ra với mức ý nghĩa $\alpha = 0{,}05$:

- H0: Tuổi và chi phí bảo hiểm không có tương quan.
- H1: Tuổi và chi phí bảo hiểm có tương quan.

Hai hệ số tương quan được sử dụng để bổ trợ cho nhau:

- Hệ số Pearson (hàm stats.pearsonr) đo mức độ quan hệ tuyến tính giữa hai biến.
- Hệ số Spearman (hàm stats.spearmanr) được tính trên thứ hạng của dữ liệu. Hệ số này đo quan hệ đơn điệu, khi đó tuổi tăng thì chi phí có xu hướng tăng, không nhất thiết theo một đường thẳng. Nhờ tính trên thứ hạng, Spearman ít bị chi phối bởi các giá trị cực trị hơn Pearson.

Kết quả kiểm định:

Hệ số	Giá trị	p-value
Pearson (r)	0,298	$6{,}98 \times 10^{-29}$
Spearman (ρ)	0,534	$3{,}19 \times 10^{-99}$

Cả hai p-value đều nhỏ hơn nhiều so với 0,05, do đó bác bỏ H0: tuổi và chi phí bảo hiểm có tương quan dương với ý nghĩa thống kê. Tuy nhiên, có ý nghĩa thống kê không đồng nghĩa với tương quan mạnh. Theo thang đánh giá của Cohen, hệ số $r \approx 0{,}3$ chỉ ở mức trung bình thấp. Hệ số xác định $r^2 = 0{,}298^2 \approx 0{,}089$ cho thấy mối quan hệ tuyến tính với tuổi chỉ giải thích được khoảng 8,9% sự biến động của chi phí bảo hiểm. Bên cạnh đó, hệ số Spearman (0,534) cao hơn đáng kể so với Pearson (0,298). Điều này cho thấy mối quan hệ giữa tuổi và chi phí mang tính đơn điệu rõ hơn tính tuyến tính. Nguyên nhân là các quan sát ở dải chi phí cao làm sai lệch đường thẳng ước lượng. Khi dữ liệu được chuyển sang thứ hạng, ảnh hưởng của các giá trị này giảm đi. Kết quả định lượng này nhất quán với cấu trúc ba dải đã quan sát ở biểu đồ 3.2.1.

3.2.3: Chi phí bảo hiểm theo nhóm tuổi

```python
# Thống kê chi phí theo 4 nhóm tuổi (biến riêng, không thêm cột vào df_clean)
nhom_tuoi = pd.cut(df_clean['age'], bins=[17, 29, 39, 49, 64],
                   labels=['18-29', '30-39', '40-49', '50-64'])
tk = df_clean.groupby(nhom_tuoi, observed=True)['charges'].agg(
    ['count', 'mean', 'median', 'std', 'min', 'max']).round(2)
display(tk)
# So sánh nhóm 50-64 với nhóm 18-29
gap = tk.loc['50-64'] / tk.loc['18-29']
print("Trung vị gấp:", round(gap['median'], 2), "lần")
print("Trung bình gấp:", round(gap['mean'], 2), "lần")
```

age	count	mean	median	std	min	max
18-29	416	9200.62	3220.37	11473.33	1121.87	51194.56
30-39	257	11738.78	6082.40	11789.07	3260.20	58571.07
40-49	279	14399.20	8606.22	11639.98	5415.66	62592.87
50-64	385	17902.55	12629.90	11631.77	8442.67	63770.43

```
Trung vị gấp: 3.92 lần
Trung bình gấp: 1.95 lần
```

Để định lượng cụ thể mức thay đổi chi phí, biến tuổi được chia thành bốn nhóm theo thập niên (18-29, 30-39, 40-49 và 50-64) bằng hàm pd.cut(). Sau đó, hàm groupby().agg() được dùng để tính các chỉ tiêu thống kê mô tả của chi phí trong từng nhóm. Biến phân nhóm nhom_tuoi được lưu riêng, không bổ sung vào df_clean, nhằm giữ nguyên cấu trúc dữ liệu cho các phân tích khác.

Nhóm tuổi	Số quan sát	Trung vị (USD)	Trung bình (USD)	Độ lệch chuẩn (USD)	Giá trị nhỏ nhất (USD)
18-29	416	3.220,37	9.200,62	11.473,33	1.121,87
30-39	257	6.082,40	11.738,78	11.789,07	3.260,20
40-49	279	8.606,22	14.399,20	11.639,98	5.415,66
50-64	385	12.629,90	17.902,55	11.631,77	8.442,67

Kết quả cho thấy cả trung vị và trung bình đều tăng liên tục qua các nhóm tuổi, củng cố giả thuyết ban đầu. Bảng số liệu có bốn điểm đáng chú ý. Thứ nhất, mức độ tăng phụ thuộc vào thước đo được sử dụng. Trung vị chi phí của nhóm 50-64 tuổi gấp 3,92 lần nhóm 18-29 tuổi, trong khi tỷ lệ này tính theo trung bình chỉ là 1,95 lần. Sự khác biệt bắt nguồn từ việc trung bình của nhóm trẻ tuổi bị kéo lên bởi một số ít quan sát có chi phí rất cao: trung bình nhóm 18-29 tuổi (9.200,62 USD) gấp gần ba lần trung vị (3.220,37 USD). Do phân phối chi phí lệch phải, trung vị là thước đo phản ánh mức chi phí của một khách hàng điển hình chính xác hơn.

Thứ hai, mức chi phí tối thiểu tăng rõ rệt theo tuổi. Giá trị nhỏ nhất tăng từ 1.121,87 USD ở nhóm 18-29 lên 8.442,67 USD ở nhóm 50-64. Nói cách khác, trong mẫu nghiên cứu không có khách hàng nào từ 50 tuổi trở lên có chi phí dưới 8.442,67 USD. Đây là bằng chứng rõ ràng nhất cho thấy tuổi gắn liền với sự gia tăng mức chi phí cơ bản của mọi khách hàng. Thứ ba, độ phân tán tuyệt đối gần như không đổi giữa các nhóm tuổi. Độ lệch chuẩn ở cả bốn nhóm đều dao động quanh mức 11.500-11.800 USD. Nếu tuổi là nguồn gốc chính tạo ra chênh lệch chi phí giữa các khách hàng, độ phân tán phải thay đổi rõ rệt theo nhóm tuổi. Việc độ phân tán ổn định cho thấy chênh

lệch chi phí trong nội bộ từng nhóm tuổi chủ yếu do một yếu tố khác gây ra, và yếu tố này tác động với cường độ tương tự ở mọi lứa tuổi.

Thứ tư, kết quả có thể được đối chiếu với thực tiễn quản lý bảo hiểm tại Hoa Kỳ. Đạo luật Chăm sóc Sức khỏe Hợp túi tiền (Affordable Care Act - ACA) giới hạn phí bảo hiểm của người 64 tuổi không vượt quá ba lần phí của người 21 tuổi (tỷ lệ 3:1). Theo Kaiser Family Foundation (KFF), với giới hạn này, phí bảo hiểm của người lớn tuổi không bù đắp đủ chi phí y tế dự kiến của họ. Trong mẫu nghiên cứu, trung vị chi phí của nhóm 50-64 tuổi gấp 3,92 lần nhóm 18-29 tuổi, vượt mức 3:1. Kết quả này phù hợp với nhận định của KFF.

3.2.4: Phân bố các quan sát có chi phí cao theo nhóm tuổi

```
# Tỷ lệ chi phí cao và tỷ lệ hút thuốc theo nhóm tuổi
# Ngưỡng chi phí cao = cận trên IQR của charges
Q1_cp, Q3_cp = df_clean['charges'].quantile([0.25, 0.75])
nguong = Q3_cp + 1.5 * (Q3_cp - Q1_cp)
print(f"Ngưỡng chi phí cao: {nguong:,.2f} USD")

chi_phi_cao = (df_clean['charges'] > nguong).groupby(nhom_tuoi, observed=True)
hut_thuoc = (df_clean['smoker'] == 'yes').groupby(nhom_tuoi, observed=True)
display(pd.DataFrame({'Số người': chi_phi_cao.size(),
                      'Số chi phí cao': chi_phi_cao.sum(),
                      '% chi phí cao': (chi_phi_cao.mean() * 100).round(1),
                      '% hút thuốc': (hut_thuoc.mean() * 100).round(1)}))
```

```
Ngưỡng chi phí cao: 34,524.78 USD
```

age	Số người	Số chi phí cao	% chi phí cao	% hút thuốc
18-29	416	34	8.2	20.7
30-39	257	29	11.3	22.6
40-49	279	32	11.5	22.2
50-64	385	44	11.4	17.7

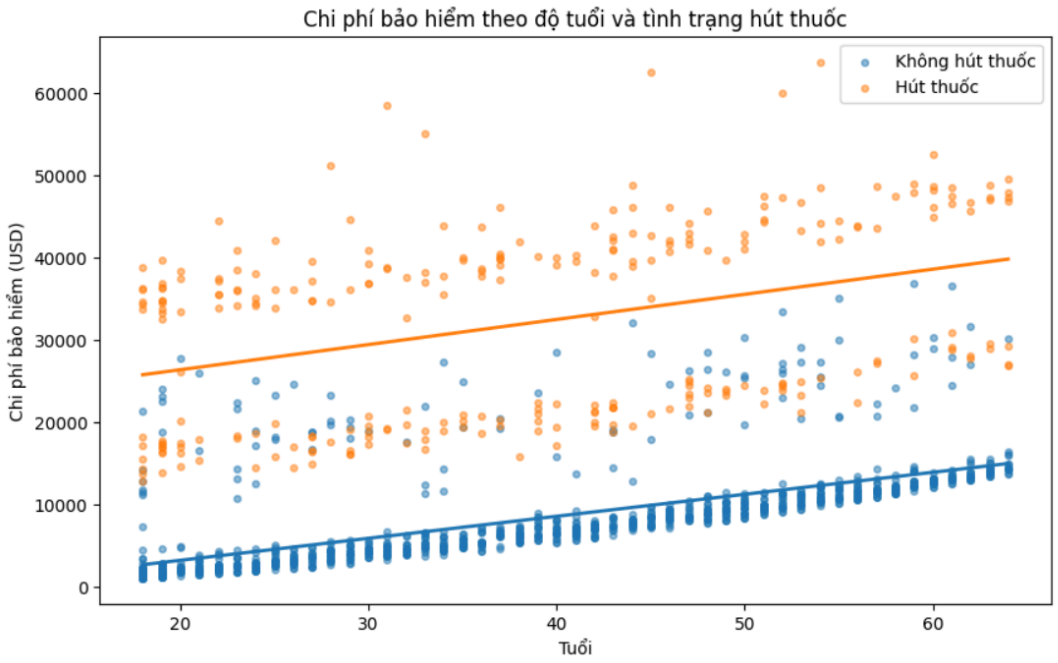
Phần này kiểm tra xem các quan sát có chi phí cao có tập trung ở người lớn tuổi hay không. Ngưỡng chi phí cao được xác định bằng cận trên của quy tắc IQR (34.524,78 USD), thống nhất với ngưỡng đã dùng ở Giai đoạn 2. Với mỗi nhóm tuổi, hai chỉ tiêu được tính đó là tỷ lệ khách hàng có chi phí vượt ngưỡng và tỷ lệ khách hàng hút thuốc. Chỉ tiêu thứ hai được đưa vào vì Giai đoạn 2 đã chỉ ra rằng 136 trong 139 quan sát ngoại lệ về chi phí thuộc nhóm hút thuốc.

Nhóm tuổi	Số quan sát	Số quan sát chi phí cao	Tỷ lệ chi phí cao (%)	Tỷ lệ hút thuốc (%)
18-29	416	34	8,2	20,7
30-39	257	29	11,3	22,6
40-49	279	32	11,5	22,2
50-64	385	44	11,4	17,7

Tỷ lệ khách hàng có chi phí cao tương đối ổn định giữa các nhóm tuổi, trong khoảng 8,2-11,5%. Ngay cả nhóm trẻ tuổi nhất cũng có 34 quan sát vượt ngưỡng. Do đó, chi phí cao không phải là đặc điểm riêng của nhóm lớn tuổi mà xuất hiện ở mọi độ tuổi. Tỷ lệ hút thuốc cũng khá đồng đều giữa các nhóm (17,7-22,6%). Đáng chú ý, nhóm 50-64 tuổi có tỷ lệ hút thuốc thấp nhất (17,7%) nhưng lại có mức chi phí điển hình cao nhất. Kết quả này loại trừ một cách giải thích có thể gây nhầm lẫn đó là xu hướng chi phí tăng theo tuổi không xuất phát từ việc người lớn tuổi hút thuốc nhiều hơn. Tuổi và tình trạng hút thuốc nhiều khả năng là hai yếu tố tác động tương đối độc lập đến chi phí.

3.2.5: Xu hướng chi phí theo tuổi khi phân tách theo tình trạng hút thuốc

```
# Scatter plot tuổi – chi phí, tách theo tình trạng hút thuốc
plt.figure(figsize=(10, 6))
nhan = [('no', 'tab:blue', 'Không hút thuốc'), ('yes', 'tab:orange', 'Hút thuốc')]
for nhom, mau, ten in nhan:
    dl = df_clean[df_clean['smoker'] == nhom]
    plt.scatter(dl['age'], dl['charges'], alpha=0.5, s=15, color=mau, label=ten)
    # Đường xu hướng riêng cho từng nhóm
    doc, chan = np.polyfit(dl['age'], dl['charges'], 1)
    plt.plot(truc_tuoi, doc * truc_tuoi + chan, color=mau, linewidth=2)
plt.title('Chi phí bảo hiểm theo độ tuổi và tình trạng hút thuốc')
plt.xlabel('Tuổi'); plt.ylabel('Chi phí bảo hiểm (USD)'); plt.legend()
plt.show()
```



Biểu đồ phân tán được vẽ lại với hai màu: xanh cho người không hút thuốc và cam cho người hút thuốc. Mỗi nhóm có một đường xu hướng tuyến tính riêng. Với từng nhóm, ba chỉ tiêu được tính: mức tăng chi phí trên mỗi năm tuổi (độ dốc), hệ số tương quan Spearman, và tỷ lệ giữa trung vị chi phí của người 50-64 tuổi so với người 18-29 tuổi. Biểu đồ làm rõ cấu trúc ba dải đã quan sát ở phần 4.2.1. Dải thấp gần như chỉ gồm người không hút thuốc, dải cao gần như chỉ gồm người hút thuốc, còn dải giữa có cả hai nhóm.

Nhóm	Số quan sát	Tăng thêm mỗi năm tuổi (USD)	Spearman	Trung vị 18-29 (USD)	Trung vị 50-64 (USD)	Tỷ lệ
Không hút thuốc	1.063	267,12	0,820	2.709,18	12.029,29	4,44 lần
Hút thuốc	274	305,24	0,452	33.604,25	43.696,40	1,30 lần

```
# So sánh xu hướng theo tuổi giữa hai nhóm hút thuốc / không hút thuốc
ket_qua = []
for nhom in ['no', 'yes']:
    dl = df_clean[df_clean['smoker'] == nhom]
    tre = dl.loc[dl['age'] <= 29, 'charges'].median()   # trung vị nhóm 18-29
    gia = dl.loc[dl['age'] >= 50, 'charges'].median()   # trung vị nhóm 50-64
    doc = np.polyfit(dl['age'], dl['charges'], 1)[0]    # tăng thêm mỗi năm tuổi
    rho = stats.spearmanr(dl['age'], dl['charges'])[0]
    ket_qua.append([nhom, len(dl), round(doc, 2), round(rho, 3),
                    round(tre, 2), round(gia, 2), round(gia / tre, 2)])
cot = ['smoker', 'Số người', 'USD/năm tuổi', 'Spearman',
       'Trung vị 18-29', 'Trung vị 50-64', 'Gấp (lần)']
display(pd.DataFrame(ket_qua, columns=cot))
```

	smoker	Số người	USD/năm tuổi	Spearman	Trung vị 18-29	Trung vị 50-64	Gấp (lần)
0	no	1063	267.12	0.820	2709.18	12029.29	4.44
1	yes	274	305.24	0.452	33604.25	43696.40	1.30

Kết quả cho thấy ba phát hiện chính. Thứ nhất, trong nhóm không hút thuốc, tuổi có tương quan mạnh với chi phí. Hệ số Spearman tăng từ 0,534 trên toàn mẫu lên 0,820 trong nhóm này. khi tách riêng ảnh hưởng của việc hút thuốc, mối quan hệ giữa tuổi và chi phí trở nên rõ ràng hơn nhiều. Chi phí điển hình của người không hút thuốc 50-64 tuổi gấp 4,44 lần người 18-29 tuổi. Kết quả này cho thấy biểu đồ tổng thể ở phần 4.2.1 đã làm mờ đi vai trò thực sự của tuổi, do bị gây nhiễu từ biến hút thuốc.

Thứ hai, tuổi và hút thuốc có xu hướng tác động cộng dồn, nhưng mức ảnh hưởng của hai yếu tố chênh lệch rất lớn. Mức tăng chi phí theo tuổi của hai nhóm khá tương đồng (267,12 và 305,24 USD mỗi năm), nên hai đường xu hướng gần như song song. Việc hút thuốc đẩy toàn bộ mức chi phí lên cao hơn, trong khi tuổi làm chi phí tăng dần với tốc độ tương tự ở cả hai nhóm. Tuy nhiên, chi phí điển hình của người hút thuốc 18-29 tuổi (33.604,25 USD) gần gấp ba lần người không hút thuốc 50-64

tuổi (12.029,29 USD). Nói cách khác, mức chênh lệch do hút thuốc lớn hơn mức chênh lệch tích lũy qua 30-40 năm tuổi. Điều này cũng giải thích vì sao trong nhóm hút thuốc, chi phí của người lớn tuổi chỉ gấp 1,30 lần người trẻ tuổi khi mức chi phí nền vốn đã rất cao.

Thứ ba, vẫn còn yếu tố khác chưa được giải thích. Đường xu hướng của nhóm hút thuốc đi qua khoảng trống giữa hai dải điểm màu cam (quanh mức 20.000 USD và 40.000 USD), khiến hệ số Spearman của nhóm này chỉ đạt 0,452. Điều này cho thấy người hút thuốc tiếp tục phân tách thành hai nhóm nhỏ theo một yếu tố khác. Kiểm tra sơ bộ cho thấy yếu tố này có liên quan đến chỉ số BMI: trung vị chi phí của người hút thuốc có BMI từ 30 trở lên vào khoảng 40.904 USD, gần gấp đôi so với khoảng 20.167 USD ở người hút thuốc có BMI dưới 30. Ngoài ra, một bộ phận người không hút thuốc vẫn nằm ở dải chi phí giữa. Hiện tượng này có thể bắt nguồn từ những yếu tố không có trong bộ dữ liệu, như bệnh mãn tính, tai nạn hoặc điều trị nội trú.

3.2.6. Kết luận Bảng 2

Kết quả phân tích ủng hộ giả thuyết ban đầu: chi phí bảo hiểm tăng theo độ tuổi với ý nghĩa thống kê. Trung bình, mỗi năm tuổi tăng thêm gắn với mức chi phí cao hơn khoảng 257 USD, và chi phí điển hình của nhóm 50-64 tuổi gấp gần bốn lần nhóm 18-29 tuổi. Tuy nhiên, vai trò của tuổi chủ yếu nằm ở việc xác định mức chi phí cơ bản, không phải ở việc tạo ra các khoản chi phí đặc biệt cao. Các quan sát có chi phí cao phân bố tương đối đồng đều ở mọi độ tuổi và gắn chủ yếu với tình trạng hút thuốc. Khi tách riêng ảnh hưởng của hút thuốc, tương quan giữa tuổi và chi phí trong nhóm không hút thuốc đạt mức mạnh ($\rho = 0,820$). Điều này cho thấy việc chỉ quan sát biểu đồ tổng thể có thể dẫn đến đánh giá thấp vai trò của tuổi. Hàm ý đối với doanh nghiệp bảo hiểm đó là tuổi là căn cứ phù hợp để xây dựng mức phí cơ bản. Tuy nhiên, do tuổi chỉ giải thích khoảng 8,9% sự biến động của chi phí, mô hình định phí và dự báo chi phí không chỉ dựa vào tuổi mà cần kết hợp với các yếu tố hành vi và sức khỏe như tình trạng hút thuốc và chỉ số BMI.

Phân tích vẫn còn một số giới hạn: bộ dữ liệu là dữ liệu chéo khi mỗi cá nhân chỉ được quan sát tại một thời điểm. Vì vậy, mức tăng 257 USD mỗi năm tuổi phản ánh chênh lệch giữa những cá nhân ở các độ tuổi khác nhau, không phải sự thay đổi chi phí của cùng một cá nhân theo thời gian. Mẫu nghiên cứu chỉ bao gồm người từ 18 đến 64 tuổi, nên không thể suy rộng cho nhóm từ 65 tuổi trở lên. Ngoài ra, bộ dữ liệu được mô phỏng dựa trên số liệu nhân khẩu học của Cục Điều tra Dân số Hoa Kỳ, không phải dữ liệu bồi thường thực tế. Do đó, các giá trị cụ thể chỉ mang tính minh họa cho xu hướng, không thể sử dụng trực tiếp cho mục đích định phí.

3.3. Chỉ số BMI có mối liên hệ với chi phí bảo hiểm y tế cá nhân không?

Chỉ số khối cơ thể (Body Mass Index - BMI) là một chỉ tiêu phổ biến phản ánh tương quan giữa cân nặng và chiều cao của cá nhân, thường được sử dụng trong quá trình đánh giá tình trạng dinh dưỡng và sàng lọc các nguy cơ sức khỏe. Trong lĩnh vực bảo hiểm y tế, việc nghiên cứu mối liên hệ giữa BMI và chi phí y tế có ý nghĩa quan trọng đối với hoạt động phân tích rủi ro, phân loại đặc điểm khách hàng và hỗ trợ xây dựng các mô hình dự báo chi phí.

Về mặt lý thuyết, chỉ số BMI cao có thể đi kèm với nguy cơ gia tăng một số bệnh lý như bệnh tim mạch, tăng huyết áp và đái tháo đường type 2, từ đó có khả năng liên quan đến nhu cầu sử dụng dịch vụ y tế và mức chi phí phát sinh. Tuy nhiên, mối liên hệ này không nhất thiết mang tính tuyến tính hoặc đồng nhất giữa các cá nhân, bởi chi phí y tế còn chịu sự chi phối của nhiều yếu tố khác như độ tuổi, tình trạng hút thuốc, đặc điểm sức khỏe và các điều kiện cá nhân khác.

Trên cơ sở bộ dữ liệu Medical Cost Personal Dataset đã được làm sạch ở Giai đoạn 2, nhóm nghiên cứu sử dụng hai biến định lượng gồm bmi (chỉ số khối cơ thể) và charges (chi phí y tế, đơn vị USD) để xem xét chiều hướng, mức độ và ý nghĩa thống kê của mối liên hệ giữa BMI và chi phí y tế cá nhân.

Câu hỏi nghiên cứu: Chỉ số BMI có mối tương quan với chi phí y tế cá nhân hay không? Mức độ tương quan có thay đổi khi phân chia khách hàng theo tình trạng hút thuốc không?

Nhóm xây dựng cặp giả thuyết nghiên cứu:

Giả thuyết	Nội dung
H_0	Không tồn tại tương quan tuyến tính giữa BMI và chi phí y tế trong tổng thể ($\rho = 0$).
H_1	Tồn tại tương quan tuyến tính giữa BMI và chi phí y tế trong tổng thể ($\rho \neq 0$).

Mức ý nghĩa thống kê được lựa chọn là $\alpha = 0,05$.

3.3.1. Trực quan hóa mối quan hệ giữa BMI và chi phí y tế bằng biểu đồ phân tán

Để đánh giá sơ bộ mối liên hệ giữa BMI và chi phí y tế, nhóm nghiên cứu sử dụng biểu đồ phân tán (Scatter Plot). Đây là phương pháp trực quan hóa phù hợp với hai biến định lượng, cho phép quan sát xu hướng biến động của chi phí khi BMI thay đổi, mức độ phân tán giữa các cá nhân cũng như sự xuất hiện của những quan sát có chi phí đặc biệt cao.

Bên cạnh các điểm dữ liệu, nhóm bổ sung đường xu hướng hồi quy tuyến tính nhằm làm rõ chiều hướng liên hệ tổng thể giữa hai biến.

Nhóm sử dụng các câu lệnh Python sau:

- df_clean[['bmi', 'charges', 'smoker']].copy(): Trích xuất ba biến cần thiết từ bộ dữ liệu đã làm sạch và tạo bản sao để không làm thay đổi dữ liệu của nhóm.

- sns.regplot(): Vẽ biểu đồ phân tán kết hợp đường hồi quy tuyến tính.

- x='bmi': Chỉ số BMI được đặt trên trục hoành.

- y='charges': Chi phí y tế được đặt trên trục tung.

- scatter_kws={'alpha': 0.4, 's': 20}: Điều chỉnh độ trong suốt và kích thước các điểm dữ liệu, giúp quan sát rõ hơn những khu vực có nhiều điểm chồng lấn.

- line_kws={'color': 'red'}: Hiển thị đường xu hướng tuyến tính màu đỏ.

- ci=None: Không hiển thị dải khoảng tin cậy quanh đường hồi quy.

```
# GIAI ĐOẠN 3 – BẢNG 3
# Phân tích mối liên hệ giữa BMI và chi phí y tế

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import pearsonr, spearmanr

# Lấy dữ liệu đã làm sạch ở Giai đoạn 2
# Chỉ chọn các biến cần thiết cho phân tích
df_bmi = df_clean[['bmi', 'charges', 'smoker']].copy()

# Kiểm tra số quan sát
print("Số quan sát:", len(df_bmi))

# Tạo biểu đồ phân tán
plt.figure(figsize=(10, 6))

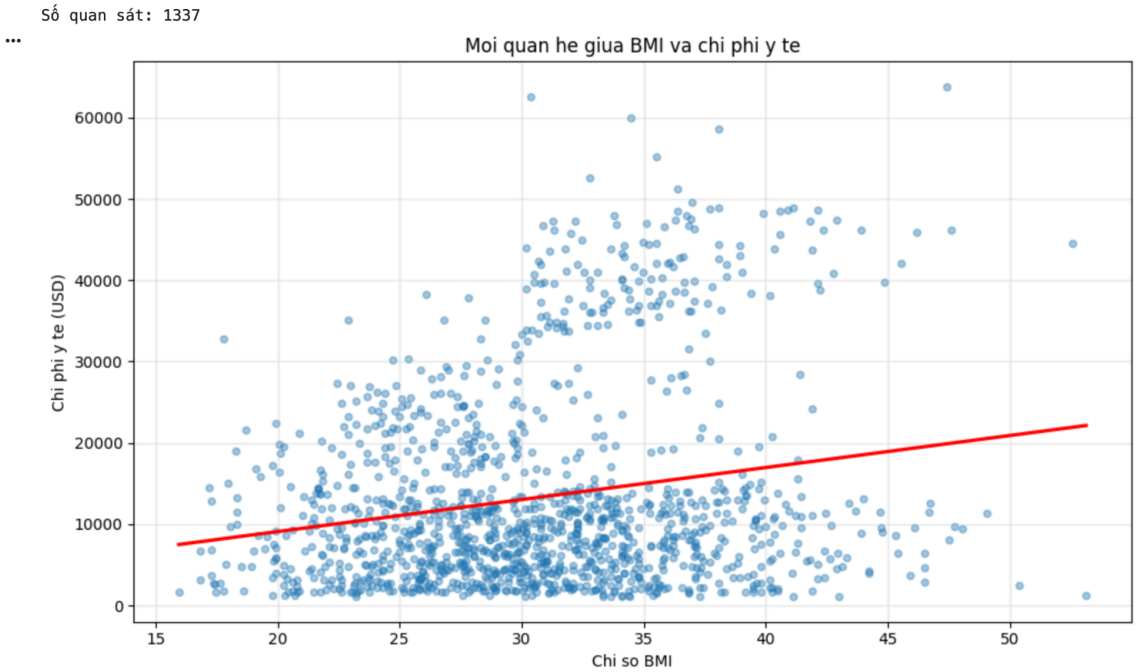
# Vẽ điểm dữ liệu và đường hồi quy tuyến tính
sns.regplot(
    data=df_bmi,
    x='bmi',
    y='charges',
    scatter_kws={'alpha': 0.4, 's': 20},
    line_kws={'color': 'red'},
    ci=None
)


# Đặt tiêu đề và nhãn trục
plt.title('Moi quan he giua BMI va chi phi y te')
plt.xlabel('Chi so BMI')
plt.ylabel('Chi phi y te (USD)')

# Hiển thị lưới
plt.grid(True, alpha=0.3)

# Điều chỉnh bố cục
plt.tight_layout()
plt.show()
```

Hình 3.3.1. Biểu đồ phân tán giữa chỉ số BMI và chi phí y tế cá nhân



Biểu đồ phân tán cho thấy mối quan hệ giữa BMI và chi phí y tế cá nhân có xu hướng dương, thể hiện qua đường hồi quy tuyến tính hơi dốc lên khi chỉ số BMI tăng. Tuy nhiên, các điểm quan sát phân bố khá rộng xung quanh đường xu hướng, cho thấy BMI chưa phản ánh đầy đủ sự khác biệt về chi phí giữa các cá nhân.

Đáng chú ý, cấu trúc phân phối không hình thành một dải điểm duy nhất mà xuất hiện nhiều vùng tập trung với mức chi phí tương đối khác biệt. Phần lớn các quan sát có chi phí thấp phân bố trên một khoảng BMI khá rộng, trong khi các quan sát có chi phí đặc biệt cao xuất hiện rõ hơn ở vùng BMI cao, nhất là từ khoảng 30 trở lên.

Điều này gợi ý rằng mức chi phí y tế cao không chỉ phụ thuộc vào sự gia tăng của BMI. Thay vào đó, có khả năng tồn tại những đặc điểm khác của cá nhân làm thay đổi đáng kể mối liên hệ giữa chỉ số BMI và chi phí y tế.

Một điểm cần lưu ý là ở cùng một mức BMI, chi phí y tế vẫn có thể chênh lệch hàng chục nghìn USD giữa các quan sát. Do vậy, chỉ số BMI không đủ để giải thích riêng lẻ mức chi phí phát sinh của từng cá nhân. Đặc điểm này cũng đặt ra yêu cầu cần kết hợp phân tích tương quan với các phương pháp phân nhóm để xác định rõ hơn bản chất của mối liên hệ.

3.3.2. Đo lường và kiểm định mối tương quan giữa BMI và chi phí y tế

Biểu đồ phân tán giúp nhận diện xu hướng trực quan nhưng chưa cung cấp bằng chứng định lượng đầy đủ về mức độ liên hệ giữa hai biến. Vì vậy, nhóm tiếp tục sử dụng hệ số tương quan Pearson và Spearman nhằm đo lường mức độ tương quan, đồng thời thực hiện kiểm định ý nghĩa thống kê.

Hệ số Pearson (r) đo lường mức độ và chiều hướng của mối tương quan tuyến tính giữa BMI và chi phí y tế. Trong khi đó, hệ số Spearman (ρ) được tính dựa trên thứ hạng của các quan sát, cho phép đánh giá mối liên hệ đơn điệu mà không yêu cầu quan hệ phải tuân theo dạng đường thẳng.

Việc kết hợp hai hệ số là cần thiết bởi phân phối của biến charges có xu hướng lệch phải và xuất hiện nhiều quan sát chi phí cao, như đã được xác định ở Giai đoạn 2.

Nhóm sử dụng câu lệnh Python sau:

- pearsonr(): Tính hệ số tương quan Pearson và giá trị p-value.
- spearmanr(): Tính hệ số tương quan Spearman và p-value tương ứng.
- r**2: Tính hệ số xác định của hồi quy tuyến tính đơn có hệ số chặn.
- pd.DataFrame(): Tạo bảng tổng hợp kết quả kiểm định.
- alpha = 0.05: Xác định mức ý nghĩa thống kê 5%.
- if p_pearson < alpha: Đưa ra quyết định đối với giả thuyết H_0.

```
# BẢNG 3
# 4.3.2. Kiểm định tương quan BMI và chi phí y tế

# Tính hệ số tương quan Pearson
r, p_pearson = pearsonr(df_bmi['bmi'], df_bmi['charges'])

# Tính hệ số tương quan Spearman
rho, p_spearman = spearmanr(df_bmi['bmi'], df_bmi['charges'])

# Tính hệ số xác định R bình phương
r_squared = r**2

# Tạo bảng tổng hợp kết quả
bang_tuongquan = pd.DataFrame({
    'Phương pháp': ['Pearson', 'Spearman'],
    'Hệ số tương quan': [r, rho],
    'p-value': [p_pearson, p_spearman]
})

# Hiển thị bảng kết quả
display(bang_tuongquan)

# Hiển thị hệ số xác định
print("R bình phương:", round(r_squared, 4))

# Kiểm định giả thuyết H0 theo Pearson
alpha = 0.05

if p_pearson < alpha:
    print("Bác bỏ H0: Có tương quan tuyến tính có ý nghĩa thống kê")
else:
    print("Chưa đủ cơ sở bác bỏ H0")
```

Bảng 3.3.1. Kết quả kiểm định tương quan giữa BMI và chi phí y tế

	Phương pháp	Hệ số tương quan	p-value
0	Pearson	0.198401	2.468040e-13
1	Spearman	0.119585	1.163718e-05

```
R bình phương: 0.0394
Bác bỏ H0: Có tương quan tuyến tính có ý nghĩa thống kê
```

Kết quả cho thấy hệ số tương quan Pearson giữa BMI và chi phí y tế đạt 0,1984, mang dấu dương và có p-value nhỏ hơn 0,001. Với mức ý nghĩa thống kê 5%, nhóm bác bỏ giả thuyết H_0 và xác định rằng tồn tại mối tương quan tuyến tính dương có ý nghĩa thống kê giữa BMI và chi phí y tế cá nhân.

Tuy nhiên, mức độ tương quan tương đối yếu. Hệ số xác định được tính bằng bình phương hệ số Pearson, đạt khoảng 0,0394, tương ứng 3,94%. Điều này có nghĩa là trong mô hình hồi quy tuyến tính đơn chỉ sử dụng BMI, biến này giải thích được khoảng 3,94% sự biến động của chi phí y tế trong mẫu nghiên cứu. Phần biến động còn lại chưa được giải thích bởi mô hình tuyến tính đơn này.

Bên cạnh đó, hệ số Spearman chỉ đạt 0,1196, thấp hơn hệ số Pearson. Mặc dù kết quả vẫn có ý nghĩa thống kê, mức độ tương quan đơn điệu giữa BMI và chi phí là khá yếu. Sự khác biệt giữa hai hệ số gợi ý rằng mối liên hệ được ghi nhận trên toàn bộ mẫu có thể chịu ảnh hưởng của một số quan sát có BMI và chi phí cao.

Như vậy, kết quả kiểm định xác nhận sự tồn tại của mối tương quan dương giữa BMI và chi phí y tế, nhưng không ủng hộ nhận định rằng BMI là một yếu tố đủ mạnh để giải thích chi phí khi được xem xét độc lập.

Đặc biệt, ý nghĩa thống kê không đồng nghĩa với ý nghĩa thực tiễn lớn. Với quy mô 1.337 quan sát, một hệ số tương quan tương đối nhỏ vẫn có thể tạo ra p-value rất thấp. Vì vậy, việc đánh giá vai trò của BMI cần tiếp tục xem xét mức độ khác biệt giữa các nhóm khách hàng thay vì chỉ dựa vào khả năng bác bỏ giả thuyết H_0.

3.3.3. Phân tích mối quan hệ giữa BMI và chi phí y tế theo tình trạng hút thuốc

Kết quả phân tích trên toàn bộ mẫu chỉ phản ánh xu hướng chung mà chưa xem xét sự khác biệt về đặc điểm rủi ro giữa các cá nhân. Trong khi đó, kết quả làm sạch dữ liệu ở Giai đoạn 2 cho thấy phần lớn các quan sát có chi phí y tế đặc biệt cao tập trung trong nhóm hút thuốc.

Do vậy, nhóm tiếp tục phân chia mẫu thành hai nhóm khách hàng hút thuốc và không hút thuốc nhằm đánh giá liệu mối liên hệ giữa BMI và chi phí y tế có thay đổi theo tình trạng hút thuốc hay không.

a. Tính hệ số tương quan riêng cho từng nhóm:

Nhóm sử dụng câu lệnh:

- groupby('smoker'): Chia dữ liệu theo hai nhóm hút thuốc và không hút thuốc.
- for trang_thai, nhom: Lần lượt thực hiện phân tích trên từng nhóm.
- pearsonr() và spearmanr(): Đo lường mối tương quan giữa BMI và chi phí trong từng nhóm.
- len(nhom): Đếm số quan sát của nhóm.
- ket_qua.append(): Lưu kết quả phân tích để tổng hợp thành bảng.

```
# BẢNG 3
# 4.3.3. Tương quan BMI và chi phí theo tình trạng hút thuốc

# Tạo danh sách lưu kết quả
ket_qua = []

# Phân tích lần lượt hai nhóm hút thuốc và không hút thuốc
for trang_thai, nhom in df_bmi.groupby('smoker'):

    # Tính hệ số Pearson
    r, p = pearsonr(nhom['bmi'], nhom['charges'])

    # Tính hệ số Spearman
    rho, p_s = spearmanr(nhom['bmi'], nhom['charges'])

    # Lưu kết quả vào danh sách
    ket_qua.append({
        'Tình trạng hút thuốc': trang_thai,
        'Số quan sát': len(nhom),
        'Pearson': r,
        'Spearman': rho,
        'p-value Pearson': p
    })

# Tạo bảng kết quả
bang_bmi_smoker = pd.DataFrame(ket_qua)

# Hiển thị
display(bang_bmi_smoker)
```

Bảng 4.3.2. Hệ số tương quan BMI và chi phí y tế theo tình trạng hút thuốc

	Tình trạng hút thuốc	Số quan sát	Pearson	Spearman	p-value Pearson
0	no	1063	0.084077	0.105373	6.091103e-03
1	yes	274	0.806481	0.834228	5.019669e-64

b. Trực quan hóa theo hai nhóm

Để thể hiện rõ sự khác biệt về mối quan hệ giữa BMI và chi phí y tế theo tình trạng hút thuốc, nhóm xây dựng biểu đồ phân tán với hai màu khác nhau và bổ sung đường xu hướng tuyến tính riêng cho từng nhóm.

```
# BẢNG 3
# Vẽ BMI và chi phí theo tình trạng hút thuốc

plt.figure(figsize=(10, 6))

# Biểu đồ phân tán, phân biệt màu theo smoker
sns.scatterplot(
    data=df_bmi,
    x='bmi',
    y='charges',
    hue='smoker',
    palette={'no': 'blue', 'yes': 'red'},
    alpha=0.5
)

# Vẽ đường hồi quy riêng cho từng nhóm
for trang_thai, mau in [('no', 'blue'), ('yes', 'red')]:
    nhom = df_bmi[df_bmi['smoker'] == trang_thai]

    # Ước lượng đường xu hướng tuyến tính
    a, b = np.polyfit(nhom['bmi'], nhom['charges'], 1)

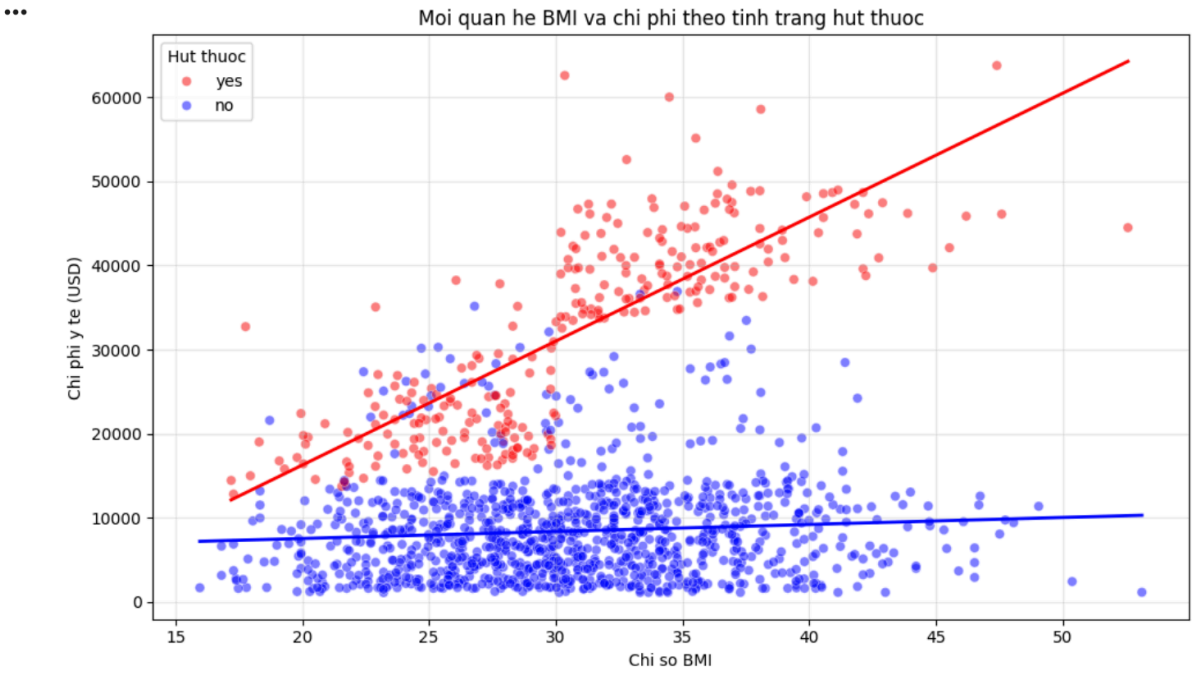
    # Tạo các giá trị BMI để vẽ đường
    x_line = np.linspace(nhom['bmi'].min(), nhom['bmi'].max(), 100)
    y_line = a * x_line + b

    # Vẽ đường xu hướng
    plt.plot(x_line, y_line, color=mau, linewidth=2)


# Hoàn thiện biểu đồ
plt.title('Moi quan he BMI va chi phi theo tinh trang hut thuoc')
plt.xlabel('Chi so BMI')
plt.ylabel('Chi phi y te (USD)')
plt.legend(title='Hut thuoc')
plt.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()
```

Hình 3.3.2. Mối quan hệ giữa BMI và chi phí y tế theo tình trạng hút thuốc



Kết quả phân nhóm cho thấy mối liên hệ giữa BMI và chi phí y tế có sự khác biệt đáng kể giữa hai nhóm khách hàng.

Đối với nhóm không hút thuốc, hệ số Pearson chỉ đạt 0,0841, phản ánh mối tương quan tuyến tính dương rất yếu. Hệ số xác định tương ứng đạt khoảng 0,71%, cho thấy BMI gần như không giải thích được sự khác biệt về chi phí y tế bằng mô hình tuyến tính đơn trong nhóm này. Mặc dù p-value đạt 0,0061, thấp hơn mức ý nghĩa 5%, mức độ liên hệ về mặt thực tiễn vẫn rất hạn chế.

Ngược lại, đối với nhóm hút thuốc, hệ số Pearson đạt 0,8065, thể hiện mối tương quan tuyến tính dương mạnh giữa BMI và chi phí y tế. Hệ số Spearman cũng đạt 0,8342, cho thấy mối liên hệ đơn điệu mạnh và nhất quán với kết quả Pearson. Hệ số xác định tương ứng với Pearson đạt khoảng 65,04%, cao hơn đáng kể so với nhóm không hút thuốc.

Sự khác biệt này cho thấy mối liên hệ giữa BMI và chi phí y tế phụ thuộc đáng kể vào nhóm tình trạng hút thuốc được xem xét. Trên biểu đồ, chi phí của nhóm không hút thuốc có xu hướng thay đổi tương đối ít theo BMI, trong khi đường xu hướng của nhóm hút thuốc có độ dốc lớn hơn rõ rệt.

Đây là một phát hiện quan trọng vì hệ số tương quan BMI-chi phí trên toàn bộ mẫu chỉ đạt 0,1984. Nếu chỉ dựa trên kết quả tổng thể, nghiên cứu có thể đánh giá thấp mức độ liên hệ giữa BMI và chi phí trong nhóm hút thuốc.

Tuy nhiên, cần nhấn mạnh rằng kết quả trên mới phản ánh sự khác biệt về tương quan trong từng nhóm và chưa đủ để khẳng định tình trạng hút thuốc gây ra sự thay đổi trong tác động nhân quả của BMI. Để kiểm chứng chính thức sự khác biệt về

độ dốc giữa hai nhóm, nghiên cứu có thể mở rộng sang mô hình hồi quy có biến tương tác giữa BMI và tình trạng hút thuốc.

3.3.4. So sánh chi phí y tế theo ngưỡng BMI và tình trạng hút thuốc

Để bổ sung bằng chứng định lượng cho kết quả tương quan, nhóm tiếp tục phân loại các cá nhân thành hai nhóm có BMI dưới 30 và BMI từ 30 trở lên. Ngưỡng BMI 30 được lựa chọn dựa trên cách phân loại thường được sử dụng đối với người trưởng thành, trong đó BMI từ 30 trở lên thuộc nhóm béo phì theo tiêu chuẩn BMI thông thường.

Việc phân chia này cho phép lượng hóa sự chênh lệch chi phí y tế giữa các nhóm BMI, đồng thời đánh giá sự khác biệt đó có đồng nhất giữa người hút thuốc và người không hút thuốc hay không.

Nhóm sử dụng câu lệnh Python:

- np.where(): Phân loại quan sát theo điều kiện BMI từ 30 trở lên hoặc dưới 30.
- groupby(['smoker', 'Nhom_BMI']): Chia dữ liệu thành bốn nhóm theo tình trạng hút thuốc và mức BMI.
- agg(): Tính các chỉ tiêu thống kê mô tả.
- count: Số quan sát.
- mean: Chi phí trung bình.
- median: Chi phí trung vị.
- std: Độ lệch chuẩn chi phí.
- round(2): Làm tròn kết quả đến hai chữ số thập phân.

```python
# 4.3.4. Phân nhóm BMI và so sánh chi phí

# Tạo biến phân nhóm BMI
df_bmi['Nhom_BMI'] = np.where(
    df_bmi['bmi'] >= 30,
    'BMI >= 30',
    'BMI < 30'
)

# Thống kê chi phí theo nhóm BMI và hút thuốc
bang_chiphi = df_bmi.groupby(
    ['smoker', 'Nhom_BMI']
)['charges'].agg(
    So_quan_sat='count',
    Trung_binh='mean',
    Trung_vi='median',
    Do_lech_chuan='std'
)

# Hiển thị bảng, làm tròn 2 chữ số
display(bang_chiphi.round(2))
```

		So_quan_sat	Trung_binh	Trung_vi	Do_lech_chuan
smoker	Nhom_BMI				
no	BMI < 30	502	7977.03	6761.62	5839.23
	BMI >= 30	561	8855.53	8083.92	6102.64
yes	BMI < 30	129	21363.22	20167.34	5066.78
	BMI >= 30	145	41557.99	40904.20	6031.47

Kết quả thống kê cho thấy sự khác biệt về chi phí y tế giữa hai nhóm BMI không đồng nhất theo tình trạng hút thuốc.

Đối với nhóm không hút thuốc, chi phí y tế trung bình của những người có BMI từ 30 trở lên đạt 8.855,53 USD, cao hơn khoảng 878,50 USD so với nhóm BMI dưới 30. Mức chênh lệch tương ứng khoảng 11,0%, cho thấy sự gia tăng BMI đi kèm với mức chênh lệch chi phí trung bình tương đối hạn chế trong nhóm không hút thuốc.

Trong khi đó, đối với nhóm hút thuốc, chi phí trung bình của người có BMI từ 30 trở lên đạt 41.557,99 USD, gần gấp 1,95 lần nhóm có BMI dưới 30 (21.363,22 USD). Chênh lệch tuyệt đối đạt khoảng 20.194,77 USD, lớn hơn nhiều so với mức chênh lệch của nhóm không hút thuốc.

Đáng chú ý, kết quả này tiếp tục được củng cố khi sử dụng trung vị thay vì trung bình. Trong nhóm hút thuốc, chi phí trung vị của người có BMI từ 30 trở lên đạt 40.904,20 USD, cao gấp khoảng 2,03 lần nhóm có BMI dưới 30. Điều này cho thấy mức chênh lệch lớn không chỉ bắt nguồn từ một vài quan sát có chi phí cực đoan mà còn phản ánh sự khác biệt rõ rệt về mức chi phí điển hình giữa hai nhóm BMI.

Kết quả trên bổ sung bằng chứng quan trọng cho phân tích tương quan tại mục 4.3.3. Trong bộ dữ liệu nghiên cứu, BMI cao gắn với mức chi phí lớn hơn đáng kể ở nhóm hút thuốc, trong khi sự khác biệt tương ứng ở nhóm không hút thuốc nhỏ hơn nhiều. Điều này gợi ý rằng việc kết hợp thông tin BMI và tình trạng hút thuốc có thể

giúp nhận diện các nhóm khách hàng với đặc điểm chi phí khác nhau một cách rõ ràng hơn so với việc chỉ xem xét riêng lẻ từng biến.

Tuy nhiên, đây là kết quả phân tích mô tả từ dữ liệu quan sát. Chênh lệch chi phí giữa các nhóm không đồng nghĩa với việc tăng BMI gây ra mức tăng chi phí tương ứng. Ngoài ra, ngưỡng BMI 30 chỉ là tiêu chí phân nhóm phục vụ phân tích, không thể hiện đầy đủ tình trạng sức khỏe của từng cá nhân.

3.3.5. Kết luận

Kết quả phân tích cho thấy chỉ số BMI có mối tương quan dương với chi phí y tế cá nhân và mối liên hệ này có ý nghĩa thống kê ở mức 5%. Tuy nhiên, hệ số tương quan Pearson trên toàn bộ mẫu chỉ đạt 0,1984, với hệ số xác định khoảng 3,94%, phản ánh khả năng giải thích tương đối hạn chế của BMI khi được xem xét độc lập.

Phát hiện quan trọng nhất của nghiên cứu nằm ở sự khác biệt về mức độ tương quan giữa hai nhóm tình trạng hút thuốc. Trong nhóm không hút thuốc, BMI có mối tương quan rất yếu với chi phí y tế, với hệ số Pearson chỉ đạt 0,0841. Ngược lại, trong nhóm hút thuốc, hệ số tương quan tăng lên 0,8065, cho thấy mối liên hệ tuyến tính mạnh hơn đáng kể.

Kết quả thống kê theo ngưỡng BMI tiếp tục củng cố nhận định trên. Ở nhóm hút thuốc, chi phí trung bình của người có BMI từ 30 trở lên cao gần gấp đôi nhóm BMI dưới 30. Trong khi đó, mức chênh lệch tương ứng ở nhóm không hút thuốc chỉ khoảng 11,0%. Như vậy, dữ liệu cho thấy sự kết hợp giữa BMI cao và tình trạng hút thuốc gắn với sự khác biệt đáng kể về chi phí y tế cá nhân.

Về ý nghĩa ứng dụng, kết quả gợi ý rằng các doanh nghiệp bảo hiểm có thể xem xét BMI như một biến thông tin bổ sung trong quá trình nghiên cứu cấu trúc rủi ro, nhưng không nên sử dụng riêng lẻ chỉ số này để đánh giá hoặc dự báo chi phí. Việc kết hợp BMI với tình trạng hút thuốc, độ tuổi và các đặc điểm sức khỏe khác có thể hỗ trợ xây dựng những mô hình dự báo đầy đủ hơn, đồng thời giúp doanh nghiệp xác định các nhóm đối tượng cần được quan tâm trong những chương trình quản lý sức khỏe dự phòng.

Mặc dù vậy, nghiên cứu vẫn tồn tại những giới hạn cần được thừa nhận. Thứ nhất, dữ liệu mang tính cắt ngang, không cho phép theo dõi sự thay đổi BMI và chi phí y tế của cùng một cá nhân theo thời gian. Thứ hai, bộ dữ liệu chưa bao gồm các thông tin quan trọng như bệnh lý nền, lịch sử điều trị, mức độ hút thuốc và lối sống, do đó chưa thể kiểm soát toàn bộ các yếu tố có khả năng ảnh hưởng đến chi phí. Thứ ba, BMI không phải chỉ tiêu trực tiếp đo lường mức độ béo cơ thể hoặc tình trạng sức khỏe tổng thể, nên việc diễn giải kết quả cần tránh đồng nhất BMI cao với nguy cơ y tế cao ở mọi cá nhân.

Do đó, những phát hiện từ phân tích này nên được xem là bằng chứng về mối liên hệ thống kê, thay vì bằng chứng khẳng định quan hệ nhân quả. Việc kiểm định

sâu hơn bằng các mô hình hồi quy đa biến có tương tác giữa BMI và tình trạng hút thuốc là hướng nghiên cứu phù hợp để đánh giá tính ổn định của kết quả và hỗ trợ ứng dụng thực tế trong lĩnh vực bảo hiểm.

3.4 Chi phí bảo hiểm y tế cá nhân có sự khác biệt giữa các khu vực địa lý không?

Sự khác biệt về chi phí y tế giữa các khu vực địa lý là một vấn đề đáng quan tâm trong hoạt động quản lý rủi ro và phân tích chi phí của doanh nghiệp bảo hiểm. Về mặt lý thuyết, chi phí y tế có thể thay đổi theo vị trí địa lý do sự khác biệt về điều kiện kinh tế - xã hội, khả năng tiếp cận dịch vụ chăm sóc sức khỏe, mức giá dịch vụ và đặc điểm nhân khẩu học của người dân. Tuy nhiên, sự chênh lệch được quan sát giữa các khu vực không nhất thiết phản ánh tác động trực tiếp của yếu tố địa lý, mà có thể bắt nguồn từ sự khác biệt về cơ cấu khách hàng tại từng khu vực.

Trên cơ sở bộ dữ liệu Medical Cost Personal Dataset đã được làm sạch ở Giai đoạn 2, nhóm nghiên cứu tiến hành so sánh chi phí y tế cá nhân giữa bốn khu vực tại Hoa Kỳ, bao gồm Northeast (Đông Bắc), Northwest (Tây Bắc), Southeast (Đông Nam) và Southwest (Tây Nam). Hai biến được sử dụng là region (khu vực địa lý, biến phân loại) và charges (chi phí y tế cá nhân, đơn vị USD, biến định lượng).

Nhóm áp dụng thống kê mô tả kết hợp biểu đồ cột (Bar Chart) để nhận diện sự khác biệt về mức chi phí giữa các khu vực, đồng thời thực hiện kiểm định thống kê nhằm đánh giá liệu chênh lệch được quan sát có đủ bằng chứng để khái quát cho tổng thể nghiên cứu hay không. Bên cạnh đó, tình trạng hút thuốc được đưa vào phân tích bổ sung để xem xét vai trò của cơ cấu khách hàng đối với sự khác biệt chi phí theo địa lý.

Câu hỏi nghiên cứu: Chi phí y tế trung bình có sự khác biệt giữa bốn khu vực địa lý hay không? Nếu có, mức độ chênh lệch như thế nào và liệu sự khác biệt này có liên quan đến cơ cấu khách hàng hút thuốc tại từng khu vực?

Nhóm xây dựng cặp giả thuyết:

Giả thuyết	Nội dung
H_0	Chi phí y tế trung bình của bốn khu vực bằng nhau: $\mu_NE = \mu_NW = \mu_SE = \mu_SW$.
H_1	Có ít nhất một khu vực có chi phí y tế trung bình khác với khu vực còn lại.

Mức ý nghĩa thống kê được lựa chọn là $\alpha = 0,05$.

Khác với phân tích tương quan trong Bảng 3, biến region là biến phân loại có bốn nhóm, do đó không phù hợp để tính hệ số tương quan Pearson trực tiếp với charges. Thay vào đó, nhóm sử dụng phép so sánh trung bình giữa các nhóm và kiểm định sự khác biệt.

3.4.1. Thống kê mô tả chi phí y tế theo từng khu vực

Trước khi tiến hành trực quan hóa và kiểm định giả thuyết, nhóm thực hiện thống kê mô tả biến charges theo từng giá trị của biến region. Phương pháp này cho phép xác định quy mô mẫu, mức chi phí trung bình, trung vị và độ lệch chuẩn của mỗi khu vực, làm cơ sở đánh giá sơ bộ mức độ chênh lệch về chi phí y tế.

Do phân phối chi phí trong bộ dữ liệu có xu hướng lệch phải, nhóm kết hợp cả giá trị trung bình và trung vị thay vì chỉ sử dụng một thước đo duy nhất. Trong đó, trung bình phản ánh mức chi phí bình quân của nhóm, còn trung vị giúp nhận diện mức chi phí điển hình và ít chịu ảnh hưởng hơn từ những quan sát có giá trị đặc biệt cao.

Nhóm sử dụng các câu lệnh Python:

- df_clean[['region', 'charges', 'smoker']].copy(): Trích xuất ba thuộc tính cần thiết từ bộ dữ liệu đã làm sạch, đồng thời tạo bản sao để không ảnh hưởng đến dữ liệu của những phần phân tích khác.

- region_order: Xác định thứ tự bốn khu vực để trình bày nhất quán trong bảng và biểu đồ.

- groupby('region'): Phân nhóm các quan sát theo khu vực địa lý.

- agg(): Tính đồng thời các chỉ tiêu thống kê mô tả.

- count: Đếm số lượng quan sát của từng khu vực.

- mean: Tính chi phí y tế trung bình.

- median: Tính chi phí y tế trung vị.

- std: Tính độ lệch chuẩn, phản ánh mức độ phân tán chi phí.

- min và max: Xác định mức chi phí nhỏ nhất và lớn nhất.

- reindex(region_order): Sắp xếp các dòng theo thứ tự khu vực đã quy định.

- round(2): Làm tròn các chỉ tiêu đến hai chữ số thập phân để thuận tiện cho việc trình bày.

```python
# GIAI ĐOẠN 3 – BẢNG 4
# Thống kê chi phí y tế theo khu vực địa lý

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

# Lấy dữ liệu đã làm sạch ở Giai đoạn 2
# Giữ nguyên dữ liệu gốc của nhóm
df_region = df_clean[['region', 'charges', 'smoker']].copy()

# Quy định thứ tự các khu vực
region_order = [
    'northeast', 'northwest',
    'southeast', 'southwest'
]

# Thống kê chi phí y tế theo khu vực
bang_region = df_region.groupby('region')['charges'].agg(
    So_quan_sat='count',
    Trung_binh='mean',
    Trung_vi='median',
    Do_lech_chuan='std',
    Nho_nhat='min',
    Lon_nhat='max'
)


# Sắp xếp thứ tự các khu vực
bang_region = bang_region.reindex(region_order)

# Hiển thị bảng kết quả
print("Thống kê chi phí y tế theo khu vực:")
display(bang_region.round(2))
```

Bảng 4.4.1. Thống kê mô tả chi phí y tế theo khu vực địa lý

Thống kê chi phí y tế theo khu vực:

region	So_quan_sat	Trung_binh	Trung_vi	Do_lech_chuan	Nho_nhat	Lon_nhat
northeast	324	13406.38	10057.65	11255.80	1694.80	58571.07
northwest	324	12450.84	8976.98	11073.13	1621.34	60021.40
southeast	364	14735.41	9294.13	13971.10	1121.87	63770.43
southwest	325	12346.94	8798.59	11557.18	1241.56	52590.83

Kết quả thống kê mô tả cho thấy chi phí y tế trung bình có sự khác biệt giữa bốn khu vực địa lý. Trong đó, Southeast ghi nhận mức chi phí trung bình cao nhất, đạt 14.735,41 USD, trong khi Southwest có mức thấp nhất, đạt 12.346,94 USD. Chênh lệch tuyệt đối giữa hai khu vực lên tới 2.388,47 USD, tương ứng khoảng 19,34% so với mức trung bình của Southwest. Hai khu vực còn lại gồm Northeast và Northwest có chi phí trung bình lần lượt đạt 13.406,38 USD và 12.450,84 USD.

Tuy nhiên, thứ tự các khu vực thay đổi khi sử dụng trung vị thay vì trung bình. Cụ thể, Northeast có mức chi phí trung vị cao nhất, đạt 10.057,65 USD, trong khi Southeast, mặc dù đứng đầu về trung bình, chỉ có trung vị 9.294,13 USD và xếp thứ hai theo chỉ tiêu này.

Đáng chú ý, tại Southeast, chi phí trung bình cao hơn trung vị tới khoảng 5.441 USD, lớn hơn mức chênh lệch tương ứng ở các khu vực khác. Đồng thời, Southeast cũng có độ lệch chuẩn cao nhất, đạt 13.971,10 USD, vượt đáng kể so với ba khu vực còn lại, vốn có độ lệch chuẩn dao động quanh 11.000-11.600 USD.

Đây là phát hiện quan trọng đầu tiên: Southeast có chi phí bình quân cao nhất, nhưng không phải khu vực có mức chi phí điển hình cao nhất. Kết quả này cho thấy mức trung bình của Southeast có thể chịu ảnh hưởng đáng kể từ các quan sát có chi phí cao, khiến phân phối chi phí phân tán mạnh hơn so với những khu vực khác.

Như vậy, sự khác biệt về chi phí theo khu vực không chỉ thể hiện ở mức trung bình mà còn thể hiện ở hình dạng và mức độ phân tán của phân phối. Vì vậy, việc chỉ so sánh các giá trị trung bình có thể dẫn tới những nhận định chưa đầy đủ về đặc điểm chi phí của khách hàng tại từng khu vực.

3.4.2. Trực quan hóa sự khác biệt chi phí y tế giữa bốn khu vực

Để làm rõ kết quả thống kê mô tả, nhóm nghiên cứu sử dụng biểu đồ cột (Bar Chart) nhằm so sánh chi phí y tế trung bình và trung vị giữa bốn khu vực. Trong đó, trục hoành biểu diễn các khu vực địa lý và trục tung thể hiện mức chi phí y tế tương ứng, tính bằng USD.

Việc biểu diễn đồng thời hai thước đo trung bình và trung vị giúp đánh giá không chỉ sự khác biệt về mức chi phí bình quân mà còn cả mức độ ảnh hưởng của những quan sát có chi phí lớn đến đặc điểm phân phối của từng khu vực.

Nhóm sử dụng các câu lệnh:

- np.arange(len(region_order)): Tạo các vị trí tương ứng với bốn khu vực trên trục hoành.

- width = 0.35: Thiết lập độ rộng mỗi cột để có thể đặt hai cột cạnh nhau trong cùng một nhóm khu vực.

- plt.bar(): Vẽ biểu đồ cột.

- x - width/2 và x + width/2: Điều chỉnh vị trí để các cột trung bình và trung vị nằm cạnh nhau, không chồng lấn.

- bang_region['Trung_binh']: Lấy giá trị chi phí trung bình đã tính ở mục 4.4.1.

- bang_region['Trung_vi']: Lấy giá trị trung vị tương ứng.

- plt.xticks(x, region_order): Hiển thị tên bốn khu vực trên trục hoành.

- plt.legend(): Hiển thị chú thích để phân biệt hai nhóm cột.

- plt.grid(axis='y', alpha=0.3): Bổ sung đường lưới ngang nhằm thuận tiện cho việc so sánh.

```
# 4.4.2. Vẽ biểu đồ so sánh chi phí giữa các khu vực

# Thiết lập vị trí của các cột
x = np.arange(len(region_order))
width = 0.35

# Tạo figure
plt.figure(figsize=(11, 6))

# Vẽ cột chi phí trung bình
plt.bar(
    x - width/2,
    bang_region['Trung_binh'],
    width,
    label='Trung binh',
    color='steelblue'
)

# Vẽ cột chi phí trung vị
plt.bar(
    x + width/2,
    bang_region['Trung_vi'],
    width,
    label='Trung vi',
    color='orange'
)

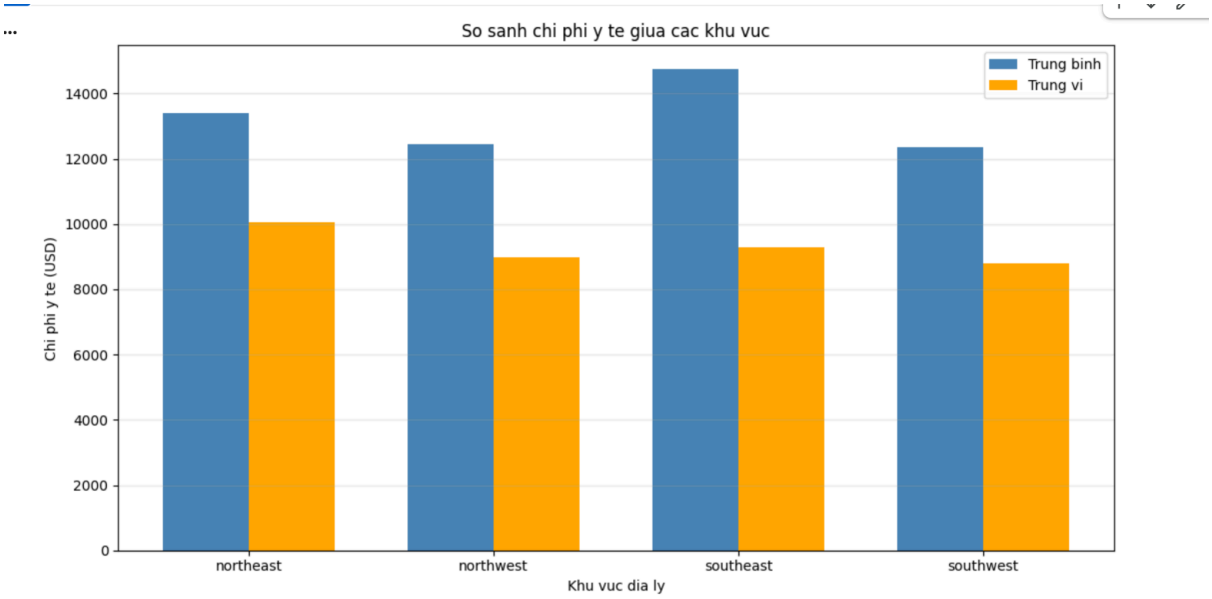

# Đặt tiêu đề và nhãn các trục
plt.title('So sanh chi phi y te giua cac khu vuc')
plt.xlabel('Khu vuc dia ly')
plt.ylabel('Chi phi y te (USD)')

# Hiển thị tên khu vực trên trục X
plt.xticks(x, region_order)

# Hiển thị chú thích và lưới
plt.legend()
plt.grid(axis='y', alpha=0.3)

# Điều chỉnh bố cục
plt.tight_layout()
plt.show()
```

Hình 3.4.1. So sánh chi phí y tế trung bình và trung vị giữa các khu vực



Biểu đồ cho thấy sự khác biệt rõ rệt giữa hai thước đo trung bình và trung vị tại từng khu vực. Southeast có cột chi phí trung bình cao nhất trong bốn khu vực, nhưng trung vị không cao tương ứng. Trong khi đó, Northeast có giá trị trung bình thấp hơn Southeast nhưng lại dẫn đầu về trung vị.

Sự khác biệt về thứ hạng giữa hai thước đo phản ánh đặc điểm phân phối chi phí không đồng đều. Đối với Southeast, các quan sát có chi phí lớn nhiều khả năng đóng góp đáng kể vào việc nâng mức trung bình, trong khi phần lớn khách hàng không nhất thiết phải chịu mức chi phí cao hơn khách hàng tại những khu vực khác.

Kết quả này cũng phù hợp với độ lệch chuẩn cao nhất được ghi nhận ở Southeast trong Bảng 4.4.1, cho thấy sự phân tán chi phí tại khu vực này lớn hơn đáng kể. Ngược lại, Northwest và Southwest có mức trung bình và trung vị tương đối thấp, đồng thời chênh lệch giữa hai thước đo nhỏ hơn Southeast.

Về ý nghĩa kinh tế, kết quả cho thấy doanh nghiệp bảo hiểm cần phân biệt giữa mức chi phí bình quân của một nhóm khách hàng và mức chi phí điển hình của nhóm đó. Nếu chỉ sử dụng trung bình để đánh giá rủi ro theo khu vực, doanh nghiệp có thể đưa ra nhận định thiếu chính xác về đặc điểm chi phí của phần lớn khách hàng, đặc biệt tại những khu vực có phân phối lệch phải hoặc xuất hiện nhiều quan sát chi phí cao.

Tuy nhiên, biểu đồ chỉ phản ánh sự khác biệt trong mẫu nghiên cứu và chưa đủ để kết luận rằng chi phí y tế trung bình của các khu vực thực sự khác nhau trong tổng thể. Vì vậy, nhóm tiếp tục thực hiện kiểm định thống kê tại mục 4.4.3.

3.4.3. Kiểm định giả thuyết về sự khác biệt chi phí y tế giữa các khu vực

Thống kê mô tả và biểu đồ cột cho thấy mức chi phí y tế trung bình có sự chênh lệch giữa bốn khu vực. Tuy nhiên, những khác biệt này có thể phát sinh do biến động ngẫu nhiên của mẫu. Để xác định liệu có bằng chứng thống kê về sự khác biệt

trung bình giữa các nhóm hay không, nhóm sử dụng kiểm định phương sai một yếu tố (One-way ANOVA).

Do phân phối của biến charges có xu hướng lệch phải và mức độ phân tán khác nhau giữa các khu vực, nhóm thực hiện thêm kiểm định Levene, Welch ANOVA và Kruskal-Wallis để đánh giá tính vững của kết quả.

Trong đó, One-way ANOVA kiểm tra sự bằng nhau của các trung bình nhóm dưới giả định phương sai đồng nhất. Levene được sử dụng để kiểm tra giả định đồng nhất phương sai. Khi giả định này không được đáp ứng, Welch ANOVA là lựa chọn phù hợp hơn để kiểm tra sự khác biệt trung bình. Kiểm định Kruskal-Wallis được sử dụng bổ sung để đánh giá sự khác biệt về phân phối thứ hạng giữa các nhóm mà không đòi hỏi dữ liệu có phân phối chuẩn.

Nhóm sử dụng câu lệnh:

- nhom_chiphi: Tạo danh sách gồm bốn mảng số liệu chi phí tương ứng với bốn khu vực.

- stats.f_oneway(*nhom_chiphi): Thực hiện kiểm định One-way ANOVA; dấu * truyền từng mảng dữ liệu làm một đối số riêng.

- stats.levene(): Kiểm tra sự đồng nhất phương sai giữa các khu vực.

- center='median': Sử dụng biến thể Levene dựa trên trung vị, ít nhạy hơn với các giá trị cực đoan.

- anova_oneway(..., use_var='unequal'): Thực hiện Welch ANOVA, không yêu cầu phương sai các nhóm bằng nhau.

- stats.kruskal(): Thực hiện kiểm định Kruskal-Wallis dựa trên thứ hạng của dữ liệu.

- pd.DataFrame(): Tạo bảng tổng hợp kết quả các kiểm định.

- alpha = 0.05: Thiết lập mức ý nghĩa 5% để đánh giá giả thuyết.

```
# 4.4.3. Kiểm định sự khác biệt chi phí giữa 4 khu vực

from scipy import stats
from statsmodels.stats.oneway import anova_oneway

# Tạo danh sách dữ liệu charges theo từng khu vực
nhom_chiphi = [
    df_region[df_region['region'] == kv]['charges'].values
    for kv in region_order
]

# 1. Kiểm định ANOVA một yếu tố
f_stat, p_anova = stats.f_oneway(*nhom_chiphi)

# 2. Kiểm định Levene: đồng nhất phương sai
lev_stat, p_levene = stats.levene(
    *nhom_chiphi,
    center='median'
)

# 3. Kiểm định Welch ANOVA
welch_result = anova_oneway(
    nhom_chiphi,
    use_var='unequal'
)

# 4. Kiểm định Kruskal-Wallis
h_stat, p_kruskal = stats.kruskal(*nhom_chiphi)
```

```
# 5. Tổng hợp kết quả kiểm định
bang_kiem_dinh = pd.DataFrame({
    'Kiem_dinh': [
        'ANOVA',
        'Levene',
        'Welch ANOVA',
        'Kruskal-Wallis'
    ],
    'Thong_ke': [
        f_stat,
        lev_stat,
        welch_result.statistic,
        h_stat
    ],
    'p_value': [
        p_anova,
        p_levene,
        welch_result.pvalue,
        p_kruskal
    ]
})

# Hiển thị kết quả
display(bang_kiem_dinh.round(6))

# 6. Đánh giá theo Welch ANOVA
alpha = 0.05

if welch_result.pvalue < alpha:
    print("Bac bo H0 theo Welch ANOVA")
else:
    print("Chua du co so bac bo H0 theo Welch ANOVA")
```

Bảng 4.4.2. Kết quả kiểm định sự khác biệt chi phí y tế giữa các khu vực

	Kiem_dinh	Thong_ke	p_value
0	ANOVA	2.926140	0.032763
1	Levene	5.553480	0.000869
2	Welch ANOVA	2.566223	0.053489
3	Kruskal-Wallis	4.622507	0.201620

```
Chua du co so bac bo H0 theo Welch ANOVA
```

Kết quả One-way ANOVA cho thấy giá trị thống kê F đạt 2,9261, với p-value bằng 0,032763, nhỏ hơn mức ý nghĩa 0,05. Nếu chỉ xét kiểm định này, nhóm có thể bác bỏ giả thuyết H_0 và kết luận rằng tồn tại bằng chứng thống kê về sự khác biệt chi phí trung bình giữa ít nhất hai khu vực.

Tuy nhiên, kết quả kiểm định Levene ghi nhận p-value bằng 0,000869, nhỏ hơn đáng kể so với 0,05. Điều này cho thấy giả định phương sai đồng nhất giữa các nhóm không được đáp ứng. Kết quả phù hợp với thống kê mô tả khi Southeast có độ lệch chuẩn cao hơn rõ rệt so với những khu vực còn lại. Vì vậy, kết luận từ One-way ANOVA truyền thống cần được xem xét thận trọng.

Khi sử dụng Welch ANOVA, phương pháp phù hợp hơn trong trường hợp phương sai không đồng nhất, p-value tăng lên 0,053489, lớn hơn mức ý nghĩa 0,05. Do đó, nhóm chưa có đủ cơ sở để bác bỏ giả thuyết các khu vực có cùng chi phí trung bình theo kiểm định Welch.

Bên cạnh đó, kiểm định Kruskal-Wallis ghi nhận p-value bằng 0,201620, cũng lớn hơn 0,05. Kết quả này cho thấy chưa có đủ bằng chứng thống kê về sự khác biệt phân phối thứ hạng chi phí giữa bốn khu vực. Cần lưu ý rằng Kruskal-Wallis không trực tiếp kiểm định sự bằng nhau của các giá trị trung bình, nên kết quả được sử dụng để bổ trợ cho phân tích thay vì thay thế hoàn toàn kiểm định Welch ANOVA.

Như vậy, kết quả kiểm định chưa hoàn toàn nhất quán. Mặc dù ANOVA truyền thống đưa ra bằng chứng về sự khác biệt trung bình, kiểm định Welch phù hợp hơn với đặc điểm phương sai không đồng nhất của mẫu lại không đạt ngưỡng ý nghĩa 5%.

Phát hiện quan trọng thứ hai: Sự chênh lệch chi phí trung bình quan sát được giữa các khu vực chưa đủ vững để khẳng định rằng bản thân yếu tố địa lý có mối liên hệ độc lập và đáng kể với chi phí y tế.

Để đánh giá mức độ khác biệt về mặt thực tiễn, nhóm tiếp tục xem xét hệ số đo lường quy mô ảnh hưởng (effect size) thông qua chỉ tiêu eta-squared (η^2).

Code bổ sung: Đo lường quy mô ảnh hưởng

```python
# Đo lường mức độ khác biệt bằng Eta-squared

# Trung bình chi phí toàn bộ mẫu
mean_all = df_region['charges'].mean()

# Tổng bình phương giữa các nhóm
ss_between = sum(
    len(nhom) * (nhom['charges'].mean() - mean_all)**2
    for _, nhom in df_region.groupby('region')
)

# Tổng bình phương toàn bộ
ss_total = ((df_region['charges'] - mean_all)**2).sum()

# Hệ số Eta-squared
eta_squared = ss_between / ss_total

print("Eta-squared:", round(eta_squared, 4))
print("Ty le (%):", round(eta_squared * 100, 2))
```

```
Eta-squared: 0.0065
Ty le (%): 0.65
```

Hệ số eta-squared đạt khoảng 0,0065, tương đương 0,65%, cho thấy sự phân nhóm theo khu vực địa lý chỉ giải thích được một tỷ lệ rất nhỏ trong tổng biến thiên chi phí y tế của mẫu nghiên cứu.

Kết quả này bổ sung cho các kiểm định thống kê và cho thấy rằng dù chênh lệch trung bình giữa Southeast và Southwest có thể đạt gần 2.400 USD, sự khác biệt giữa các khu vực vẫn tương đối nhỏ so với mức độ biến động chi phí giữa các cá nhân trong cùng khu vực.

Do đó, yếu tố địa lý chưa thể được xem là một biến có khả năng giải thích mạnh sự khác biệt chi phí y tế khi được xem xét độc lập.

3.4.4. Phân tích sự khác biệt chi phí giữa các khu vực theo tình trạng hút thuốc

Kết quả thống kê mô tả cho thấy Southeast có chi phí y tế trung bình cao nhất, đồng thời ghi nhận mức độ phân tán chi phí lớn hơn các khu vực khác. Tuy nhiên, các kiểm định thống kê chưa cung cấp bằng chứng nhất quán về sự khác biệt chi phí giữa các khu vực.

Một khả năng cần được xem xét là sự chênh lệch trung bình có liên quan đến cơ cấu khách hàng, đặc biệt là tỷ lệ người hút thuốc tại từng khu vực. Kết quả từ những phân tích trước đó đã cho thấy tình trạng hút thuốc gắn với mức chênh lệch lớn về chi phí y tế, do đó sự khác biệt trong tỷ trọng người hút thuốc có thể ảnh hưởng đáng kể đến mức trung bình chung của từng khu vực.

Trên cơ sở đó, nhóm tiến hành thống kê tỷ lệ khách hàng hút thuốc và chi phí trung bình theo tình trạng hút thuốc tại bốn khu vực, nhằm đánh giá liệu cơ cấu khách hàng có góp phần lý giải sự chênh lệch chi phí theo địa lý hay không.

a. Thống kê tỷ lệ hút thuốc theo khu vực

Câu lệnh:

- pd.crosstab(): Tạo bảng chéo thể hiện số lượng khách hàng hút thuốc và không hút thuốc theo từng khu vực.
- reindex(region_order): Sắp xếp các khu vực thống nhất với những bảng trước.
- bang_smoker['yes']: Truy xuất số khách hàng hút thuốc.
- bang_smoker.sum(axis=1): Tính tổng số khách hàng theo từng khu vực.
- Nhân 100: Chuyển tỷ lệ thành phần trăm.

```
# BẢNG 4
# 4.4.4. Kiểm tra tỷ lệ hút thuốc theo khu vực

# Đếm số người hút thuốc và không hút thuốc
bang_smoker = pd.crosstab(
    df_region['region'],
    df_region['smoker']
)

# Sắp xếp theo thứ tự khu vực
bang_smoker = bang_smoker.reindex(region_order)

# Tính tỷ lệ hút thuốc (%)
bang_smoker['Ty_le_hut_thuoc'] = (
    bang_smoker['yes'] / bang_smoker.sum(axis=1) * 100
)

# Hiển thị kết quả
display(bang_smoker.round(2))
```

Bảng 4.4.3. Cơ cấu khách hàng theo tình trạng hút thuốc và khu vực

smoker region	no	yes	Ty_le_hut_thuoc
northeast	257	67	20.68
northwest	266	58	17.90
southeast	273	91	25.00
southwest	267	58	17.85

Kết quả cho thấy Southeast có tỷ lệ khách hàng hút thuốc cao nhất, đạt 25,00%, tương ứng 91 trong tổng số 364 quan sát. Trong khi đó, Southwest có tỷ lệ thấp nhất, đạt khoảng 17,85%. Chênh lệch giữa hai khu vực lên tới 7,15 điểm phần trăm.

Đáng chú ý, Southeast đồng thời là khu vực có chi phí y tế trung bình cao nhất theo Bảng 4.4.1. Sự trùng hợp này gợi ý rằng mức chi phí trung bình cao tại Southeast có thể liên quan một phần đến tỷ trọng khách hàng hút thuốc lớn hơn so với các khu vực còn lại.

Tuy nhiên, tỷ lệ hút thuốc cao hơn chưa đủ để kết luận đây là yếu tố giải thích toàn bộ sự khác biệt chi phí. Vì vậy, nhóm tiếp tục phân tích chi phí trung bình riêng trong từng nhóm hút thuốc và không hút thuốc.

b. So sánh chi phí theo khu vực và tình trạng hút thuốc

Giải thích câu lệnh:

- groupby(['region', 'smoker']): Phân chia dữ liệu đồng thời theo hai tiêu chí khu vực và tình trạng hút thuốc.

- agg(): Tính các chỉ tiêu thống kê cho từng nhóm khách hàng.

- mean và median: So sánh mức chi phí bình quân và điển hình giữa các nhóm.

```
# Thống kê chi phí theo khu vực và tình trạng hút thuốc

bang_region_smoker = df_region.groupby(
    ['region', 'smoker']
)['charges'].agg(
    So_quan_sat='count',
    Trung_binh='mean',
    Trung_vi='median'
)

# Hiển thị kết quả
display(bang_region_smoker.round(2))
```

region	smoker	So_quan_sat	Trung_binh	Trung_vi
northeast	no	257	9165.53	8342.91
	yes	67	29673.54	28101.33
northwest	no	266	8582.47	7259.23
	yes	58	30192.00	27489.00
southeast	no	273	8032.22	6652.53
	yes	91	34845.00	37484.45
southwest	no	267	8019.28	7348.14
	yes	58	32269.06	35165.26

Bảng 3.4.4. Chi phí y tế trung bình theo khu vực và tình trạng hút thuốc

Trực quan hoá kết quả phân nhóm:

```
# Vẽ biểu đồ cột chi phí theo khu vực và hút thuốc

# Tính chi phí trung bình của từng nhóm
mean_smoker = df_region.groupby(
    ['region', 'smoker']
)['charges'].mean().unstack()

# Sắp xếp thứ tự khu vực
mean_smoker = mean_smoker.reindex(region_order)

# Thiết lập vị trí cột
x = np.arange(len(region_order))
width = 0.35

plt.figure(figsize=(11, 6))

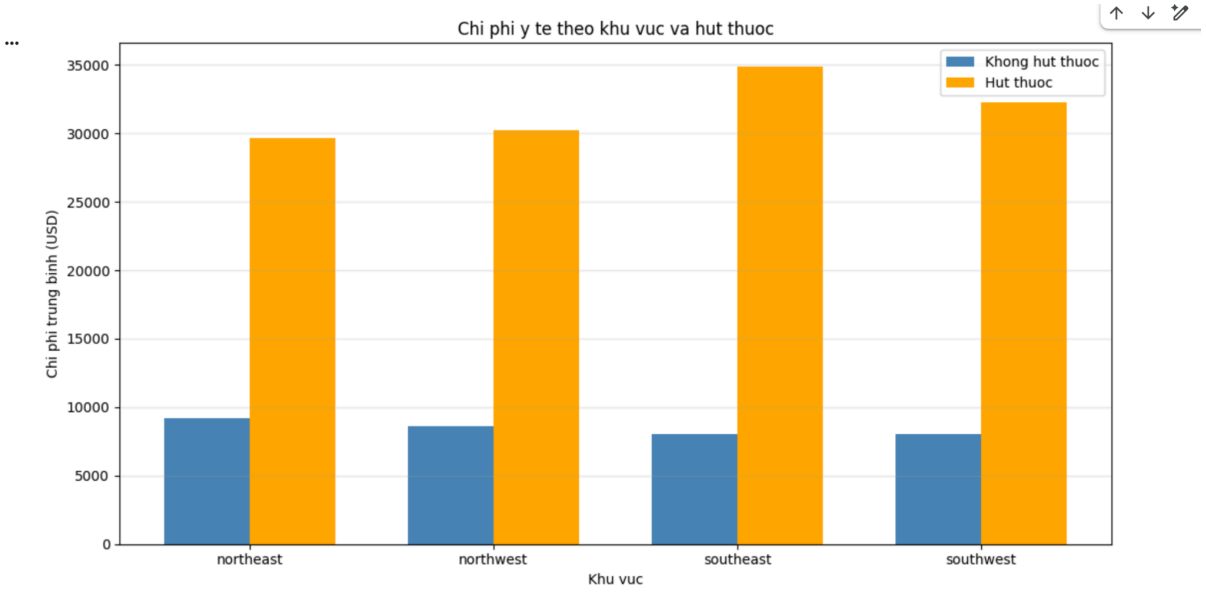
# Cột không hút thuốc
plt.bar(
    x - width/2,
    mean_smoker['no'],
    width,
    label='Khong hut thuoc',
    color='steelblue'
)


# Cột hút thuốc
plt.bar(
    x + width/2,
    mean_smoker['yes'],
    width,
    label='Hut thuoc',
    color='orange'
)

# Hoàn thiện biểu đồ
plt.title('Chi phi y te theo khu vuc va hut thuoc')
plt.xlabel('Khu vuc')
plt.ylabel('Chi phi trung binh (USD)')
plt.xticks(x, region_order)
plt.legend()
plt.grid(axis='y', alpha=0.3)

plt.tight_layout()
plt.show()
```

Hình 3.4.2. So sánh chi phí y tế theo khu vực và tình trạng hút thuốc



Kết quả cho thấy sự khác biệt về chi phí y tế giữa hai nhóm hút thuốc và không hút thuốc lớn hơn đáng kể so với mức chênh lệch trung bình giữa các khu vực địa lý.

Ở cả bốn khu vực, chi phí trung bình của nhóm hút thuốc đều vượt đáng kể nhóm không hút thuốc. Đặc biệt, tại Southeast, mức chi phí trung bình của người hút thuốc đạt 34.845,00 USD, cao hơn khoảng 26.813 USD so với người không hút thuốc tại cùng khu vực, tương đương khoảng 4,34 lần.

Một phát hiện đáng chú ý khác là thứ hạng chi phí của các khu vực thay đổi khi phân chia theo tình trạng hút thuốc. Trong nhóm không hút thuốc, Northeast ghi nhận chi phí trung bình cao nhất, đạt 9.165,53 USD, trong khi Southeast chỉ đạt 8.032,22 USD, thấp hơn cả Northeast và Northwest. Ngược lại, trong nhóm hút thuốc, Southeast có mức chi phí cao nhất với 34.845,00 USD.

Sự thay đổi thứ hạng này cho thấy mức chi phí trung bình cao của Southeast không phản ánh việc tất cả các nhóm khách hàng tại đây đều có chi phí lớn hơn. Thay vào đó, mức trung bình chung có thể chịu ảnh hưởng bởi hai yếu tố: tỷ trọng người hút thuốc cao hơn và chi phí đặc biệt lớn trong nội bộ nhóm hút thuốc.

Kết quả vì vậy cho thấy sự khác biệt về cơ cấu khách hàng là yếu tố cần được xem xét khi so sánh chi phí giữa các khu vực. Nếu không phân tách theo tình trạng hút thuốc, việc đánh giá rủi ro dựa trên mức chi phí bình quân chung có thể dẫn đến nhận định rằng Southeast là khu vực có chi phí y tế cao hơn một cách đồng nhất, trong khi thực tế mẫu nghiên cứu phản ánh sự khác biệt đáng kể giữa các nhóm khách hàng.

c. Chuẩn hóa cơ cấu hút thuốc để kiểm tra độ nhạy của kết quả

Để làm rõ hơn vai trò của cơ cấu khách hàng, nhóm thực hiện một phân tích chuẩn hóa mô tả bằng cách giả định bốn khu vực có cùng tỷ lệ hút thuốc và không hút

thuốc như toàn bộ mẫu nghiên cứu. Chi phí trung bình của từng nhóm hút thuốc tại mỗi khu vực vẫn được giữ nguyên.

Phương pháp này không nhằm xác định quan hệ nhân quả, mà giúp đánh giá mức chênh lệch chi phí giữa các khu vực có thay đổi hay không khi loại bỏ sự khác biệt về tỷ trọng hút thuốc trong phép so sánh.

```
# Chuẩn hóa cơ cấu hút thuốc giữa các khu vực

# Tính tỷ lệ hút thuốc của toàn bộ mẫu
ty_le_chung = df_region['smoker'].value_counts(
    normalize=True
).reindex(['no', 'yes'])

# Tính chi phí trung bình theo khu vực và hút thuốc
mean_by_group = df_region.pivot_table(
    index='region',
    columns='smoker',
    values='charges',
    aggfunc='mean'
)

# Tính chi phí trung bình đã chuẩn hóa cơ cấu
mean_adjusted = (
    mean_by_group * ty_le_chung
).sum(axis=1)

# Tạo bảng so sánh trước và sau điều chỉnh
bang_dieu_chinh = pd.DataFrame({
    'Trung_binh_goc': df_region.groupby(
        'region'
    )['charges'].mean(),
    'Trung_binh_dieu_chinh': mean_adjusted
})

# Sắp xếp các khu vực
bang_dieu_chinh = bang_dieu_chinh.reindex(region_order)

# Hiển thị
display(bang_dieu_chinh.round(2))
```

Bảng 3.4.5. So sánh chi phí trung bình trước và sau khi chuẩn hóa cơ cấu hút thuốc

region	Trung_binh_goc	Trung_binh_dieu_chinh
northeast	13406.38	13368.37
northwest	12450.84	13011.05
southeast	14735.41	13527.13
southwest	12346.94	12988.95

Trước khi chuẩn hóa cơ cấu hút thuốc, mức chênh lệch chi phí trung bình giữa khu vực cao nhất và thấp nhất đạt khoảng 2.388,47 USD. Sau khi áp dụng cùng một tỷ trọng hút thuốc cho cả bốn khu vực, chênh lệch này giảm xuống còn khoảng 538,18 USD, tương đương mức giảm khoảng 77,5%.

Đáng chú ý, chi phí trung bình đã chuẩn hóa của Southeast giảm từ 14.735,41 USD xuống 13.527,13 USD, trong khi mức tương ứng của Southwest tăng từ 12.346,94 USD lên 12.988,95 USD. Điều này cho thấy một phần đáng kể chênh lệch

chi phí bình quân ban đầu giữa các khu vực có liên quan đến sự khác biệt về tỷ trọng khách hàng hút thuốc trong mẫu.

Sau chuẩn hóa, Southeast vẫn có mức chi phí trung bình cao nhất, nhưng khoảng cách với ba khu vực còn lại đã thu hẹp rõ rệt. Kết quả củng cố nhận định rằng việc đánh giá chi phí theo địa lý cần kết hợp xem xét đặc điểm khách hàng, thay vì chỉ sử dụng biến khu vực riêng lẻ.

Tuy nhiên, phương pháp chuẩn hóa trên chỉ điều chỉnh cơ cấu hút thuốc, chưa kiểm soát đồng thời các yếu tố khác như tuổi, BMI, giới tính hoặc số người phụ thuộc. Do đó, kết quả không chứng minh rằng khác biệt về tỷ lệ hút thuốc là nguyên nhân tạo ra 77,5% chênh lệch chi phí, mà chỉ cho thấy mức chênh lệch giữa các khu vực giảm mạnh trong phép so sánh mô tả khi sử dụng cùng một cơ cấu hút thuốc.

3.4.5. Kết luận Bảng 4

Kết quả phân tích cho thấy chi phí y tế cá nhân có sự khác biệt về mặt mô tả giữa bốn khu vực địa lý tại Hoa Kỳ. Trong đó, Southeast có chi phí trung bình cao nhất, đạt 14.735,41 USD, trong khi Southwest có mức thấp nhất, đạt 12.346,94 USD. Tuy nhiên, Southeast không phải khu vực có chi phí trung vị cao nhất. Mức trung vị lớn nhất thuộc về Northeast, đạt 10.057,65 USD. Sự khác biệt về thứ hạng giữa trung bình và trung vị, kết hợp với độ lệch chuẩn lớn tại Southeast, cho thấy các quan sát có chi phí cao đóng vai trò đáng chú ý trong việc hình thành mức chi phí bình quân của khu vực này.

Kết quả kiểm định thống kê chưa cung cấp bằng chứng nhất quán về sự khác biệt chi phí giữa các khu vực. Mặc dù One-way ANOVA có p-value nhỏ hơn 0,05, kiểm định Levene cho thấy giả định đồng nhất phương sai không được đáp ứng. Khi sử dụng Welch ANOVA, p-value đạt 0,0535, chưa đủ cơ sở để bác bỏ giả thuyết các trung bình bằng nhau ở mức ý nghĩa 5%. Đồng thời, hệ số eta-squared chỉ đạt khoảng 0,65%, cho thấy khu vực địa lý có khả năng giải thích rất hạn chế đối với sự biến động chi phí y tế khi được xem xét độc lập.

Phân tích bổ sung theo tình trạng hút thuốc cho thấy một phát hiện quan trọng hơn. Southeast là khu vực có tỷ lệ người hút thuốc cao nhất, đạt 25,00%, đồng thời ghi nhận chi phí trung bình của nhóm hút thuốc cao nhất trong bốn khu vực. Khi chuẩn hóa tỷ trọng hút thuốc giữa các khu vực theo cơ cấu chung của mẫu nghiên cứu, mức chênh lệch chi phí trung bình lớn nhất giảm từ 2.388,47 USD xuống còn 538,18 USD, tương đương giảm khoảng 77,5%. Điều này cho thấy sự khác biệt về cơ cấu khách hàng có liên quan đáng kể đến mức chênh lệch chi phí được quan sát theo địa lý.

Về ý nghĩa ứng dụng, kết quả gợi ý rằng các doanh nghiệp bảo hiểm không nên đánh giá rủi ro chi phí chỉ dựa trên khu vực cư trú của khách hàng. Thay vào đó, việc xây dựng các mô hình dự báo cần kết hợp đồng thời yếu tố địa lý với những đặc điểm cá nhân như tình trạng hút thuốc, độ tuổi và BMI. Cách tiếp cận này có thể hỗ trợ

nhận diện rõ hơn các nhóm khách hàng có mức chi phí dự kiến khác nhau, đồng thời hạn chế những sai lệch phát sinh khi so sánh các nhóm có cơ cấu đặc điểm không đồng nhất.

Tuy nhiên, những phát hiện trên vẫn tồn tại một số giới hạn. Thứ nhất, dữ liệu mang tính cắt ngang nên không phản ánh được sự thay đổi chi phí của cùng một cá nhân theo thời gian. Thứ hai, biến khu vực chỉ chia thành bốn nhóm địa lý lớn và chưa cung cấp thông tin chi tiết về địa điểm cư trú, mức giá dịch vụ y tế, khả năng tiếp cận chăm sóc sức khỏe hoặc đặc điểm cơ sở y tế. Thứ ba, các kiểm định và phân tích phân nhóm chưa kiểm soát đồng thời toàn bộ những biến có khả năng liên quan đến chi phí. Vì vậy, kết quả không đủ cơ sở để khẳng định khu vực cư trú hoặc tình trạng hút thuốc tạo ra tác động nhân quả trực tiếp lên mức chi phí y tế.

Nhìn chung, phát hiện cốt lõi của Bảng 4 là sự khác biệt chi phí theo địa lý có thể phản ánh một phần sự khác biệt về cơ cấu khách hàng giữa các khu vực. Trong bộ dữ liệu nghiên cứu, khu vực cư trú có khả năng giải thích chi phí hạn chế khi được xem xét riêng lẻ, trong khi tình trạng hút thuốc là yếu tố phân nhóm đáng chú ý. Do đó, việc phân tích đồng thời các đặc điểm cá nhân và yếu tố địa lý là hướng tiếp cận phù hợp hơn cho hoạt động dự báo chi phí, đánh giá rủi ro và hỗ trợ ra quyết định trong lĩnh vực bảo hiểm.

3.5. Mối quan hệ giữa các biến định lượng và chi phí y tế cá nhân

Câu hỏi nghiên cứu: Các yếu tố định lượng gồm độ tuổi (age), chỉ số khối cơ thể (bmi) và số người phụ thuộc (children) có mối tương quan tuyến tính với chi phí y tế cá nhân (charges) hay không? Nếu có, mức độ và chiều hướng tương quan như thế nào?

Nhóm xây dựng các cặp giả thuyết:

Mối quan hệ	**Giả thuyết H_0**	**Giả thuyết H_1**
age - charges	Không có tương quan tuyến tính trong tổng thể ($\rho = 0$)	Có tương quan tuyến tính ($\rho \neq 0$)
bmi - charges	$\rho = 0$	$\rho \neq 0$
children - charges	$\rho = 0$	$\rho \neq 0$

3.5.1. Tính ma trận tương quan Pearson

Để xác định chiều hướng và mức độ tương quan giữa các biến định lượng trong bộ dữ liệu Insurance, nhóm nghiên cứu sử dụng phương pháp phân tích tương quan Pearson. Phương pháp này cho phép đo lường mức độ liên hệ tuyến tính giữa hai biến thông qua hệ số tương quan Pearson (r), có giá trị dao động từ -1 đến +1.

Nhóm sử dụng các câu lệnh Python sau:

- numeric_cols = ['age', 'bmi', 'children', 'charges']: Tạo danh sách gồm bốn biến định lượng cần phân tích, bao gồm độ tuổi, chỉ số khối cơ thể, số người phụ thuộc và chi phí y tế cá nhân.
- df[numeric_cols]: Trích xuất dữ liệu của bốn biến đã lựa chọn từ DataFrame để thực hiện phân tích tương quan.
- corr_matrix = df[numeric_cols].corr(method='pearson'): Tính hệ số tương quan Pearson giữa từng cặp biến và lưu kết quả dưới dạng ma trận tương quan.
- display(corr_matrix.round(3)): Hiển thị ma trận tương quan và làm tròn các hệ số đến ba chữ số thập phân, giúp thuận tiện cho việc quan sát và so sánh.

```python
# BẢNG 5
# MỐI QUAN HỆ BIẾN ĐỊNH LƯỢNG VỚI CHI PHÍ Y TẾ
# Chọn biến cho phân tích
numeric_cols = ['age', 'bmi', 'children', 'charges']

# Tính hệ số tương quan Pearson
corr_matrix = df[numeric_cols].corr(method='pearson')

# Hiển thị hệ số tương quan từng cặp biến
display(corr_matrix.round(3))
```

	age	bmi	children	charges
age	1.000	0.109	0.042	0.299
bmi	0.109	1.000	0.013	0.198
children	0.042	0.013	1.000	0.068
charges	0.299	0.198	0.068	1.000

Theo số liệu tham khảo của bộ Insurance gốc, cả ba biến đều có tương quan dương với chi phí y tế (charges), cụ thể:

- **Độ tuổi (age):** Hệ số tương quan đạt 0,299, cao nhất trong ba biến, cho thấy độ tuổi càng cao thì chi phí y tế có xu hướng tăng.
- **Chỉ số BMI (bmi):** Hệ số tương quan đạt 0,198, phản ánh mối tương quan dương nhưng tương đối yếu với chi phí y tế.
- **Số người phụ thuộc (children):** Hệ số tương quan chỉ đạt 0,068, cho thấy mối liên hệ tuyến tính rất yếu với chi phí y tế.

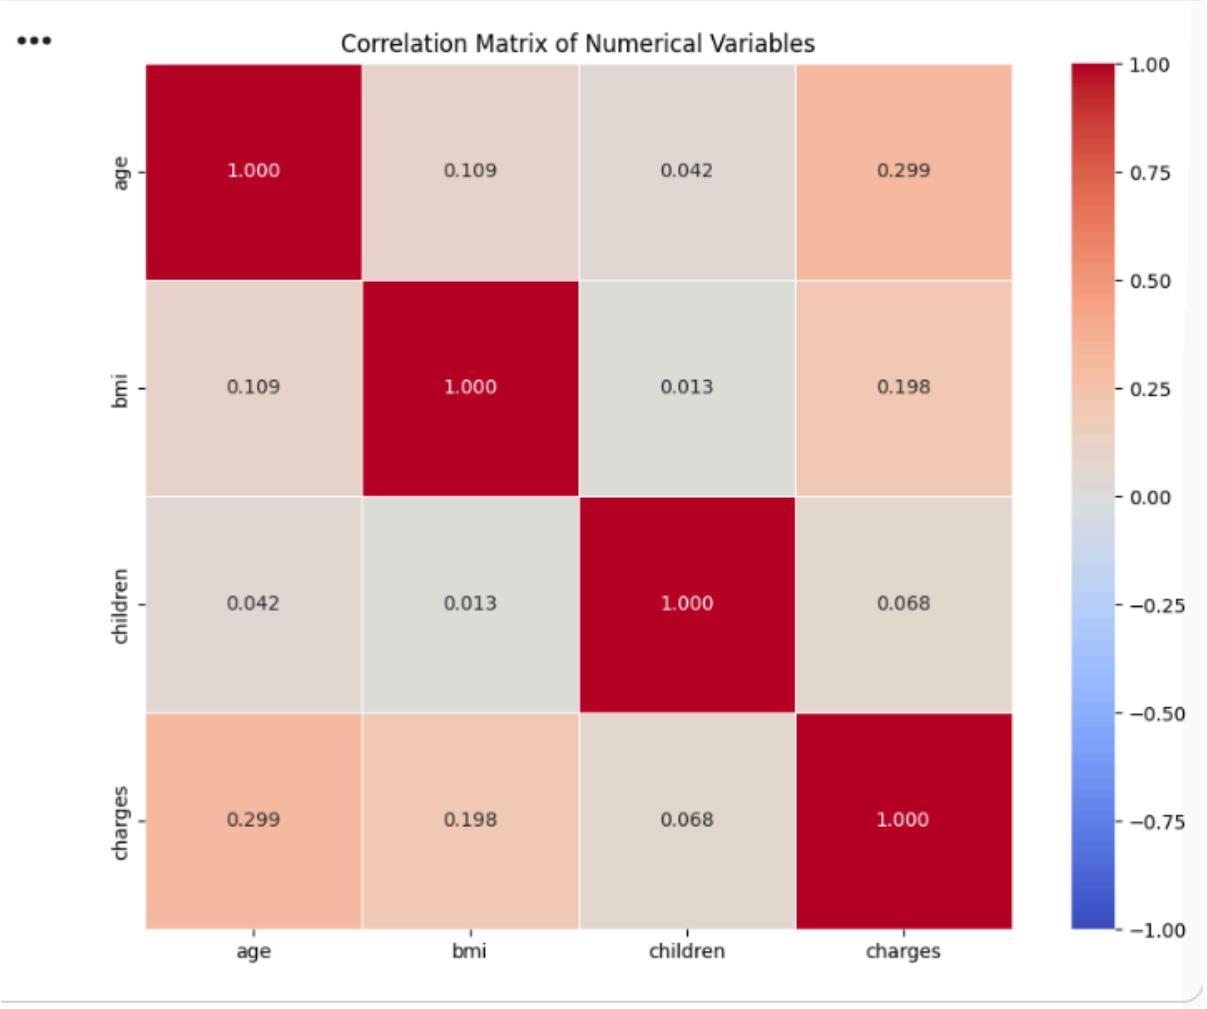
Ngoài ra, hệ số tương quan giữa các biến giải thích đều thấp, dao động từ 0,013 đến 0,109, cho thấy không có mối tương quan tuyến tính mạnh giữa chúng.

3.5.1. Trực quan hóa ma trận bằng Heatmap

```
#BẢNG 5
# Tạo biểu đồ heatmap
plt.figure(figsize=(9, 7))

sns.heatmap(
    corr_matrix,
    annot=True,
    fmt=".3f",
    cmap="coolwarm",
    vmin=-1,
    vmax=1,
    center=0,
    linewidths=0.5,
    square=True
)

plt.title("Correlation Matrix of Numerical Variables")
plt.tight_layout()
plt.show()
```



Biểu đồ Heatmap được sử dụng nhằm trực quan hóa mức độ và chiều hướng tương quan tuyến tính giữa các biến định lượng trong bộ dữ liệu Insurance, bao gồm độ tuổi (age), chỉ số khối cơ thể (bmi), số người phụ thuộc (children) và chi phí y tế (charges). Thông qua hệ số tương quan Pearson, nhóm nghiên cứu đánh giá mối liên hệ giữa từng yếu tố với chi phí y tế cá nhân.

Dựa trên các hệ số tương quan tham khảo của bộ dữ liệu gốc, có thể rút ra một số nhận định sau:

Độ tuổi có mối tương quan dương rõ nhất với chi phí y tế trong ba biến giải thích được khảo sát. Hệ số tương quan giữa age và charges đạt khoảng 0,299, phản ánh mối tương quan tuyến tính dương ở mức yếu đến trung bình. Điều này cho thấy những cá nhân có độ tuổi cao hơn có xu hướng ghi nhận chi phí y tế lớn hơn. Chỉ số BMI có mối tương quan dương nhưng tương đối yếu. Hệ số tương quan giữa bmi và charges đạt khoảng 0,198. Kết quả gợi ý rằng những cá nhân có BMI cao hơn có xu hướng ghi nhận chi phí y tế lớn hơn, nhưng mối liên hệ tuyến tính này không mạnh. Do đó, BMI riêng lẻ chưa phản ánh đầy đủ sự khác biệt về chi phí y tế giữa các cá

nhân. Mối liên hệ này cũng có thể thay đổi khi xem xét đồng thời những đặc điểm khác, chẳng hạn như tình trạng hút thuốc.

Bên cạnh đó, số người phụ thuộc có mối tương quan tuyến tính rất yếu với chi phí y tế. Hệ số tương quan giữa children và charges chỉ đạt khoảng 0,068, gần với giá trị 0. Điều này cho thấy trong bộ dữ liệu được khảo sát, số người phụ thuộc không thể hiện mối liên hệ tuyến tính rõ ràng với chi phí y tế cá nhân. Tuy nhiên, kết quả này không đồng nghĩa với việc số người phụ thuộc hoàn toàn không có liên hệ với chi phí, bởi các dạng quan hệ phi tuyến hoặc sự khác biệt giữa các nhóm vẫn có thể tồn tại. Sự tương quan giữa các biến giải thích tương đối thấp. Hệ số tương quan giữa age và bmi khoảng 0,109; giữa age và children khoảng 0,042; giữa bmi và children khoảng 0,013. Điều này cho thấy ba biến giải thích không có mối tương quan tuyến tính mạnh với nhau trong dữ liệu. Tuy nhiên, đây chưa phải bằng chứng đầy đủ để loại trừ hiện tượng đa cộng tuyến nếu nghiên cứu mở rộng sang mô hình hồi quy.

3.5.4. Kiểm định giả thuyết về mối tương quan

Heatmap cho biết chiều hướng và mức độ tương quan trong mẫu, nhưng chưa đủ để kết luận mối tương quan có ý nghĩa thống kê hay không. Vì vậy, cần thực hiện kiểm định Pearson với p-value.

```python
# Bảng 5
# Kiểm định tương quan

# Nhập hàm kiểm định tương quan Pearson
from scipy.stats import pearsonr

# Lựa chọn các biến độc lập cần kiểm định
variables = ['age', 'bmi', 'children']

# Thiết lập mức ý nghĩa thống kê 5%
alpha = 0.05

# Kiểm định tương quan giữa từng biến và chi phí y tế
for var in variables:
    r, p_value = pearsonr(df[var], df['charges'])

    print(f"\nBiến kiểm định: {var}")
    print(f"Hệ số tương quan Pearson: {r:.4f}")
    print(f"Giá trị p-value: {p_value:.6f}")

    if p_value < alpha:
        print("Bác bỏ H0: Mối tương quan có ý nghĩa thống kê")
    else:
        print("Chưa đủ cơ sở bác bỏ H0: Chưa có bằng chứng về mối tương quan tuyến tính có ý nghĩa thống kê")
```

```
Biến kiểm định: age
Hệ số tương quan Pearson: 0.2990
Giá trị p-value: 0.000000
Bác bỏ H0: Mối tương quan có ý nghĩa thống kê

Biến kiểm định: bmi
Hệ số tương quan Pearson: 0.1983
Giá trị p-value: 0.000000
Bác bỏ H0: Mối tương quan có ý nghĩa thống kê

Biến kiểm định: children
Hệ số tương quan Pearson: 0.0680
Giá trị p-value: 0.012852
Bác bỏ H0: Mối tương quan có ý nghĩa thống kê
```

Giải thích câu lệnh:

- from scipy.stats import pearsonr: Nhập hàm tính hệ số tương quan Pearson và kiểm định ý nghĩa thống kê.
- variables: Danh sách các biến cần kiểm định với charges.
- alpha = 0.05: Xác định mức ý nghĩa thống kê 5%.
- for var in variables: Lần lượt thực hiện kiểm định cho từng biến.
- pearsonr(df[var], df['charges']): Trả về hệ số tương quan r và giá trị p_value.
- if p_value < alpha: Kiểm tra liệu p-value có nhỏ hơn mức ý nghĩa đã chọn hay không.

3.5.5. Kết luận

Nguyên tắc kết luận:

- Nếu p-value < 0,05: Bác bỏ H_0, có bằng chứng thống kê về mối tương quan tuyến tính.
- Nếu p-value ≥ 0,05: Chưa đủ cơ sở bác bỏ H_0, không thể khẳng định có tương quan tuyến tính ở mức ý nghĩa 5%.

Đối với mối quan hệ giữa độ tuổi và chi phí y tế, hệ số tương quan Pearson đạt khoảng 0,299 với p-value nhỏ hơn 0,001. Do p-value nhỏ hơn mức ý nghĩa 0,05, nhóm bác bỏ giả thuyết H_0. Kết quả cho thấy có bằng chứng thống kê về mối tương quan tuyến tính dương giữa độ tuổi và chi phí y tế. Đối với chỉ số BMI, hệ số tương quan đạt khoảng 0,198 và p-value nhỏ hơn 0,001. Kết quả cũng cho phép bác bỏ giả

thuyết H_0, cho thấy tồn tại mối tương quan tuyến tính dương có ý nghĩa thống kê giữa BMI và chi phí y tế. Tuy nhiên, hệ số tương quan tương đối thấp phản ánh mức độ liên hệ còn yếu. Như vậy, kết quả phù hợp với kỳ vọng về chiều hướng tương quan, nhưng chưa cho thấy BMI có mối liên hệ tuyến tính mạnh với chi phí y tế. Đối với số người phụ thuộc, hệ số tương quan đạt khoảng 0,068 với p-value xấp xỉ 0,013. Mặc dù kết quả có ý nghĩa thống kê ở mức 5%, hệ số tương quan rất gần 0 cho thấy mức độ liên hệ tuyến tính là rất yếu.

IV. Giai đoạn 4: Đánh giá tác động và khuyến nghị

1. Tóm tắt các phát hiện kinh doanh hay chuyên môn nổi bật nhất.

Trên cơ sở bộ dữ liệu Medical Cost Personal Dataset sau khi tiền xử lý, loại bỏ bản ghi trùng lặp, nghiên cứu tiến hành phân tích 1.337 quan sát nhằm xác định mối liên hệ giữa các đặc điểm cá nhân và chi phí y tế tại Hoa Kỳ. Kết quả phân tích cho thấy chi phí y tế có sự phân hóa đáng kể giữa các nhóm khách hàng. Trong đó, tình trạng hút thuốc là đặc điểm nổi bật nhất, bên cạnh vai trò của độ tuổi và sự kết hợp giữa chỉ số BMI với tình trạng hút thuốc. Ngược lại, khu vực sinh sống và số người phụ thuộc có khả năng giải thích hạn chế hơn khi được xem xét riêng lẻ.

Thứ nhất, tình trạng hút thuốc có mối liên hệ nổi bật với sự khác biệt về chi phí y tế. Chi phí y tế trung bình của nhóm hút thuốc đạt khoảng 32.050,23 USD, cao gấp 3,80 lần nhóm không hút thuốc (8.440,66 USD). Sự khác biệt này tiếp tục được thể hiện qua trung vị chi phí, lần lượt đạt 34.456,35 USD và 7.345,73 USD. Đáng chú ý, trong 139 quan sát có chi phí vượt ngưỡng ngoại lệ theo quy tắc IQR (34.524,78 USD), có tới 136 quan sát thuộc nhóm hút thuốc, tương đương 97,84%. Như vậy, sự chênh lệch chi phí không chỉ xuất hiện ở một số trường hợp cá biệt mà còn thể hiện rõ trong mức chi phí điển hình của hai nhóm khách hàng. Đây là phát hiện có ý nghĩa đối với hoạt động đánh giá rủi ro, bởi tình trạng hút thuốc có thể được xem là một đặc điểm cần ưu tiên xem xét khi phân tích và dự báo chi phí y tế.

Thứ hai, độ tuổi có mối liên hệ thuận chiều với chi phí y tế, nhưng không phải yếu tố duy nhất quyết định mức chi phí của khách hàng. Hệ số tương quan Pearson giữa tuổi và chi phí đạt 0,298, trong khi hệ số Spearman đạt 0,534; cả hai đều có ý nghĩa thống kê. Khi phân nhóm theo độ tuổi, trung vị chi phí tăng liên tục từ 3.220,37 USD ở nhóm 18-29 tuổi lên 12.629,90 USD ở nhóm 50-64 tuổi, tương đương gần 3,92 lần. Tuy nhiên, phân tích sâu hơn cho thấy chi phí của nhóm hút thuốc vốn đã ở mức cao ngay cả khi khách hàng còn trẻ. Cụ thể, trung vị chi phí của người hút thuốc trong nhóm 18-29 tuổi đạt 33.604,25 USD, gần gấp ba lần trung vị của người không hút thuốc thuộc nhóm 50-64 tuổi (12.029,29 USD). Điều này cho thấy tuổi có vai trò

trong việc phân hóa mức chi phí cơ bản, nhưng tình trạng hút thuốc có mối liên hệ nổi bật hơn với sự khác biệt về mặt bằng chi phí giữa các nhóm khách hàng.

Thứ ba, mối liên hệ giữa BMI và chi phí y tế thay đổi đáng kể theo tình trạng hút thuốc. Xét trên toàn bộ mẫu, hệ số tương quan Pearson giữa BMI và chi phí chỉ đạt 0,1984, phản ánh mối liên hệ tuyến tính dương nhưng tương đối yếu. Tuy nhiên, khi phân tích riêng từng nhóm, hệ số này chỉ đạt 0,0841 ở nhóm không hút thuốc, trong khi tăng lên 0,8065 ở nhóm hút thuốc. Kết quả phân nhóm theo ngưỡng BMI cũng cho thấy sự khác biệt rõ rệt: trong nhóm hút thuốc, chi phí trung bình của khách hàng có BMI từ 30 trở lên đạt 41.557,99 USD, gần gấp 1,95 lần nhóm có BMI dưới 30 (21.363,22 USD). Trong khi đó, mức chênh lệch tương ứng ở nhóm không hút thuốc chỉ khoảng 11%. Đây là phát hiện đáng chú ý vì việc xem xét riêng lẻ BMI trên toàn bộ mẫu có thể chưa phản ánh đầy đủ mối liên hệ giữa đặc điểm thể chất và chi phí ở từng nhóm khách hàng. Do đó, việc kết hợp BMI với tình trạng hút thuốc có ý nghĩa hơn so với sử dụng từng biến độc lập.

Thứ tư, khu vực sinh sống có sự khác biệt về chi phí quan sát được nhưng chưa cho thấy khả năng giải thích đáng kể khi xét riêng lẻ. Trong bốn khu vực, Southeast có chi phí trung bình cao nhất (14.735,41 USD), còn Southwest thấp nhất (12.346,94 USD). Tuy nhiên, kết quả kiểm định Welch ANOVA và Kruskal-Wallis đều chưa cung cấp đủ bằng chứng thống kê về sự khác biệt giữa các khu vực ở mức ý nghĩa 5%. Hệ số eta-squared chỉ đạt khoảng 0,65%, cho thấy yếu tố địa lý giải thích một tỷ lệ rất nhỏ biến động chi phí trong mẫu. Đáng chú ý, Southeast cũng là khu vực có tỷ lệ khách hàng hút thuốc cao nhất, đạt 25%. Khi chuẩn hóa tỷ trọng hút thuốc giữa các khu vực, chênh lệch chi phí trung bình lớn nhất giảm từ 2.388,47 USD xuống còn 538,18 USD, tương đương giảm khoảng 77,5%. Kết quả này gợi ý rằng sự khác biệt về cơ cấu khách hàng, đặc biệt là tỷ lệ hút thuốc, có liên quan đáng kể đến chênh lệch chi phí quan sát được giữa các khu vực; do đó, không nên đánh giá rủi ro chỉ dựa trên địa bàn cư trú.

Thứ năm, các biến định lượng còn lại có mức độ liên hệ với chi phí khác nhau. Bên cạnh tuổi và BMI, số người phụ thuộc (children) có hệ số tương quan Pearson với chi phí chỉ đạt khoảng 0,068. Mặc dù kết quả kiểm định có ý nghĩa thống kê ở mức 5%, hệ số tương quan rất gần 0 cho thấy mối liên hệ tuyến tính giữa hai biến là rất yếu. Vì vậy, số người phụ thuộc chưa thể hiện vai trò nổi bật trong việc giải thích sự biến động chi phí y tế nếu chỉ xét riêng lẻ.

Các kết quả cho thấy chi phí y tế cá nhân không phân hóa đồng đều theo từng đặc điểm riêng biệt mà có sự khác biệt đáng kể giữa các nhóm khách hàng. Tình trạng hút thuốc là đặc điểm nổi bật nhất trong các nội dung được phân tích; độ tuổi có mối

liên hệ thuận chiều với chi phí, trong khi vai trò của BMI thể hiện rõ hơn khi kết hợp với tình trạng hút thuốc. Ngược lại, khu vực sinh sống và số người phụ thuộc có khả năng giải thích hạn chế hơn khi xem xét độc lập. Những phát hiện này cho thấy doanh nghiệp bảo hiểm cần tiếp cận khách hàng theo nhiều đặc điểm đồng thời, thay vì dựa vào một chỉ tiêu đơn lẻ, nhằm hỗ trợ đánh giá rủi ro và dự báo chi phí y tế sát với đặc điểm của từng nhóm khách hàng hơn.

Cần lưu ý rằng các kết quả trên phản ánh mối liên hệ thống kê trong bộ dữ liệu quan sát, không chứng minh quan hệ nhân quả giữa các đặc điểm cá nhân và chi phí y tế. Vì vậy, những phát hiện này nên được sử dụng làm cơ sở nhận diện xu hướng và định hướng phân tích sâu hơn, thay vì được xem là căn cứ duy nhất để đưa ra quyết định định phí hoặc phân loại khách hàng.

2. Đề xuất giải pháp mang tính ứng dụng thực tế.

Từ kết quả phân tích, nhóm nhận thấy chi phí y tế cá nhân không phân hóa đồng đều giữa các nhóm đối tượng. Trong đó, tình trạng hút thuốc có mối liên hệ nổi bật nhất với chi phí y tế; độ tuổi có tương quan thuận với chi phí; tác động của BMI thể hiện rõ hơn khi xem xét đồng thời với tình trạng hút thuốc. Ngược lại, sự khác biệt về chi phí giữa các khu vực và số người phụ thuộc chưa cho thấy khả năng giải thích mạnh khi xét riêng lẻ. Trên cơ sở đó, các giải pháp cần tập trung vào phòng ngừa rủi ro sức khỏe, cá nhân hóa hoạt động quản lý chi phí và nâng cao hiệu quả sử dụng dữ liệu trong lĩnh vực bảo hiểm y tế, thay vì áp dụng một chính sách chung cho tất cả mọi người.

2.1. Xây dựng chương trình bảo hiểm gắn với hỗ trợ cai thuốc lá và phòng ngừa rủi ro sức khỏe

Kết quả phân tích cho thấy chi phí y tế trung bình của nhóm hút thuốc cao gấp khoảng 3,8 lần nhóm không hút thuốc. Đáng chú ý, trong 139 quan sát có chi phí vượt ngưỡng ngoại lệ theo quy tắc IQR, có tới 136 quan sát thuộc nhóm hút thuốc. Điều này cho thấy tình trạng hút thuốc là một dấu hiệu phân nhóm quan trọng khi đánh giá nguy cơ chi phí y tế. Vì vậy, thay vì chỉ sử dụng tình trạng hút thuốc để phân loại khách hàng hoặc điều chỉnh mức phí bảo hiểm, doanh nghiệp bảo hiểm có thể chuyển hướng sang mô hình "bảo hiểm kết hợp hỗ trợ thay đổi hành vi sức khỏe".

Cụ thể, doanh nghiệp có thể phối hợp với bệnh viện, cơ sở y tế và đơn vị tư vấn sức khỏe để triển khai chương trình cai thuốc lá cho người tham gia bảo hiểm. Khách hàng đăng ký tự nguyện sẽ được tiếp cận dịch vụ tư vấn, kiểm tra sức khỏe định kỳ, hỗ trợ xây dựng lộ trình cai thuốc và theo dõi tiến trình thông qua ứng dụng di động. Những người duy trì được tiến độ cải thiện có thể nhận các quyền lợi khuyến khích

như giảm một phần phí tái tục, tăng hạn mức chi trả cho một số dịch vụ chăm sóc dự phòng hoặc nhận điểm thưởng để đổi lấy gói khám sức khỏe.

Điểm khác biệt của giải pháp này là chuyển trọng tâm từ việc định giá rủi ro sau khi khách hàng đã phát sinh chi phí sang đầu tư để hạn chế rủi ro trước khi chi phí xuất hiện. Doanh nghiệp bảo hiểm không chỉ đóng vai trò chi trả mà còn trở thành đối tác đồng hành trong quá trình cải thiện sức khỏe của người tham gia. Về phía khách hàng, chương trình tạo thêm động lực để từ bỏ thuốc lá và chủ động chăm sóc sức khỏe; về phía doanh nghiệp, việc giảm thiểu các yếu tố nguy cơ có thể góp phần hạn chế những khoản chi trả y tế lớn trong dài hạn.

2.2. Phát triển gói bảo hiểm và chương trình chăm sóc sức khỏe theo từng giai đoạn tuổi

Kết quả nghiên cứu cho thấy chi phí y tế có xu hướng tăng theo độ tuổi. Cụ thể, chi phí trung vị của nhóm 50-64 tuổi đạt 12.629,90 USD, cao gấp khoảng 3,92 lần nhóm 18-29 tuổi (3.220,37 USD). Hệ số tương quan Spearman giữa tuổi và chi phí đạt 0,534, cho thấy mối liên hệ thuận tương đối rõ giữa thứ hạng độ tuổi và thứ hạng chi phí y tế. Kết quả này gợi ý rằng nhu cầu chăm sóc sức khỏe và khả năng phát sinh chi phí có thể khác nhau đáng kể giữa các giai đoạn tuổi.
Trên cơ sở đó, doanh nghiệp bảo hiểm có thể thiết kế các gói chăm sóc sức khỏe theo vòng đời, thay vì chỉ phân chia khách hàng theo nhóm tuổi để áp dụng mức phí khác nhau. Chẳng hạn:

- Nhóm 18-29 tuổi: Tập trung vào khám sức khỏe cơ bản, tư vấn dinh dưỡng, vận động thể chất và phòng ngừa các hành vi có nguy cơ ảnh hưởng đến sức khỏe lâu dài.
- Nhóm 30-49 tuổi: Bổ sung các chương trình sàng lọc định kỳ, tư vấn kiểm soát cân nặng, huyết áp và các yếu tố nguy cơ chuyển hóa; khuyến khích khách hàng duy trì thói quen khám sức khỏe thay vì chỉ tìm đến bệnh viện khi đã xuất hiện triệu chứng.
- Nhóm 50-64 tuổi: Tăng cường quyền lợi khám chuyên sâu, theo dõi các chỉ số sức khỏe định kỳ, tư vấn quản lý bệnh mạn tính và hỗ trợ tiếp cận dịch vụ y tế phù hợp.

Một hướng triển khai có tính ứng dụng cao là xây dựng "hồ sơ sức khỏe theo vòng đời" trên nền tảng số. Khách hàng có thể theo dõi lịch sử khám chữa bệnh, các chỉ số sức khỏe, lịch tái khám và những khuyến nghị chăm sóc phù hợp với độ tuổi. Hệ thống có thể tự động gửi nhắc lịch khám hoặc cảnh báo khi một số chỉ số sức khỏe thay đổi bất thường, đồng thời kết nối khách hàng với cơ sở y tế khi cần thiết.
Giải pháp này giúp khách hàng chủ động theo dõi sức khỏe, giảm nguy cơ bỏ sót các đợt kiểm tra quan trọng và có thêm thông tin để lựa chọn dịch vụ phù hợp. Đối với doanh nghiệp bảo hiểm, việc phân bổ quyền lợi theo nhu cầu từng giai đoạn tuổi có

thể giúp sử dụng nguồn lực hiệu quả hơn. Tuy nhiên, độ tuổi chỉ nên là một trong những căn cứ thiết kế chương trình, không nên được sử dụng như yếu tố duy nhất để đánh giá tình trạng sức khỏe hoặc quyết định quyền lợi của từng cá nhân.

2.3. Xây dựng chương trình quản lý BMI kết hợp với tình trạng hút thuốc, thay vì chỉ dựa vào chỉ số BMI riêng lẻ

Một phát hiện đáng chú ý của nghiên cứu là mối liên hệ giữa BMI và chi phí y tế có sự khác biệt lớn giữa nhóm hút thuốc và không hút thuốc. Trong toàn bộ mẫu, hệ số tương quan Pearson giữa BMI và chi phí chỉ đạt khoảng 0,198. Tuy nhiên, khi phân tích riêng, hệ số này đạt 0,8065 ở nhóm hút thuốc, trong khi chỉ đạt 0,0841 ở nhóm không hút thuốc. Bên cạnh đó, trong nhóm hút thuốc, chi phí trung bình của những người có BMI từ 30 trở lên đạt 41.557,99 USD, cao gần gấp đôi nhóm có BMI dưới 30 (21.363,22 USD). Ngược lại, chênh lệch chi phí giữa hai nhóm BMI ở những người không hút thuốc nhỏ hơn đáng kể.

Điều này cho thấy việc sử dụng BMI như một tiêu chí độc lập để đánh giá nguy cơ chi phí có thể chưa phản ánh đầy đủ sự khác biệt giữa các nhóm khách hàng. Doanh nghiệp bảo hiểm và các cơ sở chăm sóc sức khỏe có thể triển khai mô hình phân tầng nguy cơ kết hợp, trong đó BMI được xem xét đồng thời với tình trạng hút thuốc và các thông tin sức khỏe phù hợp khác.

Cụ thể, có thể xây dựng các nhóm chăm sóc như sau:

- Người có BMI cao nhưng không hút thuốc: ưu tiên tư vấn dinh dưỡng, vận động thể chất và theo dõi cân nặng định kỳ.
- Người hút thuốc nhưng BMI chưa cao: tập trung vào hỗ trợ cai thuốc, kiểm tra sức khỏe và đánh giá các nguy cơ liên quan.
- Người vừa hút thuốc vừa có BMI cao: được khuyến nghị tham gia chương trình quản lý sức khỏe chuyên sâu hơn, kết hợp tư vấn cai thuốc, dinh dưỡng, vận động và theo dõi sức khỏe định kỳ.

Điểm mới của giải pháp nằm ở việc không đánh đồng những người có cùng BMI là có cùng mức độ rủi ro, mà xây dựng lộ trình chăm sóc dựa trên sự kết hợp giữa nhiều đặc điểm cá nhân. Chẳng hạn, hai khách hàng có cùng BMI có thể được tư vấn những chương trình khác nhau nếu tình trạng hút thuốc và các chỉ số sức khỏe khác biệt.

Để triển khai, doanh nghiệp bảo hiểm có thể phối hợp với các cơ sở y tế xây dựng bộ câu hỏi đánh giá nguy cơ ban đầu, sau đó đề xuất chương trình chăm sóc phù hợp và cập nhật định kỳ. Việc phân tầng cần dựa trên hướng dẫn chuyên môn y tế, bảo

đảm thông tin cá nhân được bảo mật và không sử dụng kết quả phân nhóm đơn thuần để từ chối bảo hiểm hoặc gây bất lợi cho khách hàng. Đây cũng là hướng giúp hoạt động bảo hiểm chuyển từ cách tiếp cận chỉ chi trả khi phát sinh bệnh tật sang mô hình đồng hành và phòng ngừa rủi ro sức khỏe.

2.4. Ứng dụng phân tích dữ liệu để cá nhân hóa đánh giá rủi ro và dự báo chi phí bảo hiểm

Kết quả nghiên cứu cho thấy các yếu tố liên quan đến chi phí y tế có mức độ liên hệ khác nhau. Trong đó, tình trạng hút thuốc tạo ra sự phân hóa rõ rệt; tuổi có mối tương quan thuận với chi phí; BMI thể hiện mối liên hệ đáng chú ý hơn khi kết hợp với tình trạng hút thuốc. Trong khi đó, khu vực cư trú có khả năng giải thích chi phí hạn chế khi xét riêng lẻ và số người phụ thuộc chỉ có tương quan rất yếu với chi phí y tế ($r = 0,068$).

Từ những kết quả này, doanh nghiệp bảo hiểm có thể phát triển hệ thống đánh giá rủi ro và dự báo chi phí theo hồ sơ khách hàng, thay vì sử dụng một vài tiêu chí riêng lẻ hoặc mức chi phí trung bình của toàn bộ danh mục khách hàng. Hệ thống có thể sử dụng các biến hiện có trong nghiên cứu như độ tuổi, BMI, tình trạng hút thuốc và khu vực cư trú để phân nhóm khách hàng, nhận diện những nhóm có khả năng phát sinh chi phí cao và hỗ trợ dự báo nhu cầu chi trả trong tương lai.

Một ứng dụng cụ thể là xây dựng bảng điều khiển quản trị rủi ro (Risk Dashboard) dành cho bộ phận nghiệp vụ bảo hiểm. Bảng điều khiển có thể thể hiện tỷ trọng khách hàng theo nhóm nguy cơ, mức chi phí trung bình, tỷ lệ xuất hiện các khoản chi phí cao và sự thay đổi của các chỉ tiêu theo thời gian. Khi phát hiện một nhóm khách hàng có chi phí tăng bất thường, doanh nghiệp có thể kiểm tra nguyên nhân, đánh giá cơ cấu khách hàng và chủ động điều chỉnh chương trình chăm sóc hoặc dự phòng nguồn lực chi trả.

Đặc biệt, doanh nghiệp cần tránh sử dụng kết quả phân tích khu vực như căn cứ trực tiếp để kết luận khách hàng tại một địa bàn có rủi ro cao hơn. Nghiên cứu cho thấy chênh lệch chi phí giữa các khu vực có thể liên quan đến sự khác biệt về tỷ trọng người hút thuốc trong cơ cấu khách hàng. Do đó, khi so sánh các chi nhánh hoặc thị trường, doanh nghiệp nên chuẩn hóa cơ cấu khách hàng theo những đặc điểm quan trọng như tuổi và tình trạng hút thuốc trước khi đánh giá hiệu quả quản lý chi phí. Cách tiếp cận này hạn chế tình trạng đánh giá sai hiệu quả của một địa bàn chỉ vì nơi đó có tỷ trọng khách hàng thuộc nhóm nguy cơ cao hơn.

Về lâu dài, khi có dữ liệu đầy đủ hơn, doanh nghiệp có thể phát triển mô hình dự báo chi phí y tế bằng các thuật toán học máy, đồng thời kiểm tra mức độ chính xác của mô hình trên những nhóm khách hàng khác nhau. Đây là cơ sở để nâng cao chất

lượng dự báo, hỗ trợ lập kế hoạch tài chính và phân bổ nguồn lực chi trả hợp lý hơn. Tuy nhiên, các kết quả tương quan trong nghiên cứu hiện tại mới là cơ sở ban đầu để lựa chọn biến đầu vào, chưa đủ để khẳng định khả năng dự báo chính xác hoặc quan hệ nhân quả giữa các yếu tố.

2.5. Phát triển mô hình chăm sóc sức khỏe cộng đồng dựa trên nhu cầu thực tế, thay vì phân bổ nguồn lực đồng đều theo khu vực

Kết quả so sánh bốn khu vực cho thấy chi phí trung bình có sự chênh lệch nhất định, trong đó Southeast có mức trung bình cao nhất (14.735,41 USD), còn Southwest thấp nhất (12.346,94 USD). Tuy nhiên, các kiểm định phù hợp hơn trong điều kiện phương sai không đồng nhất và phân phối không chuẩn chưa cung cấp bằng chứng đủ mạnh để khẳng định sự khác biệt chi phí giữa các khu vực. Nghiên cứu đồng thời cho thấy tỷ lệ người hút thuốc tại Southeast là 25%, cao hơn mức 17,85% tại Southwest. Khi chuẩn hóa theo cơ cấu hút thuốc, khoảng cách chi phí trung bình lớn nhất giữa các khu vực giảm khoảng 77,5%.

Như vậy, sự khác biệt chi phí quan sát được giữa các khu vực có thể chịu ảnh hưởng từ cơ cấu khách hàng, chứ không nhất thiết xuất phát từ bản thân yếu tố địa lý. Do đó, một giải pháp thực tế là chuyển từ cách phân bổ nguồn lực chăm sóc sức khỏe đồng đều theo địa bàn sang phân bổ theo nhu cầu và đặc điểm rủi ro của cộng đồng. Chẳng hạn, các doanh nghiệp bảo hiểm có thể phối hợp với chính quyền địa phương, bệnh viện và trung tâm y tế để tổ chức các chương trình khám sức khỏe lưu động, tư vấn cai thuốc lá hoặc sàng lọc nguy cơ sức khỏe tại những cộng đồng có tỷ lệ người thuộc nhóm nguy cơ cao. Việc lựa chọn địa bàn triển khai cần dựa trên dữ liệu thực tế về đặc điểm dân cư, khả năng tiếp cận dịch vụ y tế và nhu cầu chăm sóc sức khỏe, thay vì chỉ căn cứ vào mức chi phí trung bình của khu vực.

Một sáng kiến có thể triển khai là xây dựng "bản đồ nhu cầu chăm sóc sức khỏe cộng đồng". Bản đồ này tổng hợp dữ liệu đã được ẩn danh về các nhóm tuổi, tình trạng hút thuốc, BMI và nhu cầu sử dụng dịch vụ y tế tại từng địa bàn. Từ đó, cơ quan quản lý và đơn vị cung cấp dịch vụ có thể xác định khu vực cần ưu tiên tổ chức khám sàng lọc, tư vấn sức khỏe hoặc hỗ trợ tiếp cận dịch vụ y tế.

Giải pháp không chỉ giúp doanh nghiệp bảo hiểm sử dụng hiệu quả hơn nguồn lực chăm sóc dự phòng mà còn có thể mang lại lợi ích trực tiếp cho người dân, đặc biệt là những nhóm gặp khó khăn trong việc tiếp cận các dịch vụ kiểm tra sức khỏe. Đồng thời, việc sử dụng dữ liệu để xác định nhu cầu thực tế sẽ góp phần hạn chế tình trạng phân bổ nguồn lực theo cảm tính hoặc dựa trên những chênh lệch chi phí chưa được giải thích đầy đủ.

2.6. Thiết kế các gói bảo hiểm gia đình linh hoạt theo nhu cầu chăm sóc thực tế

Trong nghiên cứu, số người phụ thuộc (children) có tương quan thuận nhưng rất yếu với chi phí y tế cá nhân, với hệ số Pearson chỉ đạt 0,068. Điều này cho thấy số lượng người phụ thuộc không phải là yếu tố có mối liên hệ tuyến tính đáng kể về mặt thực tiễn khi được xem xét riêng lẻ trong bộ dữ liệu. Vì vậy, doanh nghiệp bảo hiểm không nên chỉ dựa vào số con hoặc số người phụ thuộc để suy đoán mức chi phí y tế của một cá nhân.

Thay vào đó, có thể phát triển gói bảo hiểm gia đình linh hoạt, cho phép các thành viên lựa chọn quyền lợi theo nhu cầu chăm sóc sức khỏe riêng. Ví dụ, trẻ em có thể được ưu tiên quyền lợi khám sức khỏe định kỳ và tiêm chủng; người trưởng thành được bổ sung các dịch vụ sàng lọc và tư vấn sức khỏe; người lớn tuổi có thể lựa chọn quyền lợi theo dõi bệnh mạn tính và khám chuyên sâu. Các thành viên vẫn được quản lý trong cùng một hợp đồng gia đình để thuận tiện theo dõi và thanh toán.
Điểm khác biệt của mô hình là thay vì áp dụng một gói quyền lợi giống nhau cho tất cả thành viên, khách hàng có thể lựa chọn và điều chỉnh quyền lợi theo nhu cầu của từng người. Doanh nghiệp bảo hiểm cũng có thể thiết kế cơ chế quản lý chung cho cả gia đình, chẳng hạn một tài khoản theo dõi lịch khám, nhắc lịch tái khám và tổng hợp các khoản chi trả của từng thành viên.

Giải pháp này giúp các gia đình chủ động hơn trong việc quản lý ngân sách chăm sóc sức khỏe, đồng thời hạn chế tình trạng mua những quyền lợi không cần thiết hoặc thiếu các dịch vụ phù hợp với nhu cầu thực tế. Tuy nhiên, đây là đề xuất về thiết kế sản phẩm dựa trên định hướng lấy khách hàng làm trung tâm, không phải kết luận rằng quy mô gia đình không ảnh hưởng đến chi phí y tế trong mọi trường hợp.

3. Chỉ ra các giới hạn của tập dữ liệu và hướng mở rộng trong tương lai.

Mặc dù bộ dữ liệu Medical Cost Personal Dataset cung cấp cơ sở để phân tích mối liên hệ giữa đặc điểm cá nhân và chi phí y tế, kết quả nghiên cứu vẫn tồn tại một số giới hạn nhất định. Những giới hạn này chủ yếu xuất phát từ phạm vi thông tin được thu thập, tính chất của nguồn dữ liệu và phương pháp phân tích. Việc nhận diện các hạn chế có ý nghĩa quan trọng nhằm đánh giá đúng mức độ tin cậy của kết quả, đồng thời xác định hướng mở rộng để nâng cao khả năng ứng dụng trong thực tiễn.

3.1. Giới hạn của tập dữ liệu

Phạm vi quan sát và quy mô dữ liệu còn hạn chế. Nghiên cứu sử dụng bộ dữ liệu Medical Cost Personal Dataset được công bố trên Kaggle, bao gồm 1.338 quan sát ban đầu và 7 thuộc tính. Sau khi loại bỏ một bản ghi trùng lặp hoàn toàn, dữ liệu còn 1.337 quan sát. Mặc dù bộ dữ liệu cung cấp thông tin về tuổi, giới tính, BMI, tình trạng hút thuốc, số người phụ thuộc, khu vực sinh sống và chi phí y tế, quy mô này

vẫn tương đối hạn chế nếu sử dụng để khái quát hóa đặc điểm chi phí y tế của toàn bộ dân số Hoa Kỳ. Bên cạnh đó, dữ liệu chỉ phân chia khu vực sinh sống thành bốn nhóm địa lý lớn, chưa phản ánh được sự khác biệt giữa các bang, thành phố, khu vực đô thị và nông thôn. Do đó, kết quả so sánh giữa các khu vực chưa đủ cơ sở để đưa ra kết luận rộng hơn về sự khác biệt trong chi phí y tế giữa các địa bàn.

Tính chất của nguồn dữ liệu chưa phản ánh đầy đủ chi phí bảo hiểm y tế thực tế. Đây là một hạn chế đặc biệt quan trọng của nghiên cứu. Theo thông tin được trình bày trong báo cáo, bộ dữ liệu được mô phỏng dựa trên số liệu nhân khẩu học của Cục Điều tra Dân số Hoa Kỳ, không phải dữ liệu bồi thường bảo hiểm thực tế. Vì vậy, các giá trị chi phí trong bộ dữ liệu chủ yếu có ý nghĩa minh họa cho xu hướng và mối liên hệ giữa các biến, chưa thể đại diện đầy đủ cho các khoản chi trả thực tế của doanh nghiệp bảo hiểm. Điều này cũng khiến việc sử dụng trực tiếp các kết quả để định phí, dự báo nghĩa vụ bồi thường hoặc xây dựng chính sách bảo hiểm có thể dẫn đến những sai lệch nhất định.

Các biến giải thích chưa bao quát đầy đủ những yếu tố ảnh hưởng đến chi phí y tế. Bộ dữ liệu hiện tại tập trung vào một số đặc điểm nhân khẩu học, sức khỏe và hành vi cá nhân. Tuy nhiên, chi phí y tế trên thực tế còn có thể chịu ảnh hưởng bởi nhiều yếu tố khác chưa được đưa vào phân tích, chẳng hạn như tiền sử bệnh lý, tình trạng bệnh mạn tính, mức độ nghiêm trọng của bệnh, tần suất khám chữa bệnh, loại hình dịch vụ y tế sử dụng, mức độ bao phủ bảo hiểm, thu nhập và khả năng tiếp cận cơ sở y tế. Việc thiếu những thông tin này khiến mô hình chưa thể giải thích toàn diện sự khác biệt về chi phí giữa các cá nhân. Chẳng hạn, hai người có cùng độ tuổi, BMI và tình trạng hút thuốc vẫn có thể phát sinh chi phí rất khác nhau do khác biệt về bệnh nền hoặc nhu cầu điều trị.
Dữ liệu chưa thể hiện sự thay đổi của chi phí y tế theo thời gian. Các phân tích trong nghiên cứu chủ yếu dựa trên thông tin của từng cá nhân tại một tập dữ liệu nhất định, chưa có chuỗi quan sát theo thời gian để theo dõi sự thay đổi của tình trạng sức khỏe và chi phí y tế. Vì vậy, nhóm chưa thể đánh giá một cá nhân có chi phí y tế thay đổi như thế nào khi tuổi tăng lên, khi thay đổi thói quen hút thuốc hoặc khi chỉ số BMI được cải thiện. Đồng thời, nghiên cứu cũng chưa xem xét được ảnh hưởng của lạm phát y tế, biến động giá dịch vụ, thay đổi chính sách bảo hiểm và những yếu tố kinh tế - xã hội theo từng giai đoạn.

Phương pháp phân tích mới chủ yếu xác định mối liên hệ thống kê, chưa chứng minh được quan hệ nhân quả. Nghiên cứu đã sử dụng thống kê mô tả, so sánh giữa các nhóm, phân tích tương quan Pearson và Spearman cùng một số kiểm định thống kê để nhận diện những yếu tố có mối liên hệ với chi phí y tế. Tuy nhiên, các phương pháp này chưa đủ để khẳng định một yếu tố cụ thể trực tiếp làm tăng hoặc giảm chi phí.

Chẳng hạn, mặc dù nhóm hút thuốc có chi phí trung bình cao hơn đáng kể so với nhóm không hút thuốc, kết quả này chưa loại trừ được ảnh hưởng đồng thời của tuổi, BMI và những đặc điểm sức khỏe khác. Tương tự, mối liên hệ giữa BMI và chi phí có sự khác biệt rõ rệt theo tình trạng hút thuốc, nhưng chưa thể kết luận rằng sự kết hợp của hai yếu tố này trực tiếp gây ra mức chi phí cao hơn. Do đó, các kết quả cần được diễn giải thận trọng, tránh chuyển từ mối tương quan quan sát được sang kết luận về nguyên nhân.

3.2. Hướng mở rộng trong tương lai

Từ những hạn chế trên, nhóm đề xuất một số hướng mở rộng nhằm nâng cao chất lượng dữ liệu, chiều sâu phân tích và khả năng ứng dụng của nghiên cứu.

Mở rộng nguồn dữ liệu và tăng tính đại diện của mẫu nghiên cứu. Trong các nghiên cứu tiếp theo, có thể kết hợp bộ dữ liệu hiện tại với những nguồn dữ liệu thực tế từ doanh nghiệp bảo hiểm, bệnh viện hoặc cơ quan quản lý y tế. Việc mở rộng số lượng quan sát, bổ sung dữ liệu từ nhiều bang và nhóm dân cư khác nhau sẽ giúp phản ánh đa dạng hơn đặc điểm của người tham gia bảo hiểm. Đặc biệt, cần ưu tiên sử dụng dữ liệu bồi thường thực tế đã được ẩn danh, bao gồm số tiền yêu cầu bồi thường, số tiền được chi trả và tần suất sử dụng dịch vụ y tế. Đây sẽ là cơ sở quan trọng để kiểm tra xem những xu hướng phát hiện từ bộ dữ liệu mô phỏng có tiếp tục xuất hiện trong hoạt động bảo hiểm thực tế hay không.

Bổ sung các biến phản ánh tình trạng sức khỏe và điều kiện kinh tế - xã hội. Bên cạnh 7 thuộc tính hiện có, các nghiên cứu tiếp theo nên bổ sung những biến có khả năng giải thích trực tiếp hơn sự khác biệt về chi phí, chẳng hạn như tiền sử bệnh lý, bệnh nền, huyết áp, đường huyết, tình trạng tim mạch, tần suất khám chữa bệnh, loại hình dịch vụ y tế và mức độ bao phủ bảo hiểm. Ngoài ra, việc bổ sung thu nhập, nghề nghiệp, trình độ học vấn và khả năng tiếp cận cơ sở y tế sẽ giúp đánh giá rõ hơn vai trò của điều kiện kinh tế - xã hội đối với chi phí chăm sóc sức khỏe. Đặc biệt, việc bổ sung thông tin về tiền sử bệnh và mức độ nghiêm trọng của bệnh có thể giúp giải thích những trường hợp có chi phí y tế cao nhưng không được phản ánh đầy đủ qua các biến tuổi, BMI hoặc tình trạng hút thuốc. Qua đó, mô hình phân tích có thể chuyển từ việc nhận diện các đặc điểm cá nhân có liên quan đến chi phí sang đánh giá toàn diện hơn về nhu cầu sử dụng dịch vụ y tế.

Phát triển dữ liệu theo thời gian để theo dõi sự thay đổi của chi phí y tế. Thay vì chỉ phân tích dữ liệu tại một thời điểm, các nghiên cứu tiếp theo có thể xây dựng bộ dữ liệu theo dõi cùng một nhóm khách hàng qua nhiều năm. Mỗi cá nhân được ghi nhận thông tin về tình trạng sức khỏe, hành vi sinh hoạt, quá trình tham gia bảo hiểm và các khoản chi phí y tế phát sinh theo từng giai đoạn. Cách tiếp cận này cho phép

đánh giá sự thay đổi của chi phí khi khách hàng bước sang nhóm tuổi mới, cải thiện BMI hoặc thay đổi tình trạng hút thuốc. Một hướng ứng dụng đáng chú ý là theo dõi hiệu quả của các chương trình chăm sóc sức khỏe dự phòng. Chẳng hạn, có thể so sánh chi phí y tế và tần suất sử dụng dịch vụ trước và sau khi khách hàng tham gia chương trình hỗ trợ cai thuốc lá hoặc kiểm soát cân nặng. Nếu có nhóm đối chứng phù hợp, nghiên cứu còn có thể đánh giá tốt hơn hiệu quả thực tế của các chương trình này, thay vì chỉ dừng lại ở việc quan sát sự khác biệt giữa các nhóm khách hàng.

Mở rộng phương pháp phân tích bằng các mô hình hồi quy và thuật toán học máy. Từ kết quả phân tích tương quan và so sánh nhóm hiện tại, các nghiên cứu tiếp theo có thể sử dụng mô hình hồi quy đa biến để đánh giá mối liên hệ giữa từng yếu tố với chi phí y tế trong điều kiện kiểm soát đồng thời các đặc điểm khác. Đặc biệt, cần xem xét các biến tương tác giữa BMI và tình trạng hút thuốc, bởi nghiên cứu hiện tại cho thấy mối liên hệ giữa BMI và chi phí khác biệt đáng kể giữa hai nhóm này. Đây cũng là hướng được đề cập trong phần phân tích BMI của báo cáo.

Bên cạnh đó, có thể thử nghiệm các thuật toán học máy như Decision Tree, Random Forest hoặc Gradient Boosting để dự báo chi phí y tế dựa trên hồ sơ cá nhân. Việc so sánh các mô hình theo những tiêu chí như MAE, RMSE và R^2 sẽ giúp lựa chọn phương pháp có khả năng dự báo phù hợp hơn. Tuy nhiên, cần chia dữ liệu thành tập huấn luyện và kiểm tra, đánh giá khả năng dự báo trên dữ liệu chưa được sử dụng để xây dựng mô hình, đồng thời kiểm tra mức độ ổn định giữa các nhóm khách hàng nhằm hạn chế hiện tượng mô hình chỉ phù hợp với mẫu nghiên cứu ban đầu.

Mở rộng phạm vi nghiên cứu sang bối cảnh Việt Nam để tăng khả năng ứng dụng thực tiễn. Do bộ dữ liệu hiện tại được xây dựng từ bối cảnh Hoa Kỳ, các kết quả chưa thể áp dụng trực tiếp cho thị trường bảo hiểm y tế Việt Nam, nơi có sự khác biệt về cơ chế bảo hiểm, mức thu nhập, hệ thống cung cấp dịch vụ y tế, thói quen chăm sóc sức khỏe và cơ cấu dân số. Vì vậy, một hướng nghiên cứu có ý nghĩa thực tiễn là xây dựng bộ dữ liệu tương tự tại Việt Nam, thông qua việc kết hợp dữ liệu khảo sát cá nhân với dữ liệu đã ẩn danh từ các cơ sở khám chữa bệnh hoặc doanh nghiệp bảo hiểm.Trên cơ sở đó, có thể kiểm định liệu tình trạng hút thuốc, độ tuổi và BMI có tiếp tục là những yếu tố phân hóa chi phí đáng chú ý hay không; đồng thời xác định những yếu tố đặc thù của Việt Nam có ảnh hưởng đến chi phí y tế. Kết quả nghiên cứu có thể hỗ trợ doanh nghiệp bảo hiểm thiết kế sản phẩm phù hợp hơn với khả năng chi trả của người dân, giúp cơ sở y tế xây dựng chương trình chăm sóc dự phòng và cung cấp thêm bằng chứng cho hoạt động hoạch định chính sách y tế.

3.3. Định hướng phát triển nghiên cứu

Nhìn chung, hướng mở rộng quan trọng nhất không chỉ là tăng số lượng quan sát mà còn phải cải thiện chất lượng, tính thực tế và chiều sâu của thông tin được thu thập. Trong ngắn hạn, nhóm có thể ưu tiên bổ sung các biến về tình trạng sức khỏe và kiểm định mô hình hồi quy có xét đến tương tác giữa BMI và tình trạng hút thuốc. Trong dài hạn, việc tiếp cận dữ liệu bảo hiểm thực tế theo thời gian và mở rộng nghiên cứu sang Việt Nam sẽ giúp kiểm chứng khả năng khái quát hóa của các phát hiện.

Qua đó, nghiên cứu có thể phát triển từ việc mô tả và nhận diện những yếu tố có liên quan đến chi phí y tế cá nhân thành một công cụ hỗ trợ phân tích, dự báo và quản lý rủi ro có tính ứng dụng cao hơn. Điều này không chỉ mang lại giá trị cho doanh nghiệp bảo hiểm và cơ sở y tế mà còn góp phần thúc đẩy các chương trình chăm sóc sức khỏe dự phòng, giúp người dân chủ động kiểm soát sức khỏe và giảm thiểu những gánh nặng chi phí y tế có thể phòng tránh.